

BỘ GIÁO DỤC VÀ ĐÀO TẠO

TRƯỜNG ĐẠI HỌC MỞ THÀNH PHỐ HỒ CHÍ MINH

BÁO CÁO TỔNG KẾT

ĐỀ TÀI NGHIÊN CỨU KHOA HỌC SINH VIÊN

**SHEAF ATTENTION NETWORKS (SHEAFAN)
TRONG NGHIÊN CỨU PHÂN TÍCH DỰ ĐOÁN
DIỄN BIẾN DỊCH TỄ BỆNH TRUYỀN NHIỄM SỐT
XUẤT HUYẾT Ở BRAZIL**

MÃ SỐ ĐỀ TÀI: 594

TP HỒ CHÍ MINH, 03/2026

BỘ GIÁO DỤC VÀ ĐÀO TẠO

TRƯỜNG ĐẠI HỌC MỞ THÀNH PHỐ HỒ CHÍ MINH

BÁO CÁO TỔNG KẾT

ĐỀ TÀI NGHIÊN CỨU KHOA HỌC SINH VIÊN

**SHEAF ATTENTION NETWORKS (SHEAFAN)
TRONG NGHIÊN CỨU PHÂN TÍCH DỰ ĐOÁN
DIỄN BIẾN DỊCH TỄ BỆNH TRUYỀN NHIỄM SỐT
XUẤT HUYẾT Ở BRAZIL**

MÃ SỐ ĐỀ TÀI: 594

Chủ nhiệm đề tài: HUỖNH LÊ THANH HẢI

Khoa: ĐÀO TẠO ĐẶC BIỆT

Các thành viên:

NGUYỄN THANH TUẤN

CHÂU QUỐC BẢO

Người hướng dẫn: TS. LÊ QUANG MINH

TP HỒ CHÍ MINH, 03/2026

THÔNG TIN KẾT QUẢ NGHIÊN CỨU CỦA ĐỀ TÀI

1. Thông tin chung:

- Tên đề tài: Sheaf Attention Networks (SheafAN) trong nghiên cứu phân tích dự đoán diễn biến dịch tễ ở bệnh truyền nhiễm sốt xuất huyết ở Brazil.
- Mã số đề tài: 594
- Sinh viên chủ nhiệm đề tài: Huỳnh Lê Thanh Hải
- Khoa: Đào Tạo Đặc Biệt Mã số sinh viên: 2251012054
- Giảng viên hướng dẫn: Tiến Sĩ. Lê Quang Minh

2. Mục tiêu đề tài:

Thực nghiệm bộ dữ liệu thực tế chính quy qua dự án Mosqlimate từ Brazil để dự đoán diễn biến dịch tễ ở bệnh truyền nhiễm sốt xuất huyết tại Brazil qua 4 mô hình Graph Neural Networks, Graph Convolutional Networks, Spatial-Temporal Graph Attention Networks, Sheaf Neural Networks Baseline, Sheaf-Connection Neural Based Positional Encoding Networks.

3. Tính mới và sáng tạo:

Thay đổi từ tư duy dự đoán bệnh sốt xuất huyết không chỉ dự đoán từ số ca bệnh mà còn liên kết chặt chẽ đến biến môi trường, dân số, khí hậu, liên kết địa lý và cấp bậc hành chính thành phố, bản đồ và mạng lưới liên kết đô thị thông qua 4 mô hình tiên tiến mạng nơ-ron đồ thị GNNs, GCNs, ST-GATs, Sheaf Neural Networks và Sheaf-Connection Neural Based Positional Encoding Networks.

4. Kết quả nghiên cứu:

Khảo sát xây dựng thiết kế Pipeline áp dụng mạng Nơ-ron đồ thị ở bệnh sốt xuất huyết từ bộ dữ liệu thực tế, thông qua đó huấn luyện & phân tích và có thể dự đoán và trực quan hóa bằng bản đồ mạng lưới liên kết toàn Brazil. Phân tích chi tiết từng mô hình về

khả năng học huấn luyện và kết luận rằng Sheaf Neural Networks thể hiện khả năng học mạnh mẽ trong lý thuyết bó so với các mô hình còn lại làm nền tảng.

5. Đóng góp về mặt kinh tế - xã hội, giáo dục và đào tạo, an ninh, quốc phòng và khả năng áp dụng của đề tài:

Có thể mang thực nghiệm về Việt Nam tương tự như Brazil vì bệnh sốt xuất huyết có nền tảng cơ sở dữ liệu ở mỗi quốc gia như số ca bệnh, biến môi trường, dân số, khí hậu, liên kết địa lý và cấp bậc hành chính thành phố/phường, bản đồ nơi mà các cơ quan – viện tại Việt Nam hoàn toàn có thể cung cấp dữ liệu. Và kế thừa ý tưởng triển khai tiếp tục nghiên cứu dự án từ các mô hình tiên tiến áp dụng mạng lưới liên kết nơ-ron đồ thị (GNNs) và các biến thể đặc biệt là về lý thuyết Bó trong Sheaf Attention Networks trong việc dự đoán và trực quan hóa bệnh sốt xuất huyết tại Việt Nam trong công tác y tế và phòng tránh dịch bệnh.

6. Công bố khoa học của sinh viên từ kết quả nghiên cứu của đề tài

STT	Tên công bố (1)	Chỉ mục (2)	Xếp hạng (3)	Trạng thái xuất bản (4)
1				
...				

Ghi chú:

(1): Tên công bố được ghi theo định dạng APA, lên Scholar để lấy định dạng mẫu, ví dụ: “Lâm Quốc Bảo., & Nguyễn Lê Hoàng Thụy Tô Quyên. (2024). Nghiên cứu các yếu tố ảnh hưởng đến hiệu quả thực hiện nhiệm vụ của thể hệ Z. *TẠP CHÍ KHOA HỌC ĐẠI HỌC MỞ THÀNH PHỐ HỒ CHÍ MINH-KINH TẾ VÀ QUẢN TRỊ KINH DOANH*, 19(1), trang-trang.”

(2): Ghi rõ chỉ mục xếp hạng là Scopus, Web of Science, ACI... đối với công bố quốc tế hoặc HDGSNN nếu công bố trong nước.

(3): Ghi rõ xếp hạng Q1, Q2, Q3, Q4 và (hoặc) xếp hạng SSCI, SCIE, AHCI, ESCI đối với công bố quốc tế hoặc mức điểm của tạp chí theo quy định của Hội đồng Giáo sư nhà nước nếu công bố trong nước.

(4): Ghi rõ “Chấp nhận đăng” hoặc “Đã xuất bản”.

MỤC LỤC

DANH MỤC THUẬT NGỮ TIẾNG ANH	1
DANH MỤC VIẾT TẮT.....	2
DANH MỤC KÝ HIỆU.....	4
DANH MỤC HÌNH VẼ	6
DANH MỤC BẢNG	6
TÓM TẮT	8
Chương 1. Giới thiệu	9
1.1. Bối cảnh dịch tễ & Nhu cầu dự báo	9
1.1.1. Thực trạng dịch tễ sốt xuất huyết tại Brazil.....	9
1.1.2. Nhu cầu cấp thiết về một công cụ dự báo hiện đại.....	9
1.2. Tổng quan tình hình nghiên cứu	9
1.2.1. Xu hướng mô hình hóa dựa trên đồ thị (Graph-based Approach).....	9
1.3. Khoảng trống trong các mô hình dự báo	10
1.3.1. Thiếu hụt yếu tố tương quan không gian (Spatio-temporal)	10
1.4. Định vị & Mục tiêu của Graph Neural Networks trong bài toán bệnh sốt xuất huyết	11
1.4.1. Định vị mô hình GNN trong nghiên cứu dịch	11
1.4.2. Mục tiêu nghiên cứu	12
1.4.3. Đối tượng và phạm vi nghiên cứu	12
1.5. Đóng góp.....	13
1.5.1. Về mặt khoa học	13
1.5.2. Về mặt thực tiễn.....	13
Chương 2. Cơ sở lý thuyết.....	14
2.1. Graph Neural Networks cho dữ liệu không gian	14
2.1.1. Khung lý thuyết và Biểu diễn cấu trúc đồ thị	14

2.1.2.	Cơ chế nắm bắt sự phụ thuộc không gian.....	14
2.2.	Graph Convolutional Networks và cơ chế tổng hợp lân cận	15
2.2.1.	Cơ chế vận hành và Phép toán tích chập trên đồ thị.....	15
2.2.2.	Hạn chế về tính linh hoạt cấu trúc	15
2.3.	Graph Attention Networks và cơ chế attention cho mạng lưới dịch tễ.....	15
2.3.1.	Cơ chế Tự chú ý (Self-attention Mechanism) trên đồ thị.....	15
2.3.2.	Công thức hóa trọng số chú ý động.....	16
2.4.	Spatial-Temporal Graph Attention Networks về không gian thời gian	16
2.4.1.	Bản chất tương quan đa chiều trong dịch tễ học	16
2.4.2.	Kiến trúc tích hợp Không - Thời gian (Hybrid Architecture)	17
2.4.1.	Ưu thế trong dự báo dịch tễ ngắn hạn	17
2.5.	Sheaf Neural Networks về lý thuyết bó	17
2.5.1.	Cơ sở lý thuyết về Bó tế bào (Cellular Sheaves).....	17
2.5.2.	Giải quyết hiện tượng San phẳng dữ liệu (Oversmoothing)	18
2.5.3.	Giá trị trong mô hình hóa dịch tễ phức tạp.....	18
2.6.	Sheaf-based Positional Encoding.....	19
2.6.1.	Hạn chế của phương pháp mã hóa tọa độ truyền thống	19
2.6.2.	Bảo toàn cấu trúc Topo thông qua Hình học	19
2.6.3.	Tăng cường khả năng biểu diễn thông qua sự kết hợp giữa Sheaf- Encoding và Attention.....	20
2.7.	Khoảng trống & vị trí nghiên cứu (Gap & Positioning)	20
2.7.1.	Phân tích khoảng trống nghiên cứu	20
2.7.2.	Định vị nghiên cứu	20
2.8.	Định nghĩa toán học về bài toán dự báo	21
Chương 3.	Nguồn dữ liệu và phương pháp xây dựng	21
3.1.	Xây dựng đồ thị từ dữ liệu đa nguồn	21

3.1.1.	Tổng quan & định vị đa nguồn dữ liệu (Overview & Positioning).....	21
3.1.2.	Định nghĩa khởi tạo Nút – Node.....	29
3.1.3.	Định nghĩa khởi tạo Cạnh – Edge.....	31
3.1.4.	Định nghĩa Đặc trưng và Nhãn gốc – Original Features and Labels...	33
3.1.5.	Bổ sung Đặc trưng dẫn xuất – Engineered Features	34
3.1.6.	Xây dựng snapshot theo tuần.....	35
3.1.7.	Phân chia mặt nạ train/validation/test theo trục thời gian	37
3.1.8.	Chuẩn hóa và biến đổi log - scale & log-transform.....	38
3.2.	Kiến trúc mô hình – Model Architectures	39
3.2.1.	Graph Neural Networks Baseline	39
3.2.2.	Graph Convolutional Networks.....	40
3.2.3.	Spatial-Temporal Graph Attention Networks	40
3.2.4.	Sheaf Neural Networks Baseline.....	42
3.2.5.	Sheaf-Connection Neural Networks.....	43
3.2.6.	Độ phức tạp và tính ổn định	45
3.3.	Hàm mất mát & Thước đo - Loss & Metrics	46
3.3.1.	Loss: Huber – Robust với outliers	46
3.3.2.	Log-space metrics: MAE/RMSE/R ² /trimmed-R ²	47
3.3.3.	Real-space metrics: MAE/RMSE/SMAPE/R ² /trimmed-R ²	48
3.3.4.	ROC-AUC/PR-AUC từ hồi quy (q=0.9).....	49
3.3.5.	Kiểm tra warning SMAPE (khi y _{true} =0) và cách xử lý (Discussion)	
	50	
Chương 4.	Thực nghiệm.....	51
4.1.	Dữ liệu thực nghiệm và thống kê tập dữ liệu.....	51
4.2.	Thiết lập thực nghiệm	56
4.2.1.	Môi trường thực nghiệm (Computing Environment)	56

4.2.2.	Chiến thuật thực nghiệm và cấu hình	56
Chương 5.	Kết quả phân tích và thảo luận	58
5.1.	Tổng quan so sánh các mô hình	58
5.2.	Phân tích hội tụ	62
5.3.	Phân tích theo tuần	70
5.4.	Kiểm chứng độ hợp lệ của thực nghiệm	74
5.4.1.	Kiểm định hoán vị nhân - Permutation Test	74
5.5.	Ý nghĩa diễn giải dịch tễ	75
Chương 6.	Kết luận	76
6.1.	Kết luận chính từ kết quả thực nghiệm	76
6.1.1.	Kết luận theo log-space (MAE/RMSE/R ² /trimmed-R ²)	76
6.1.2.	Kết luận theo real-space (MAE/RMSE/SMAPE/R ² /trimmed-R ²)	76
6.1.3.	Kết luận về hội tụ và độ ổn định (epoch log & convergence plots)	77
6.1.4.	Kết luận về khả năng tổng quát hóa theo thời gian	77
6.2.	Kết luận theo từng họ mô hình	78
6.2.1.	GNN baseline: vai trò mốc so sánh và giới hạn	78
6.2.2.	GCN: cải thiện nhờ tổng hợp lân cận, khi nào hiệu quả	78
6.2.3.	ST-GAT: lý do mạnh trong bối cảnh không gian-thời gian	79
6.2.4.	Sheaf baseline: nhận định về hiệu năng và độ khó tối ưu	79
6.2.5.	Sheaf-Connection (sheaf_conn): mức độ phù hợp với cấu trúc liên vùng	79
6.3.	Đóng góp	80
6.3.1.	Dữ liệu và mô hình hóa	80
6.3.2.	Thiết kế Pipeline trong bài toán dịch tễ sốt xuất huyết	80
6.3.3.	Khả năng ứng dụng thực tế giám sát dịch tễ	80
6.3.4.	Khả năng mang thực nghiệm về Việt Nam	80

6.3.5. Hướng phát triển và kiến nghị nghiên cứu tiếp theo	80
TÀI LIỆU THAM KHẢO	81
PHỤ LỤC	83

DANH MỤC THUẬT NGỮ TIẾNG ANH

Graph Neural Networks	Mạng nơ-ron đồ thị
Graph Convolutional Networks	Mạng tích chập đồ thị
Graph Attention Networks	Mạng chú ý đồ thị
Spatial-Temporal Graph Attention Networks	Mạng chú ý đồ thị không gian–thời gian
Sheaf Neural Networks	Mạng nơ-ron bó
Sheaf Attention Networks	Mạng chú ý dựa trên sheaf/bó
Cellular Sheaves	Bó tế bào
Sheaf-based Positional Encoding	Mã hóa vị trí dựa trên sheaf/bó
Restriction Maps	Ảnh xạ hạn chế
Message Passing	Lan truyền thông điệp / truyền tin
Self-attention Mechanism	Cơ chế tự chú ý
Multi-head Attention	Chú ý đa đầu
Hybrid Architecture	Kiến trúc tích hợp / kiến trúc lai
Graph Attention Layer	Lớp chú ý đồ thị
Gated Recurrent Unit	Đơn vị tái phát có cổng
non-Euclidean	Phi Euclid
First-order approximation	Xấp xỉ bậc một
Edge-conditioned message passing	Lan truyền thông điệp có điều kiện theo cạnh
Original Features and Labels	Đặc trưng và nhãn gốc
Engineered Features	Đặc trưng dẫn xuất / đặc trưng được tạo thêm
weekly graph snapshots	Ảnh chụp đồ thị theo tuần
End-to-end Pipeline	Quy trình đầu-cuối
nearest-year imputation	Bù khuyết theo năm gần nhất
temporal split / year-based temporal split	Chia theo trục thời gian / chia theo năm
data leakage	Rò rỉ dữ liệu
early stopping	Dừng sớm
checkpoint	Điểm lưu mô hình
Sanity Check	Kiểm định hợp lệ sơ bộ
Permutation Test	Kiểm định hoán vị nhãn
Computing Environment	Môi trường thực nghiệm

DANH MỤC VIẾT TẮT

SheafAN	Sheaf Attention Networks
SheafAT	Sheaf Attention Networks (dạng viết tắt xuất hiện trong phần giới thiệu mô hình)
GNN	Graph Neural Networks
GCN	Graph Convolutional Networks
GAT	Graph Attention Networks
ST-GAT	Spatial-Temporal Graph Attention Networks
SNN	Sheaf Neural Networks
RNN	Recurrent Neural Networks
CNN	Convolutional Neural Networks
LSTM	Long Short-Term Memory
GRU	Gated Recurrent Unit
ARIMA	AutoRegressive Integrated Moving Average
KNN	K-Nearest Neighbors
BI	Breteau Index / Chỉ số Breteau
MAE	Mean Absolute Error
RMSE	Root Mean Squared Error
SMAPE	Symmetric Mean Absolute Percentage Error
MAPE	Mean Absolute Percentage Error
MSE	Mean Squared Error

ROC-AUC	Receiver Operating Characteristic – Area Under the Curve
PR-AUC	Precision-Recall Area Under the Curve
CFR	Case Fatality Rate / Tỷ lệ tử vong ca bệnh
ICU	Intensive Care Unit / Đơn vị hồi sức tích cực
WHO	World Health Organization / Tổ chức Y tế Thế giới
SINAN	Hệ thống Cảnh báo / giám sát bệnh tật quốc gia Brazil (tên viết tắt được file dùng trong bối cảnh hệ thống giám sát dịch tễ)
IBGE	Viện Địa lý và Thống kê Brazil
DOI	Digital Object Identifier
CSV	Comma-Separated Values
EPSG	Mã hệ quy chiếu tọa độ địa lý
WGS84	World Geodetic System 1984

DANH MỤC KÝ HIỆU

G	Đồ thị biểu diễn hệ thống dịch tễ
$G = (V, E)$	Đồ thị gồm tập nút và tập cạnh
$G = (V, E, A)$	Đồ thị gồm tập nút, tập cạnh và ma trận kề
V	Tập nút
E	Tập cạnh
A	Ma trận kề biểu diễn cấu trúc kết nối không gian
N	Số lượng nút trong đồ thị
D	Số chiều đặc trưng / số biến đầu vào
v_i	Nút thứ i
g_i	Geocode của nút i
ϕ	Ánh xạ từ geocode sang chỉ số nút
h_i	Biểu diễn / đặc trưng của nút i
$h_i^{(l)}$	Biểu diễn của nút i tại lớp l
$N(i)$	Tập lân cận của nút i
W	Ma trận trọng số cần học
$W^{(l)}$	Ma trận biến đổi đặc trưng tại lớp l
c_{ij}	Hệ số chuẩn hóa trong GCN
α_{ij}	Trọng số chú ý từ nút j tới nút i
e_{ij}	Điểm chú ý trước bước softmax
$ $	Phép nối chuỗi (concatenation)
X_t	Ma trận đặc trưng tại thời điểm t
$X_t \in R^{N \times D}$	Ma trận đặc trưng gồm N nút và D biến
y_{t+1}	Vector dự báo số ca tại thời điểm $t+1$

$\int (\cdot)$	Hàm ánh xạ dự báo
L	Hàm mất mát
z_t	Cổng cập nhật trong GRU
r_t	Cổng thiết lập lại trong GRU
h_t	Trạng thái ẩn tại thời điểm t
F	Sheaf / bó trên đồ thị
$F(v)$	Không gian vector gán cho nút v
$F(e)$	Không gian vector gán cho cạnh e
$\phi_{u \leq e}: F(u) \rightarrow F(e)$	Ánh xạ hạn chế từ nút u sang cạnh e
L_F	Sheaf Laplacian / Laplacian bó
D_F	Ma trận bậc khối
A_F	Ma trận kề khối
$X_{v,t}$	Vector đặc trưng của nút v tại thời điểm t
P	Lượng mưa tích lũy
$T_{avg}/temp_med$	Nhiệt độ trung bình
T_{min}	Nhiệt độ tối thiểu
x	Tensor đặc trưng của một snapshot
y	Tensor nhãn của một snapshot
train_mask	Mặt nạ nút dùng khi huấn luyện
val_mask	Mặt nạ nút dùng khi kiểm định
test_mask	Mặt nạ nút dùng khi kiểm thử
$q = 0.9$	Ngưỡng phân vị dùng để quy đổi hồi quy sang bài toán cảnh báo bùng phát

DANH MỤC HÌNH VẼ

Hình 1.1 Cơ chế Message Passing [5]	10
Hình 1.2 Cấu trúc tầng kết nối đầy đủ trong kiến trúc GNN [6]	11
Hình 3.1: Geojs-100-mun.json – bản đồ Brazil cấp thành phố	29
Hình 5.1: Tổng quan các mô hình	58
Hình 5.2 Biểu đồ tổng hợp sự hội tụ	62
Hình 5.3 Hội tụ của từng mô hình	63
Hình 5.4 Hội tụ của biến thể Sheaf	64
Hình 5.5 Công cụ trực quan hóa	75

DANH MỤC BẢNG

Bảng 3.1: Trích chọn 10 dòng từ tệp dengue_2024.csv	23
Bảng 3.2: Trích chọn 10 dòng từ tệp Climate_2024.csv	24
Bảng 3.3: Trích chọn 10 dòng từ tệp environ_vars.csv	26
Bảng 3.4: Trích chọn 10 dòng từ tệp regic2018.csv	28
Bảng 3.5: Trích chọn 10 dòng từ tệp regic2018_clean.csv	28
Bảng 3.6 Độ phức tạp và tính ổn định	46
Bảng 4.1 Thống kê dữ liệu thô theo năm 2010 đến 2024	51
Bảng 4.2 Thống kê dữ liệu thô từ năm 2010 đến 2024	51
Bảng 4.3 Thống kê chia tập dữ liệu	52
Bảng 4.4 Thống kê theo năm chia tập huấn luyện	53
Bảng 4.5 Thống kê về đồ thị	54
Bảng 4.6 Thống kê về đặc trưng	54
Bảng 4.7 Môi trường thực nghiệm	56
Bảng 4.8 Cấu hình theo từng mô hình	57
Bảng 5.1 So sánh tổng quan các mô hình	60
Bảng 5.2 Sự hội tụ của GNN	64
Bảng 5.3 Sự hội tụ của GCN	65
Bảng 5.4 Sự hội tụ của GAT	66
Bảng 5.5 Sự hội của của Sheaf Baseline	67
Bảng 5.6 Sự hội tụ biến thể Sheaf Connection Neural Network	69
Bảng 5.7 Bảng thông số theo tuần	70

Bảng 5.8 Kiểm định hoán vị nhân	74
---------------------------------------	----

TÓM TẮT

Nghiên cứu này xây dựng và đánh giá 5 mô hình: GNN baseline, GCN, Spatial-Temporal GAT (ST-GAT), Sheaf baseline và Sheaf-Connection (sheaf_conn) qua theo khung dự báo sốt xuất huyết (dengue) theo không gian - thời gian ở cấp đô thị (municipality) dựa trên học đồ thị tại Brazil. Dữ liệu được tổ chức thành các weekly graph snapshots trong giai đoạn 2010–2024, với nút là municipality (geocode), cạnh là liên kết lân cận không gian, và đặc trưng nút gồm 14 biến đa nguồn (dịch tễ, khí hậu, dân số và môi trường). Nhãn dự báo là số ca theo tuần, được biến đổi $\log_{1p}$ để giảm lệch phân phối và tăng ổn định tối ưu. Thực nghiệm sử dụng temporal split theo trục thời gian (train: 2010–2020 validation: 2021–2022; test: 2023–2024), huấn luyện với Huber loss, early stopping và theo dõi hội tụ bằng epoch logs, đồng thời tiến hành các thiết kế hợp lệ gồm mask integrity, kiểm tra metadata chuẩn hóa, quét dấu hiệu leakage và permutation test. Kết quả cho thấy sheaf_conn vượt trội nhất quán trên cả validation và test: trong log-space đạt $R^2_{\text{macro}}(\text{test})=0.966$ và $\text{MAE}_{\text{macro}}(\text{test})=0.042$, đồng thời duy trì năng lực cảnh báo tuần bùng phát với PR -AUC(test)=0.993, vượt đáng kể so với ST-GAT và các baseline còn lại. Các kiểm định hoán vị làm suy giảm mạnh R^2 và tăng MAE, củng cố rằng mô hình không dựa vào shortcut/leak. Đồng thời cho thấy kiến trúc connection-style theo cạnh (restriction/consistency) phù hợp đặc biệt với bài toán lan truyền dịch liên vùng theo tuần, và khung dữ liệu – mô hình hóa theo weekly graphs có khả năng mở rộng cho giám sát dịch tễ và cảnh báo sớm trong thực tiễn.

Chương 1. Giới thiệu

1.1. Bối cảnh dịch tễ & Nhu cầu dự báo

1.1.1. Thực trạng dịch tễ sốt xuất huyết tại Brazil

Brazil, một trong những quốc gia chịu ảnh hưởng nặng nề nhất bởi sốt xuất huyết Dengue, chiếm khoảng 80% tổng số ca mắc tại khu vực Mỹ Latinh theo báo cáo của Tổ chức Y tế Thế Giới (WHO) [1]. Tính riêng đến năm 2023 và đầu năm 2024, quốc gia này đã ghi nhận con số kỷ lục hơn 3 triệu ca nhiễm [2], điều này gây ra những hệ lụy nghiêm trọng về sức khỏe cộng đồng và gánh nặng đối với nền kinh tế do chi phí điều trị trực tiếp. Mặc dù các chiến lược kiểm soát vector *Aedes aegypti* đã được Chính Phủ nước này triển khai trong nhiều thập kỉ, từ những năm 1980 và tiếp tục cho đến nay, dịch bệnh vẫn đang tiếp tục bùng phát theo chu kì 3 đến 4 năm một lần với diễn biến bệnh ngày càng phức tạp.

1.1.2. Nhu cầu cấp thiết về một công cụ dự báo hiện đại

Trước thực trạng dịch bệnh lây lan phức tạp qua mạng lưới hạ tầng và di biến động dân cư, các phương pháp giám sát truyền thống dựa trên thống kê tuyến tính đang bộc lộ những rào cản kỹ thuật đáng kể. Việc thiếu hụt công cụ dự báo trực quan tích hợp yếu tố không gian - thời gian (Spatio-Temporal) khiến công tác điều phối nguồn lực y tế thường rơi vào trạng thái bị động. Các mô hình hiện tại thường bỏ qua tính tương quan mạng lưới giữa các đô thị, dẫn đến sai số lớn khi dự báo các đợt bùng phát xuyên vùng.

1.2. Tổng quan tình hình nghiên cứu

Việc dự báo dịch sốt xuất huyết Dengue đã chuyển dịch mạnh mẽ từ các phương pháp thống kê truyền thống sang kỹ thuật học sâu hiện đại nhằm tối ưu hóa độ chính xác.

1.2.1. Xu hướng mô hình hóa dựa trên đồ thị (Graph-based Approach)

Những năm gần đây, xu hướng nghiên cứu dịch tễ học đã có sự chuyển dịch đáng kể từ phân tích các điểm dữ liệu rời rạc sang mô hình hóa dựa trên cấu trúc đồ thị (Graph-based modeling). Phương pháp tiếp cận này cho phép biểu diễn các tương quan địa lý và mạng lưới hạ tầng một cách trực quan và hệ thống. Tuy nhiên, việc thực nghiệm các kiến trúc đồ thị tiên tiến — tiêu biểu là Graph Neural Networks (GNNs) — trên các hệ


sinh thái dữ liệu tích hợp quy mô lớn như dự án Mosqlimate tại Brazil vẫn là một thách thức kỹ thuật chưa được khai phá triệt để.

1.3. Khoảng trống trong các mô hình dự báo

1.3.1. Thiếu hụt yếu tố tương quan không gian (Spatio-temporal)

Các phương pháp truyền thống thường tập trung phân tích trực thời gian tại các địa điểm biệt lập, bỏ qua tính tương quan không gian giữa 5.564 đô thị tại Brazil. Trong bối cảnh hạ tầng kết nối chặt chẽ, dịch bệnh không chỉ biến thiên theo thời gian mà còn lây lan nhanh chóng qua mạng lưới hành chính và sự di biến động dân cư [4]. Việc thiếu hụt các công cụ dự báo trực quan thời gian thực khiến công tác điều phối nguồn lực y tế rơi vào thế bị động, gây khó khăn trong việc xác định tâm dịch và dự đoán hướng lây lan sang các vùng lân cận. Khoảng trống trong xử lý dữ liệu nhiễu, mô hình hóa phi tuyến tính và tương quan không gian đặt ra yêu cầu cấp thiết về một phương pháp luận tiên tiến. Nghiên cứu này định hướng ứng dụng Mạng nơ-ron Đồ thị (Graph Neural Networks - GNNs) như một giải pháp cốt lõi nhờ:

1. **Mô phỏng cấu trúc mạng lưới thực tế:** GNN cho phép biểu diễn các đô thị thành các nút (nodes) và các liên kết giao thông, hành chính thành các cạnh (edges), tái hiện chính xác lộ trình lây nhiễm trong không gian phi Euclid.
2. **Cơ chế Lan truyền Thông điệp (Message Passing):** Mô hình hóa sự tương tác dịch tễ giữa các vùng lân cận, giúp dự báo nguy cơ bùng phát dựa trên cả điều kiện nội tại và áp lực lan truyền từ mạng lưới xung quanh.



Hình 1.1 Cơ chế Message Passing [5]


3. **Đồng hóa dữ liệu đa chiều:** Tích hợp đồng thời dữ liệu khí hậu, dân số và bản đồ không gian để trích xuất các đặc trưng tiềm ẩn, từ đó tối ưu hóa độ chính xác trong việc xác định các điểm nóng dịch bệnh.

1.4. Định vị & Mục tiêu của Graph Neural Networks trong bài toán bệnh sốt xuất huyết

1.4.1. Định vị mô hình GNN trong nghiên cứu dịch

Trong bối cảnh dịch tễ phức tạp tại Brazil, nghiên cứu định vị Graph Neural Networks (GNNs) là khung kiến trúc cốt lõi nhằm chuyển đổi phương thức tiếp cận từ dự báo trên điểm sang dự báo trên mạng lưới kết nối. Khác với các mô hình truyền thống (Random Forest, ARIMA), GNNs cho phép biểu diễn hệ thống dịch tễ dưới dạng đồ thị đa tầng $G = (V, E)$.

1. Các nút (Node - V): Đại diện cho 5.564 đô thị tại Brazil, những đặc trưng nội tại như dữ liệu dịch tễ lịch sử, biến số khí tượng và chỉ số nhân khẩu học.
2. Các cạnh (Edges - E): Phản ánh các tương tác xuyên vùng như khoảng cách địa lý, lưu lượng di biến động dân cư và phân cấp hành chính.



Hình 1.2 Cấu trúc tầng kết nối đầy đủ trong kiến trúc GNN [6]

Thêm vào đó, việc ứng dụng các mô hình biến thể tiên tiến như Graph Attention Networks (GAT) và Sheaf Attention Networks (SheafAT) giúp đồng hóa đồng thời đặc trưng nội tại và tương quan không gian đa chiều. Cơ chế này định lượng hóa cường độ

ảnh hưởng từ vùng phụ cận, mô hình hóa chính xác các quan hệ phi tuyến tính và động lực lan truyền của virus Dengue.

1.4.2. Mục tiêu nghiên cứu

Nghiên cứu hướng tới thiết lập quy trình xử lý dữ liệu tích hợp (End-to-end Pipeline) và thực nghiệm mô hình Temporal-GAT nhằm dự báo chính xác động lực lây lan dịch bệnh, hỗ trợ trực quan hóa ra quyết định y tế. Ba nhiệm vụ trọng tâm bao gồm

Hợp nhất và chuẩn hóa cơ sở dữ liệu đa nguồn: Đồng bộ hóa dữ liệu dịch tễ, môi trường và nhân khẩu học tại 5.564 đô thị Brazil (giai đoạn 2010–2024) để tạo tập dữ liệu sạch, có độ phân giải không gian - thời gian cao.

Đánh giá đối soát các kiến trúc học sâu trên đồ thị: Huấn luyện và so sánh hiệu năng các kiến trúc tiên tiến (GNN, GAT và các biến thể Spatio-temporal) để xác lập mô hình tối ưu trong việc nắm bắt đặc trưng phi tuyến tính và sự lan truyền dịch bệnh.

Xây dựng hệ thống dự báo trực quan: Phát triển bảng điều khiển (**Dashboard**) tích hợp bản đồ số và biểu đồ nhiệt để mô phỏng biến thiên dịch bệnh theo thời gian thực, giúp nhận diện sớm các vùng nguy cơ.

1.4.3. Đối tượng và phạm vi nghiên cứu

1.4.3.1. Đối tượng nghiên cứu

Nghiên cứu tập trung vào cơ chế lan truyền dịch tễ của bệnh sốt xuất huyết thông qua việc xây dựng mô hình mạng nơ-ron đồ thị tích hợp yếu tố không gian - thời gian. Trọng tâm phân tích bao gồm các biến số khí tượng (nhiệt độ, lượng mưa, độ ẩm), đặc điểm nhân khẩu học và cấu trúc sinh thái quần xã. Đề tài đi sâu vào việc thiết lập các cấu trúc hình học phi Euclid để mô hình hóa mối quan hệ tương quan phức tạp giữa các đơn vị hành chính.

1.4.3.2. Phạm vi nghiên cứu

Phạm vi không gian: Triển khai trên toàn lãnh thổ Brazil với dữ liệu chi tiết tại 5.564 đô thị, được định danh qua mã địa lý (geocode và Id) duy nhất.

Phạm vi thời gian: Dữ liệu thực nghiệm kéo dài từ năm 2010 đến năm 2024, phân tích theo đơn vị tuần dịch tễ (epiweek) để đảm bảo độ phân giải cho giám sát y tế.

Dữ liệu huấn luyện: Phân chia nghiêm ngặt theo tiến trình thời gian: Huấn luyện (2010–2020), Kiểm định (2021–2022) và Kiểm thử (2023–2024) nhằm tránh hiện tượng rò rỉ dữ liệu.

Nội dung kỹ thuật: Tập trung xây dựng hệ thống pipeline từ tiền xử lý dữ liệu Mosqlimate, huấn luyện kiến trúc ST-GAT đến phát triển bảng điều khiển trực quan hóa hỗ trợ ra quyết định

1.5. Đóng góp

Nghiên cứu hi vọng mang lại những đóng góp quan trọng cả về mặt lý thuyết phương pháp luận và giá trị thực tiễn trong công tác quản lý dịch tễ học hiện đại:

1.5.1. Về mặt khoa học

Ứng dụng thực nghiệm các cấu trúc học sâu tiên tiến: Nghiên cứu chứng minh tính ưu việt của kiến trúc Spatio-Temporal Graph Attention Networks (ST-GAT) trong việc mô hình hóa các tương tác phi tuyến tính phức tạp. Kết quả này mở ra hướng xử lý dữ liệu dịch tễ học không đồng nhất, vượt xa khả năng của các mô hình thống kê truyền thống.

Tối ưu hóa khả năng biểu diễn dữ liệu đa chiều: Thiết lập khung phương pháp luận trích xuất đặc trưng ẩn từ dữ liệu thô và nhiễu (Mosqlimate), tạo tiêu chuẩn mới trong dự báo biến động dịch bệnh trên quy mô lớn 5.564 đơn vị hành chính

1.5.2. Về mặt thực tiễn

Hệ thống hỗ trợ ra quyết định (Decision Support System): Cung cấp công cụ dự báo theo tuần dịch tễ (epiweek), giúp cơ quan y tế chuyển từ ứng phó thụ động sang chủ động ngăn chặn thông qua việc nhận diện sớm các điểm nóng.

Trực quan hóa và hỗ trợ ra quyết định lâm sàng: Chuyển hóa các thuật toán học sâu phức tạp thành giao diện bảng điều khiển (dashboard) trực quan, hỗ trợ cán bộ y tế xây dựng chiến lược khoanh vùng và xử lý vector hiệu quả.

Khả năng chuyển giao và kế thừa: Quy trình thực nghiệm tại Brazil tạo khung tham chiếu có khả năng áp dụng cho các quốc gia nhiệt đới có đặc điểm dịch tễ tương đồng, tiêu biểu là khu vực phía Nam hoặc toàn bộ Việt Nam.

Chương 2. Cơ sở lý thuyết

2.1. Graph Neural Networks cho dữ liệu không gian

2.1.1. Khung lý thuyết và Biểu diễn cấu trúc đồ thị

Trong bối cảnh phân tích dịch tễ học không gian, các thực thể địa lý không tồn tại độc lập mà có sự tương tác chặt chẽ với nhau. Các thực thể này được mô hình hóa dưới dạng một đồ thị $G=(V, E)$, trong đó:

1. V là tập hợp các nút (Nodes), đại diện cho các đơn vị hành chính. Mỗi nút $v_i \in V$ được liên kết với một đặc trưng h_i (ví dụ: số ca nhiễm, mật độ dân cư)
2. E là tập hợp các cạnh (Edges), biểu diễn mối quan hệ tiếp giáp hoặc sự kết nối hạ tầng giữa các đơn vị này.

Sức mạnh cốt lõi của Graph Neural Networks như được định nghĩa sơ khởi bởi Scarselli et al. (2008) [7], nằm ở khả năng xử lý dữ liệu trong không gian phi Euclid (non-Euclidean). Khác với các mạng nơ-ron truyền thống (CNN, RNN) vốn yêu cầu dữ liệu có cấu trúc lưới ổn định, GNN cho phép học các biểu diễn đặc trưng từ các cấu trúc hình học phức tạp và biến đổi, nơi khoảng cách và sự kết nối giữa các thực thể không tuân theo quy tắc hình học phẳng thông thường.

2.1.2. Cơ chế nắm bắt sự phụ thuộc không gian

GNN nắm bắt sự phụ thuộc không gian thông qua cơ chế truyền tin (Message Passing). Trong đó, trạng thái của một nút được cập nhật liên tục bằng cách tổng hợp thông tin từ các nút lân cận thông qua cấu trúc cạnh E [8]. Cụ thể, đặc trưng của nút

v_i tại lớp $l + 1$ được biểu diễn qua hàm số: $h_i^{(l+1)} = \sigma \left(\sum_{j \in N(i)} \frac{1}{c_{ij}} h_j^{(l)} W^{(l)} \right)$

Trong đó, $N(i)$ là tập hợp lân cận của nút i , W là ma trận trọng số cần học, và là hàm kích hoạt phi tuyến tính. Cơ chế này cho phép mô hình tích hợp đồng thời cả Node features và Edge structure, từ đó, mô hình hóa động lực lan truyền không gian (spatial diffusion dynamics) của dịch bệnh, cho phép nắm bắt các tương tác phi tuyến tính giữa tâm dịch và các vùng phụ cận.

2.2. Graph Convolutional Networks và cơ chế tổng hợp lân cận

2.2.1. Cơ chế vận hành và Phép toán tích chập trên đồ thị

Kế thừa nền tảng từ GNNs, Graph Convolutional Networks (GCN) cụ thể hóa việc khai thác thông tin không gian thông qua phép tích chập bậc một (First-order approximation) trên miền phổ của đồ thị. Theo Kipf & Welling (2017) [8], trong nghiên cứu phân loại bán giám sát (Semi-supervised Classification), cơ chế cốt lõi của GCN là quá trình lan truyền đặc trưng dựa trên cấu trúc liên kết của các nút lân cận. Cụ thể, trạng thái của nút i tại lớp $l+1$ được cập nhật thông qua hàm hội tụ trọng số:

$$h_i^{(l+1)} = \sigma \left(\sum_{j \in N(i) \cup \{i\}} \frac{1}{c_{ij}} W^{(l)} h_j^{(l)} \right)$$

Trong đó: $N(i) \cup \{i\}$ biểu thị tập hợp các nút lân cận bao gồm cả chính nó để bảo toàn đặc trưng nội tại. $c_{ij} = \sqrt{d_i d_j}$ là hệ số chuẩn hóa dựa trên bậc của các nút (degrees), giúp ổn định hóa các giá trị gradient trong quá trình huấn luyện mạng học sâu. $W^{(l)}$ là ma trận trọng số khả biến learnable parameter tại lớp l .

2.2.2. Hạn chế về tính linh hoạt cấu trúc

Mặc dù GCN đạt hiệu suất vượt trội trong việc nắm các phụ thuộc không gian tĩnh, mô hình này vẫn tồn tại những hạn chế nhất định về mặt phương pháp luận. Trọng tâm của sự hạn chế nằm ở hệ số chuẩn hóa c_{ij} hoàn toàn phụ thuộc vào cấu trúc đồ thị bậc của đồ thị mà không xét đến giá trị đặc trưng thực tế của dữ liệu tại thời điểm đó. Nói cách khác, GCN coi tất cả nút lân cận cùng bậc và đóng góp một giá trị tương đương vào nút trung tâm. Trong bài báo cáo dịch tễ học, điều này dẫn đến sự thiếu linh hoạt khi mô hình không thể tự động phân biệt được cường độ ảnh hưởng khác nhau giữa các đô thị.

2.3. Graph Attention Networks và cơ chế attention cho mạng lưới dịch tễ

2.3.1. Cơ chế Tự chú ý (Self-attention Mechanism) trên đồ thị

Để khắc phục những hạn chế về trọng số cố định của GCN, Veličković et al. [9] đã đề xuất kiến trúc Graph Attention Networks (GAT). Điểm đột phá của GAT nằm ở việc tích hợp cơ chế tự chú ý, điều này cho phép mô hình gán các trọng số khác nhau cho các nút một cách linh hoạt và thích ứng với đặc trưng dữ liệu giữa các điểm.

Trong bài toán dịch tễ học, cơ chế này mang ý nghĩa thực tiễn quan trọng: khả năng lây lan virus giữa các đơn vị hành chính không chỉ phụ thuộc vào khoảng cách địa lý hay sự tiếp giáp. Chẳng hạn, mức độ ảnh hưởng dịch tễ từ Quận A sang Quận B có thể cao hơn đáng kể so với Quận A sang Quận C dù cho khoảng cách địa lý tương đương, do sự khác biệt về lưu lượng giao thông, mật độ dân cư hoặc các biến số khí hậu.

2.3.2. Công thức hóa trọng số chú ý động

Trọng số chú ý α_{ij} giữa nút i và nút lân cận j được tính toán thông qua một lớp nơ-ron chia sẻ (shared attentional mechanism) [10]:

$$e_{ij} = \text{LeakyReLU}(a^T [Wh_i || Wh_j])$$

$$\alpha_{ij} = \text{softmax}_j(e_{ij}) = \frac{\exp(e_{ij})}{\sum_{k \in N(i)} \exp(e_{ik})}$$

Trong đó $||$ là phép toán nối chuỗi (Concatenation), W là ma trận chuyển đổi đặc trưng và α_{ij} là trọng số chú ý biểu diễn mức độ quan trọng của nút j đối với nút i . Sau đó, trạng thái mới của nút i được tổng hợp bằng cách tính tổng có trọng số các đặc trưng lân cận đã qua biến đổi. $h_i^{(l+1)} = \sigma(\sum_{j \in N(i)} \alpha_{ij} Wh_j^{(l)})$. Việc sử dụng cơ chế đa đầu chú ý (Multi-head Attention) giúp GAT ổn định hơn trong quá trình học và nắm bắt được các tương tác đa chiều từ nhiều góc nhìn khác nhau của dữ liệu dịch tễ, từ đó, nâng cao độ chính xác trong việc dự báo các vùng nguy cơ cao.

2.4. Spatial-Temporal Graph Attention Networks về không gian thời gian

2.4.1. Bản chất tương quan đa chiều trong dịch tễ học

Trong nghiên cứu dịch tễ, dữ liệu sốt xuất huyết mang đặc tính phụ thuộc đa tuyến (multi-dependence). Sự bùng phát dịch bệnh được xác định bởi hai biến số cốt lõi: Sự tương quan không gian thông qua sự di chuyển của vật chủ giữa các đơn vị hành chính lân cận, tương quan thời gian liên quan đến chu kỳ sinh học của muỗi *Aedes aegypti* dưới tác động của lượng mưa, độ ẩm và ngưỡng nhiệt độ tích lũy. Do đó, các mô hình tĩnh truyền thống không có khả năng mô hình hóa các tín hiệu trễ và tính tuần hoàn của dịch bệnh. Kiến trúc ST-GAT được triển khai nhằm thiết lập một khung phân tích hợp nhất, cho phép đồng bộ hóa các đặc trưng không gian động theo trục thời gian.

2.4.2. Kiến trúc tích hợp Không - Thời gian (Hybrid Architecture)

Cấu trúc của ST-GAT được thiết kế dựa trên sự kết hợp giữa các lớp chú ý đồ thị (Graph Attention Layer) và Recurrent Neural Networks (RNN). Khác với các mô hình xếp chồng tuyến tính, kiến trúc này tích hợp trực tiếp toán tử GAT vào cơ chế các cổng kiểm soát (Gate mechanisms) của đơn vị tái phát có cổng (Gated Recurrent Unit - GRU) [9]. Cơ chế cập nhật trạng thái ẩn h_t tại thời điểm t được thực hiện thông qua hệ thống phương trình:

$$\begin{aligned} z_t &= \sigma(W_z \text{GAT}(X_t, G) + U_z h_{t-1} + b_z) \\ r_t &= \sigma(W_r \text{GAT}(X_t, G) + U_r h_{t-1} + b_r) \\ \tilde{h}_t &= \tanh(W_h \text{GAT}(X_t, G) + U_h(r_t \odot h_{t-1}) + b_h) \\ h_t &= (1 - z_t) \odot h_{t-1} + z_t \odot \tilde{h}_t \end{aligned}$$

Trong đó là hàm trích xuất đặc trưng không gian bằng cách tính toán trọng số giữa các nút trên đồ thị G tại thời điểm t . r_t, z_t lần lượt là cổng cập nhật (update gate) và cổng thiết lập lại (reset gate), điều phối lượng thông tin đặc trưng qua từng bước thời gian và h_t Trạng thái ẩn chứa đựng thông tin tích hợp không - thời gian. Cấu trúc này cho phép mô hình đồng thời biểu diễn các biến động địa lý cục bộ và duy trì các phụ thuộc thời gian dài hạn trong dữ liệu dịch tễ.

2.4.1. Ưu thế trong dự báo dịch tễ ngắn hạn

Việc tích hợp cơ chế chú ý vào trục thời gian giúp ST-GAT phản hồi hiệu quả hơn với các biến động phi tuyến tính, chẳng hạn như sự gia tăng đột ngột của các biến số khí tượng. Thay vì cố định trọng số cho tất cả các bước thời gian quá khứ, mô hình tự động tái phân phối các trọng số chú ý để tập trung vào các giai đoạn có sự tương quan cao nhất với thời điểm hiện tại. Đặc điểm này giúp tối ưu hóa độ chính xác dự báo, góp phần giảm sai số MAE và RMSE khi thực hiện kiểm chứng trên các tập dữ liệu thực địa có độ nhiễu cao như Brazil và Việt Nam.

2.5. Sheaf Neural Networks về lý thuyết bó

2.5.1. Cơ sở lý thuyết về Bó tế bào (Cellular Sheaves)

Trong khi các kiến trúc GNN truyền thống biểu diễn đặc trưng tại các nút dưới dạng vector trong không gian Euclidean cố định, mạng thần kinh Bó (Sheaf Neural Networks)

mở rộng khả năng này thông qua lý thuyết Bó tế bào. Theo Bodnar et al. [11], một bó F trên đồ thị G gán cho mỗi nút một không gian vector $F(v)$, gọi là stalk, và cho mỗi cạnh $e = (u, v)$ một không gian vector $F(e)$. Tính chất cốt lõi của SNN nằm ở các ánh xạ hạn chế (Restriction Maps) $\phi_{u \rightarrow e}: F(u) \rightarrow F(e)$, đại diện cho các phép biến đổi tuyến tính thiết lập mối quan hệ cục bộ giữa các thực thể. Khác với GNN thông thường vốn giả định sự tương quan giữa các nút là đồng nhất, SNN cho phép biểu diễn các cấu trúc dữ liệu không đồng nhất thông qua việc điều chỉnh cấu trúc của ánh xạ hạn chế. Điều này đặc biệt có ý nghĩa trong dịch tễ học khi các vùng lân cận có thể diễn biến dịch bệnh đối lập hoặc không đồng bộ do các yếu tố chính sách hoặc địa hình khác biệt.

2.5.2. Giải quyết hiện tượng San phẳng dữ liệu (Oversmoothing)

Một hạn chế điển hình của GCN truyền thống là hiện tượng oversmoothing, dẫn đến sự hội tụ đặc trưng của các nút về một giá trị trung bình chung và làm mất đi tính phân hóa dữ liệu. SNN khắc phục được vấn đề này thông qua cơ chế khuếch tán Bó (Sheaf Diffusion) dựa trên ma trận Laplacian Bó L_F [12], một ma trận khối có kích thước cực lớn chứa đựng các ánh xạ hạn chế: $L_F = D_F - A_F$. Trong đó D_F là ma trận bậc khối và A_F là ma trận kề khối, được xây dựng từ các ánh xạ hạn chế. Khác với Laplacian đồ thị tĩnh L , L_F có khả năng biến đổi linh hoạt cấu trúc dựa trên đặc trưng của dữ liệu đầu vào. Về mặt phổ học (spectral perspective), SNN không chỉ hoạt động như một bộ lọc thông thấp (low-pass filter) mà còn có thể cấu hình như một bộ lọc thông cao (high-pass filter) [12]. Khả năng này ngăn chặn các tín hiệu dịch tễ bị san phẳng, giữ lại những đặc trưng riêng biệt của từng đồ thị ngay cả khi mạng lưới đi sâu vào nhiều lớp xử lý.

2.5.3. Giá trị trong mô hình hóa dịch tễ phức tạp

Trong bài toán dự báo dịch tễ tại Brazil, SNN cho phép tích hợp các nguồn dữ liệu đa chiều, bao gồm biến số khí tượng và số liệu báo cáo dịch tễ tổng hợp vào cấu trúc không gian của các stalk $F(v)$. Thông qua quá trình tối ưu hóa các ánh xạ hạn chế, mô hình có khả năng nhận diện các cơ chế lan truyền không đồng nhất. Cụ thể, SNN mô phỏng hiệu quả sự tương tác giữa các vùng có năng lực đáp ứng y tế và điều kiện hạ tầng khác biệt. Trong khi mô hình GCN truyền thống thường gặp những sai số lớn do giả định tính tương đồng giữa các nút lân cận, SNN sử dụng ánh xạ hạn chế để điều chỉnh trọng số truyền tin, phản ánh đúng thực tế thực nghiệm: sự biến động dữ liệu tại một vùng có hạ tầng ổn định có thể khác hoàn toàn so với một vùng đang có chỉ số lây nhiễm tăng vọt.

Khả năng này giúp mô hình bảo toàn các tín hiệu đặc trưng địa phương, từ đó, tối ưu hóa độ chính xác của dự báo.

2.6. Sheaf-based Positional Encoding

2.6.1. Hạn chế của phương pháp mã hóa tọa độ truyền thống

Trong các kiến trúc học máy trên đồ thị hiện hành, việc biểu diễn vị trí thường phụ thuộc vào tọa độ Cartesian (X Y) hoặc hệ thống vector riêng của ma trận Laplacian đồ thị tĩnh [13]. Tuy nhiên, các phương pháp này chủ yếu phản ánh khoảng cách hình học trong không gian Euclid, chưa mô phỏng được đặc tính cấu trúc liên kết phức tạp của mạng lưới dịch tễ [13]. Trong thực nghiệm dự báo thực tế, các yếu tố phi địa lý - gồm ranh giới hành chính, sự phân hóa về hạ tầng y tế, thường thiết lập các kênh dẫn truyền có tác động lớn hơn so với khoảng cách vật lý thông thường. Việc thiếu hụt cơ chế mã hóa cấu trúc thích nghi dẫn đến hệ quả là mô hình không phân biệt được giữa khoảng cách địa lý và khoảng cách dịch tễ, từ đó làm giảm độ chính xác khi dự báo tại các khu có cấu trúc mạng lưới không đồng nhất.

2.6.2. Bảo toàn cấu trúc Topo thông qua Hình học

Nghiên cứu đề xuất Sheaf-based Positional Encoding nhằm thay thế các kỹ thuật mã hóa tọa độ truyền thống. Thông qua việc tích hợp thông tin vị trí vào các ánh xạ hạn chế của Bó, mô hình thực hiện ánh xạ các nút vào một không gian nhúng có khả năng phản ánh cấu trúc liên kết phân cấp. Cơ chế này cho phép Biểu diễn các rào cản phi địa lý: Các ánh xạ hạn chế được tối ưu hóa để mô phỏng sự suy giảm hoặc biến đổi của các tín hiệu dịch tễ khi truyền tải qua các ranh giới hành chính phức tạp. Giá trị của ma trận khối trong Sheaf Laplacian đóng vai trò là bộ lọc thích nghi đối với dòng dữ liệu giữa các vùng. Mô hình hóa cấu trúc mạng lưới phân cấp: SNN thiết lập các tương tác không đối xứng giữa các đô thị trung tâm và các khu vực vệ tinh. Mã hóa dựa trên Bó cho phép biểu diễn sự ưu tiên và hướng tính trong luồng di cư và lan truyền dịch bệnh.

Việc triển khai Sheaf - based Positional Encoding giúp mô hình trích xuất được các đặc trưng tiềm ẩn, vốn là yếu tố quyết định đến độ chính xác của dự báo trong các hệ thống dịch tễ không đồng nhất.

2.6.3. Tăng cường khả năng biểu diễn thông qua sự kết hợp giữa Sheaf-Encoding và Attention

Việc tích hợp Sheaf-based Positional Encoding giúp tối ưu hóa khả năng phân biệt đặc trưng cấu trúc của mạng nơ-ron đồ thị. Thay vì giả định dữ liệu tồn tại trong không gian Euclid đẳng hướng, mô hình thực hiện biểu diễn mạng lưới dịch tễ dưới dạng một thực thể có cấu trúc liên kết biến đổi [13]. Cơ chế này khi kết hợp với Attention giúp điều chỉnh các trọng số chú ý dựa trên sự tích hợp giữa khoảng cách hình học và độ tương đồng cấu trúc liên kết. Cụ thể, các nút được xác định là lân cận không chỉ dựa trên khoảng cách địa lý mà còn dựa trên cường độ kết nối dựa trên cường độ kết nối được xác định bởi các ánh xạ hạn chế. Bằng cách ưu tiên các luồng dữ liệu có độ tương quan dịch tễ cao, điều này cho phép mô hình tối ưu hóa năng lực dự báo trong các kịch bản lan truyền xuyên vùng tại Brazil.

2.7. Khoảng trống & vị trí nghiên cứu (Gap & Positioning)

2.7.1. Phân tích khoảng trống nghiên cứu

Mặc dù các kiến trúc mạng nơ-ron đồ thị đã chứng minh được hiệu quả trong việc mô hình hóa dữ liệu dịch tễ, các phương pháp tiếp cận truyền thống như GNN, GCN vẫn tồn tại hai thách thức kỹ thuật chưa được tối ưu: Tính bất đối xứng trong tương tác không gian: Các mô hình hiện hành chủ yếu giả định tương tác giữa các nút là đối xứng hoặc phụ thuộc vào trọng số chú ý không hướng. Trong thực tiễn dịch tễ, sự di chuyển dân cư từ một tâm dịch về một vùng chưa có dịch mang tính chất định hướng và bất đối xứng rõ rệt. GNN truyền thống thiếu đi cơ chế toán học đủ mạnh để mô tả sự lệch pha và hướng lan truyền phức tạp. Tính nhạy cảm với nhiễu và hiện tượng oversmoothing: Dữ liệu dịch tễ học tại các quốc gia đang phát triển như Brazil thường tồn tại nhiều nhiễu hệ thống do độ trễ trong báo cáo ca bệnh. Việc tăng độ sâu của mạng GNN để khai thác các phụ thuộc dài hạn dẫn đến hiện tượng đồng hóa các đặc, làm mất đi tín hiệu cảnh báo sớm tại các địa phương có biến động đột biến

2.7.2. Định vị nghiên cứu

Nghiên cứu này định vị là một bước đi tiên phong trong việc chuyển đổi từ Đồ thị phẳng (Flat Graphs) sang đồ thị Bó (Sheaf-based Graphs) trong dự báo dịch tễ học:

1. Phương pháp luận: Đề tài sử dụng Sheaf Neural Networks để tận dụng các ánh xạ hạn chế. Đây là một công cụ toán học cho phép mô hình hóa sự lan truyền không đồng nhất và bất đối xứng. Thay vì bắt các nút hội tụ về một trạng thái chung, SNN cho phép bảo toàn các đặc trưng riêng biệt của từng đô thị, đồng thời mô phỏng các rào cản dịch tễ một cách linh hoạt thông qua các stalks.
2. Tính ứng dụng: Bằng việc kết hợp Neural Sheaf với cơ chế Attention và Mã hóa vị trí Topo, nghiên cứu thiết lập một khung dự báo có khả năng chống nhiễu cao và phản ánh trung thực động lực học của virus Dengue trên quy mô lớn.

2.8. Định nghĩa toán học về bài toán dự báo

Nghiên cứu mô hình hóa bài toán dưới dạng bài toán hồi quy trên đồ thị không - thời gian. Giả sử, mạng lưới đô thị được biểu diễn dưới dạng $G = (V, E, A)$, trong đó, V là tập hợp N nút, E là các cạnh liên kết, $A \in R^{N \times N}$ là ma trận kề biểu diễn cấu trúc kết nối không gian. Tại mỗi thời điểm t , trạng thái hệ thống được mô tả bởi ma trận đặc trưng $X_t \in R^{N \times D}$, với D là số lượng biến đầu vào, bao gồm dữ liệu dịch tễ, khí tượng và đặc trưng nhân khẩu học. Mục tiêu là xác định hàm ánh xạ $f(\cdot)$ nhằm dự báo vector trạng thái dịch tễ trong tương lai y_{t+1} (số ca nhiễm tại $t+1$) dựa trên chuỗi quan sát lịch sử trong cửa sổ thời gian k : $\widehat{y_{(t+1)}} = f(G; (X_{t-k}, \dots, X_t))$. Trong đó $(X_{t-k}, \dots, X_t)$ là các quan sát quá khứ dùng để nắm bắt động lực học thời gian. G cung cấp cấu trúc kết nối không gian để mô hình hóa sự lây lan. Trong kiến trúc SNN, G được mở rộng thành một Bó tế bào F với các ánh xạ hạn chế khả biến và y_{t+1} là vector dự báo số ca nhiễm tại thời điểm $t+1$. Quá trình tối ưu hóa mô hình được thực hiện thông qua việc cực tiểu hóa hàm mất mát (Loss function) L , cụ thể, sai số bình phương trung bình MSE:

$$L = \frac{1}{N} \sum_{i=1}^N (y_{i,t+1} - \widehat{y_{i,t+1}})^2$$

Chương 3. Nguồn dữ liệu và phương pháp xây dựng

3.1. Xây dựng đồ thị từ dữ liệu đa nguồn

3.1.1. Tổng quan & định vị đa nguồn dữ liệu (Overview & Positioning)

Trong bài toán dự báo bệnh sốt xuất huyết (Dengue) theo không gian – thời gian, yêu cầu đáp ứng dữ liệu phản ánh chi tiết số ca bệnh theo tuần mà còn mô tả bối cảnh tương

quan giữa điều kiện khí hậu, dân số, môi trường, liên kết địa lý và cấp đơn vị hành chính để mô hình học được cơ chế lan truyền và tính mùa vụ. Vì thế trong nghiên cứu này, kế thừa trực tiếp bộ dữ liệu từ dự án bộ dữ liệu của Mosqlimate Project phục vụ Infodengue–Mosqlimate Sprint/Dengue Challenge được công bố chính thức trên Zenodo với DOI 10.5281/zenodo.13328231 và giấy phép mở Creative Commons Attribution 4.0 (CC BY 4.0) nhằm thiết lập một nền tảng nghiên cứu thực nghiệm đầy đủ để các nhà nghiên cứu có thể xây dựng – so sánh – tái lập các mô hình dự báo dengue ở Brazil [14] [15].

3.1.1.1. Dữ liệu số ca bệnh sốt xuất huyết – Dengue cases

Nguồn dữ liệu dịch tễ trong nghiên cứu này được kế thừa từ hệ sinh thái Mosqlimate, cung cấp chuỗi quan sát dengue đã được tổ chức theo không gian–thời gian ở cấp đơn vị hành chính địa phương (geocode) và theo tuần dịch tễ (epiweek) tại Brazil [14]. Dữ liệu bao phủ giai đoạn 2010–2024, phù hợp với yêu cầu mô hình hóa diễn biến theo mùa vụ và lan truyền liên vùng trong bài toán dự báo dịch theo tuần.

Do dữ liệu gốc có quy mô lớn và được thiết kế để phục vụ nhiều mục đích phân tích dịch tễ (bao gồm nhiều trường mô tả và các cờ/mặt nạ phục vụ các kịch bản khác nhau), nghiên cứu này áp dụng chiến lược tiền xử lý nhằm tối ưu hóa việc nạp và quản lý dữ liệu cho pipeline học máy. Cụ thể, tập dữ liệu dengue được tách theo từng năm thành các tệp độc lập (ví dụ: Dengue_2010.csv, Dengue_2011.csv, ..., Dengue_2024.csv) với quy tắc đặt tên thống nhất để thuận tiện cho thao tác đọc theo lô và tái lập quy trình. Việc tách tệp không làm thay đổi cấu trúc dữ liệu cốt lõi và vẫn bảo toàn tính nhất quán giữa các năm. Từ cấu trúc gốc, nghiên cứu chỉ trích xuất các trường tối thiểu nhưng đủ để xây dựng chuỗi quan sát theo tuần ở cấp node, gồm:

- **Geocode:** mã địa phương (định danh node).
- **Year:** năm dịch tễ (phục vụ quản trị thời gian và chia tập theo trục thời gian).
- **Epiweek:** tuần dịch tễ (đơn vị thời gian chuẩn hóa theo tuần).
- **Casos:** số ca mắc mới trong tuần (biến mục tiêu ở miền thực trước khi biến đổi).

Cách chọn lọc này giúp giữ lại đúng nền tảng của bài toán dự báo: mỗi điểm dữ liệu tương ứng (geocode, epiweek), cho phép ánh xạ trực tiếp vào mô hình đồ thị theo tuần (weekly snapshots) và giảm nhiễu do các trường không dùng trong huấn luyện. Nhờ đó,

pipeline xử lý trở nên nhẹ hơn, dễ tái lập hơn, đồng thời vẫn bảo đảm mô hình được học trên thông tin dịch tễ cốt lõi của từng địa phương theo thời gian [14].

Bảng 3.1: Trích chọn 10 dòng từ tệp dengue_2024.csv

date	year	epiweek	casos	geocode	regional	regional_geocode	macroregional	macroregional_geocode	uf
01/07/2024	2024	2	0	1718006	Sudeste	17003	Centro-Sul	1702	TO
01/07/2024	2024	2	0	1705557	Sudeste	17003	Centro-Sul	1702	TO
01/07/2024	2024	2	0	3516002	Adamantina	35091	RRAS10	3533	SP
01/07/2024	2024	2	90	3506003	Bauru	35062	RRAS9	3518	SP
01/07/2024	2024	2	17	3549102	Mantiqueira	35142	RRAS15	3528	SP
01/07/2024	2024	2	15	3513009	Mananciais	35013	RRAS4	3523	SP
01/07/2024	2024	2	46	3533908	Norte - Barretos	35051	RRAS13	3530	SP
01/07/2024	2024	2	4	3522703	Centro Oeste do DRS III	35032	RRAS13	3530	SP
01/07/2024	2024	2	0	3543006	Itapeva	35162	RRAS8	3519	SP
01/07/2024	2024	2	0	3539103	Rota dos Bandeirantes	35014	RRAS5	3522	SP

3.1.1.2. Dữ liệu khí hậu – Climate

Bên cạnh dữ liệu dịch tễ, nghiên cứu này tiếp tục sử dụng nguồn dữ liệu khí tượng thuộc hệ sinh thái Mosqlimate [14], nhằm mô tả các điều kiện môi trường có liên quan chặt chẽ đến cơ chế phát triển véc-tơ và tính mùa vụ của sốt xuất huyết. Bộ dữ liệu khí hậu bao phủ giai đoạn 2010–2024, cung cấp chuỗi quan sát theo không gian (đơn vị địa phương geocode) và theo thời gian, hỗ trợ mô hình học được quan hệ giữa biến động thời tiết và biến động ca bệnh. Về tổ chức dữ liệu, tệp khí hậu gốc được công bố ở độ phân giải hằng ngày (daily time series). Để thuận tiện cho quy trình tiền xử lý và đồng bộ với pipeline dữ liệu theo năm của nghiên cứu, dữ liệu khí hậu được tách thành các tệp con theo năm với quy ước đặt tên thống nhất dạng climate_<year>.csv (ví dụ:

Climate_2010.csv ... Climate_2024.csv). Mỗi tệp con vẫn bảo toàn cấu trúc schema gốc và các trường khí tượng chính, bao gồm thông tin thời gian (date, epiweek, year), định danh không gian (geocode) và các nhóm biến đo lường như nhiệt độ (min/median/max), lượng mưa (min/median/max/tổng), áp suất khí quyển (min/median/max), độ ẩm tương đối (min/median/max), biên độ nhiệt (thermal_range) và số ngày mưa (rainy_days).

Trong phạm vi thực nghiệm của nghiên cứu, nhằm giảm chiều dữ liệu và đảm bảo tính ổn định khi ghép nối theo tuần–địa phương, tập biến khí hậu được rút gọn về các trường cốt lõi sau:

- **Geocode:** mã địa phương (7 ký tự)
- **Year:** năm
- **Epiweek:** tuần dịch tễ
- **Temp_med:** nhiệt độ trung bình theo tuần
- **Precip_tot:** tổng lượng mưa theo tuần
- **Rainy_days:** số ngày mưa trong tuần
- **Rel_humid_med:** độ ẩm tương đối trung bình theo tuần

Các biến được lựa chọn này đại diện cho các thành phần khí hậu quan trọng, đồng thời phù hợp với cách biểu diễn dữ liệu theo snapshot tuần trong đồ thị, giúp giảm nhiễu do dư thừa cột và tối ưu chi phí tính toán mà vẫn giữ được thông tin cần thiết cho bài toán dự báo [14].

Bảng 3.2: Trích chọn 10 dòng từ tệp Climate_2024.csv

date	e pi we ek	ge oc od e	tem p_ min	tem p_ me d	tem p_ ma x	prec ip_ min	prec ip_ med	prec ip_ max	prec ip_ _tot	press ure_ min	press ure_ med	press ure_ max	rel_h umid _min	rel_h umid _med	rel_h umid _max	ther mal_ range	rain y_d ays	y e ar
01/07/2024	2024	110005	23.0759	25.6121	29.1807		0.3177	1.847	2.5416	0.9953	0.9978	1.0001	68.4249	84.705	95.5749	6.1047	7	2024
01/07/2024	2024	1100023	23.485	25.9554	29.2657	0.002	0.7243	2.3891	5.7948	0.9952	0.9977	1.0001	70.8236	85.564	94.9045	5.7806	7	2024
01/07/2024	2024	1100031	23.1783	26.0618	30.1486	0.0173	0.1702	0.5646	1.3618	0.9948	0.9973	0.9995	63.9454	82.162	93.3611	6.9703	7	2024

01/0	20	11	23.		29.													2
7/20	24	04	486	25.	501	0.00	0.34	1.38	2.7	0.99	0.99	1.00	70.09	86.11	94.81	6.015		0
24	02	9	9	87	9	04	34	54	474	53	78	01	2	16	14	1	7	4
01/0	20	11	23.	26.	30.													2
7/20	24	05	312	052	103	0.00	0.16	0.67	1.3	0.99	0.99	0.99	64.05	82.22	93.49	6.791		0
24	02	6	3	4	6	45	98	16	587	48	73	96	61	22	45	3	7	4
01/0	20	11	23.		29.													2
7/20	24	06	093	25.	566	0.00	0.18	0.89	1.4	0.99	0.99	0.99	65.73	82.77	92.86	6.473		0
24	02	4	2	633	8	14	39	95	714	51	76	98	54	01	25	6	7	4
01/0	20	11	23.	25.	29.													2
7/20	24	07	098	589	292	0.00	0.31	1.83	2.4	0.99	0.99	0.99	66.70	83.55	93.87	6.194		0
24	02	2	1	1	3	14	13	97	905	52	76	99	74	88	28	2	7	4
01/0	20	11	24.		30.													2
7/20	24	08	781	27.	753	0.00	0.30	1.79	2.4	0.99	0.99	0.99	64.33	80.23	89.88	5.972		0
24	02	0	4	215	5	01	62	53	5	43	68	91	54	63	44	1	6	4
01/0	20	11	23.	25.	29.													2
7/20	24	09	351	739	361	0.00	0.23	0.92	1.9	0.99	0.99	1.00	70.12	86.21	94.73	6.009		0
24	02	8	9	8	5	07	83	91	066	53	79	01	88	48	76	6	7	4

3.1.1.3. Dữ liệu dân số – Population

Nghiên cứu sử dụng dữ liệu dân số thuộc hệ sinh thái Mosqlimate, trong đó nguồn thống kê dân số được tổng hợp từ Viện Địa lý và Thống kê Brazil (IBGE) [14]. Tập dữ liệu gốc IBGE_POPTCU.csv cung cấp thông tin dân số theo đơn vị địa phương và theo năm bắt đầu từ 1992, với các trường chính gồm:

- **MUNIC_RES:** mã địa phương tương đồng giá trị trường geocode (7 ký tự).
- **ANO:** Năm quan sát rộng từ năm 1992 đến 2024 tương tự trường year.
- **POPULACAO:** Dữ liệu dân số cho từng địa phương được công bố chính thức.

Để đảm bảo tính nhất quán khi ghép nối với dữ liệu dịch tễ và khí hậu trong bài toán dự báo theo tuần, nghiên cứu giới hạn khoảng thời gian sử dụng dân số trong giai đoạn 2010–2024 nhằm đồng bộ với khung thời gian của các snapshot đô thị. Đối với các năm không có số liệu dân số được công bố trực tiếp trong tập dữ liệu sử dụng nghiên cứu áp dụng chiến lược bù khuyết nội suy theo năm lân cận gần nhất (nearest-year imputation), tức gán giá trị dân số của năm gần nhất sẵn có cho năm thiếu tương ứng. Cách xử lý này được lựa chọn để duy trì tính liên tục của chuỗi thời gian và tránh tạo ra trung bình không phản ánh quan sát thống kê thực tế, đồng thời giảm nguy cơ làm sai lệch xu hướng lịch sử khi đưa dân số vào như một đặc trưng nền cho mô hình học máy.

Bảng 3.3: Trích chọn 10 dòng từ tệp IBGE_POPTCU.csv

MUNIC_RES	ANO	POPULACAO
1100015	2010	24422
1100023	2010	90354
1100031	2010	6309
1100049	2010	78601
1100056	2010	17030
1100064	2010	18602
1100072	2010	8802
1100080	2010	13700
1100098	2010	28741

3.1.1.4. Dữ liệu sinh thái quần xã – Biome

Mô hình có thể học được sự khác biệt nền giữa các vùng (ví dụ điều kiện sinh thái – địa hình – kiểu khí hậu dài hạn), nghiên cứu sử dụng nhóm dữ liệu môi trường sinh thái trong hệ sinh thái Mosqlimate. Nhóm dữ liệu này gắn thuộc tính bối cảnh cố định theo địa phương (theo mã geocode), nhằm phản ánh sự đa dạng sinh học và đặc trưng tự nhiên khác biệt giữa các khu vực tại Brazil. Các biến môi trường được chuẩn hóa ở cấp địa phương và có vai trò như biến nền tĩnh (static contextual covariates) hỗ trợ giải thích sự khác biệt rủi ro dịch tễ theo vùng, độc lập với biến động theo tuần của khí hậu và số ca bệnh.

- **Geocode:** mã địa phương (7 ký tự).
- **Name_muni:** tên địa phương.
- **Biome:** môi trường quần xã sinh thái đặc thù bao gồm: Amazonia, Cerrado, Caatinga, Mata Atlântica, Pampa, Pantanal.
- **Altitude:** độ cao so với mực nước biển.
- **Koppen:** ký hiệu loại khí hậu.

Bảng 3.3: Trích chọn 10 dòng từ tệp environ_vars.csv

geocode	name_muni	biome	altitude	koppen
1100015	ALTA FLORESTA D'OESTE	amazonia	246.08	Am
1100023	ARIQUEMES	amazonia	165.9	Am

1100031	CABIXI	amazonia	224.18	Am
1100049	CACOAL	amazonia	229.95	Am
1100056	CEREJEIRAS	amazonia	192.22	Am
1100064	COLORADO DO OESTE	amazonia	359.62	Am
1100072	CORUMBIARA	amazonia	266.89	Am
1100080	COSTA MARQUES	amazonia	190.01	Am
1100098	ESPIGÇO D'OESTE	amazonia	296.94	Am

3.1.1.5. Bản đồ và liên kết hành chính

Nhằm xây dựng mạng lưới liên kết không gian làm nền cho việc tạo cạnh (edges) và đồng thời đảm bảo khả năng ánh xạ sang bản đồ hành chính, nghiên cứu sử dụng bộ dữ liệu liên kết hành chính trong hệ sinh thái Mosqlimate, được tổng hợp từ các nguồn thống kê – địa lý chính quy tại Brazil (IBGE) [14]. Nhóm dữ liệu này đóng vai trò quan trọng vì cung cấp một khung tham chiếu thống nhất theo mã địa phương (geocode), cho phép mô hình hóa mối liên hệ giữa các đơn vị hành chính theo cấu trúc vùng và/hoặc quan hệ phân cấp:

- **Geocode:** mã địa phương (7 ký tự).
- **UF:** Ký hiệu bang.
- **Name_muni:** tên địa phương.
- **Hierarquia:** bậc địa phương.

Tập tin gốc regic2018.csv (phiên bản đầu vào ban đầu) bao gồm các thông tin cốt lõi như geocode, UF, name_muni, và hierarquia. Tuy nhiên, trong quá trình tiền xử lý, dữ liệu được ghi theo định dạng dính trường (các thuộc tính ghép chung trong một chuỗi), gây khó khăn cho thao tác trích xuất, kiểm tra tính nhất quán và ghép nối với các nguồn dữ liệu khác. Vì vậy, nghiên cứu tiến hành chuẩn hóa cấu trúc bảng bằng cách tách các thành phần thành từng cột riêng biệt theo đúng ngữ nghĩa trường dữ liệu (ví dụ tách riêng mã địa phương, bang, tên địa phương và bậc/phân cấp). Bước chuẩn hóa này giúp dữ liệu dễ quản lý hơn, giảm rủi ro lỗi khi join theo khóa.

- **Id:** tương tự giá trị như trường geocode bao gồm 7 ký tự.
- **Name:** tên địa phương.

- **Description:** mô tả địa phương thường trùng với name dùng để thể hiện tương tác
- **Geometry:** đa giác biểu diễn vùng và ranh giới thành phố chuẩn tọa độ WGS84 (EPSG:4326).

Bảng 3.4: Trích chọn 10 dòng từ tệp regic2018.csv

geocode;UF;name_muni;hierarquia
3550308;SP;Arranjo Populacional de São Paulo/SP;Grande Metrópole Nacional
3304557;RJ;Arranjo Populacional do Rio de Janeiro/RJ;Metrópole Nacional
5300108;DF;Arranjo Populacional de Brasília/DF;Metrópole Nacional
3106200;MG;Arranjo Populacional de Belo Horizonte/MG;Metrópole
4314902;RS;Arranjo Populacional de Porto Alegre/RS;Metrópole
4106902;PR;Arranjo Populacional de Curitiba/PR;Metrópole
3509502;SP;Arranjo Populacional de Campinas/SP;Metrópole
2927408;BA;Arranjo Populacional de Salvador/BA;Metrópole
2611606;PE;Arranjo Populacional do Recife/PE;Metrópole

Sau khi tách thành từng trường riêng biệt thành bảng 3.5

Bảng 3.5: Trích chọn 10 dòng từ tệp regic2018_clean.csv

geocode	name_muni	biome	altitude	koppen
1100015	ALTA FLORESTA D'OESTE	amazonia	246.08	Am
1100023	ARIQUEMES	amazonia	165.9	Am
1100031	CABIXI	amazonia	224.18	Am
1100049	CACOAL	amazonia	229.95	Am
1100056	CEREJEIRAS	amazonia	192.22	Am
1100064	COLORADO DO OESTE	amazonia	359.62	Am
1100072	CORUMBIARA	amazonia	266.89	Am
1100080	COSTA MARQUES	amazonia	190.01	Am
1100098	ESPIGÇO D'OESTE	amazonia	296.94	Am

Để mô tả đặc trưng không gian của các đơn vị hành chính cấp thành phố tại Brazil và phục vụ trực quan hóa theo vùng ranh giới, nghiên cứu sử dụng tệp geojis-100-mun.json

dưới dạng GeoJSON. Đây là dữ liệu biên giới hành chính được công bố/chuyển đổi từ nguồn địa lý–thống kê chính quy của Brazil (IBGE) [14]. Tập GeoJSON này đóng vai trò nguồn hỗ trợ quan trọng nhằm liên kết geocode với hình học đa giác tương ứng, kiểm chứng tính hợp lệ của chỉ số nút theo không gian, và hỗ trợ xuất bản đồ/đồ thị kết quả theo địa lý.



Hình 3.1: Geojs-100-mun.json – bản đồ Brazil cấp thành phố

3.1.2. Định nghĩa khởi tạo Nút – Node

Trong nghiên cứu này, nút (node) được định nghĩa là một đơn vị hành chính cấp thành phố (municipality) tại Brazil, đóng vai trò điểm neo để hợp nhất đa nguồn dữ liệu theo cùng một khóa định danh. Mỗi nút tương ứng với một mã địa phương geocode gồm 7 ký tự, được sử dụng xuyên suốt để liên kết dữ liệu dịch tễ (số ca theo tuần), dữ liệu khí hậu, dữ liệu dân số, dữ liệu môi trường sinh thái và lớp bản đồ hành chính.

3.1.2.1. Nguồn hình thành tập nút và quy tắc định danh

Tập nút V được hình thành trực tiếp từ lớp ranh giới hành chính cấp municipality trong tập geojs-100-mun.json, trong đó mỗi thực thể địa lý (feature) tương ứng một địa phương. Trường định danh id của GeoJSON được chuẩn hóa về chuỗi 7 ký tự (zero-padding nếu cần) để đồng nhất với geocode trong các bảng dữ liệu còn lại. Khi đó, tập nút được ký hiệu:

$$V = \{v_i\}_{i=0}^{N-1}, N = 5564,$$

Với mỗi nút v_i gắn với duy nhất một mã định danh g_i (geocode).

3.1.2.2. Ánh xạ chỉ số nút và tính nhất quán toàn pipeline

Để bảo toàn tính nhất quán chỉ số nút từ tiền xử lý đến huấn luyện, đánh giá và trực quan hóa (điểm thường gây sai lệch nếu bị trượt index), nghiên cứu xây dựng ánh xạ chỉ mục cố định: $\phi: g_i \mapsto i, i \in \{0, 1, \dots, N - 1\}$, và lưu dưới dạng node2idx.json (geocode $\rightarrow$ index). Đồng thời tạo ánh xạ ngược: $\phi^{-1}: i \mapsto g_i$, lưu trong idx2node.json (index $\rightarrow$ geocode) để phục vụ truy hồi địa phương khi phân tích lỗi theo tuần/khu vực, và xuất kết quả dự báo theo geocode ở các bước trực quan hóa/báo cáo.

3.1.2.3. Thuộc tính hình học nút và vai trò trong liên kết không gian

Mỗi nút v_i mang theo thông tin ranh giới hành chính dưới dạng polygon/multipolygon từ cột geometry. Tuy nhiên, hình học không được đưa trực tiếp vào vector đặc trưng đầu vào để tránh mã hóa vị trí thô gây khó diễn giải/khó tổng quát, thay vào đó, hình học chỉ dùng cho:

- Xây dựng quan hệ kề cận hành chính (queen contiguity) khi tạo cạnh,
- Tính centroid để xử lý nút cô lập bằng KNN,
- Trực quan hóa không gian (bản đồ).

Ký hiệu: $\text{Geometry}(v_i) = P_i, \text{Centroid}(v_i) = c_i \in \mathbb{R}^2$.

3.1.2.4. Điều kiện hợp lệ của node đối với GNN và xử lý nút cô lập

Trong cơ chế message passing của GNN, một nút có bậc bằng 0 sẽ không nhận thông tin từ lân cận, làm giảm khả năng học quan hệ không gian và gây bất ổn khi huấn luyện.

Vì vậy nghiên cứu đặt ra các ràng buộc hợp lệ:

1. Mỗi geocode xuất hiện đúng một lần trong node2idx.json.
2. Chỉ số node không thay đổi theo thời gian; các snapshot theo tuần chỉ thay đổi đặc trưng/nhãn, không thay đổi tập V .
3. Các nút cô lập sẽ được xử lý ở bước khởi tạo cạnh bằng cơ chế bổ sung liên kết dựa trên centroid (KNN) nhằm tăng liên thông và đảm bảo message passing hoạt động ổn định.

3.1.2.5. Biểu diễn đồ thị theo tuần với tập nút cố định

Dữ liệu được tổ chức thành chuỗi đồ thị theo tuần (weekly snapshots). Mỗi tuần t tương ứng một đồ thị: $G_t = (V, E)$, trong đó V cố định với $N = 5564$ nodes cho mọi t , còn E là tập cạnh không gian và phân thay đổi theo tuần nằm ở ma trận đặc trưng X_t và nhãn y_t sau khi đã đồng bộ theo ánh xạ ϕ .

3.1.3. Định nghĩa khởi tạo Cạnh – Edge

3.1.3.1. Định nghĩa đồ thị không gian

Tại mỗi thời điểm tuần dịch tễ t , nghiên cứu mô hình hóa không gian hành chính Brazil dưới dạng một đồ thị $G_t = (V, E)$, trong đó V là tập nút cố định theo không gian (municipality) và E là tập cạnh biểu diễn quan hệ lân cận không gian. Vì cấu trúc hành chính không đổi theo tuần, ta sử dụng một tập cạnh không đổi cho mọi t , tức là: $G_t = (V, E), \forall t$. Mỗi nút $v_i \in V$ tương ứng một municipality định danh bởi geocode; geocode được ánh xạ sang chỉ số số nguyên qua hàm: $\phi: \text{geocode} \rightarrow \{0, 1, \dots, N - 1\}$, với $N = |V|$. Tập cạnh E được xây dựng trên không gian geocode và sau đó chuyển về chỉ số $(\phi(u), \phi(v))$ để dùng trong mô hình GNN.

3.1.3.2. Thành phần cạnh 1: Tiếp giáp hành chính theo Queen contiguity

Để phản ánh lân cận hành chính, nghiên cứu sử dụng Queen adjacency (queen contiguity) trên đa giác ranh giới hành chính. Gọi P_i là polygon (hoặc multipolygon) của node v_i . Hai nút v_i và v_j được nối cạnh nếu: $P_i \cap P_j \neq \emptyset$, tức là hai polygon giao nhau hoặc chạm nhau (kể cả chỉ tại một điểm biên). Khi đó, cạnh (i, j) được thêm vào tập cạnh E_Q . Để giảm chi phí tính toán do số lượng polygon lớn, quá trình kiểm tra được tăng tốc bằng spatial index: trước hết lấy các ứng viên theo bounding box, sau đó mới kiểm tra điều kiện hình học $P_i \cap P_j \neq \emptyset$. Đồ thị được dùng trong nghiên cứu là đồ thị vô hướng, nên cạnh được chuẩn hóa và loại bỏ self-loop:

$$(i, j) \leftarrow (\min(i, j), \max(i, j)), (i, i) \notin E_Q.$$

3.1.3.3. Thành phần cạnh 2: Bổ sung KNN cho nút cô lập

Trong dữ liệu không gian thực tế, một số municipality có thể trở thành nút cô lập sau bước Queen contiguity (bậc bằng 0). Với các mô hình message passing, nút cô lập không nhận hay khuếch tán thông tin lân cận, làm suy giảm khả năng học quan hệ không gian. Gọi $\deg_Q(i)$ là bậc của node i trong đồ thị $G_Q = (V, E_Q)$. Với mọi node cô lập: $\deg_Q(i) = 0$, nghiên cứu bổ sung cạnh bằng K-nearest neighbors dựa trên centroid của polygon. Gọi $c_i \in \mathbb{R}^2$ là centroid của P_i . Với mỗi node cô lập i , ta chọn tập K láng giềng gần nhất: $\mathcal{N}_K(i) = \text{KNN}(c_i, \{c_j\}_{j \neq i}, K)$, và thêm các cạnh:

$$E_K \leftarrow E_Q \cup \{(i, j) \mid j \in \mathcal{N}_K(i)\},$$

Trong đó $K = 6$ trong nghiên cứu này.

3.1.3.4. Hợp nhất tập cạnh và biểu diễn cho PyTorch Geometric

Tập cạnh cuối cùng được hợp nhất: $E = E_Q \cup E_K$. Sau đó, các cạnh theo geocode được ánh xạ về chỉ số node bằng ϕ và lưu dưới hai dạng:

- Edge_list.csv: danh sách cạnh dạng bảng (src, dst) (phục vụ kiểm tra/đối soát).
- Edge_index.pt: tensor chuẩn PyTorch Geometric:

$$\text{edge_index} \in \mathbb{N}^{2 \times |E|},$$

Trong đó mỗi cột là một cạnh (src, dst) . Nếu mô hình yêu cầu cạnh hai chiều, có thể lưu thêm cặp đảo chiều (dst, src) để tạo đồ thị vô hướng từ đồ thị có hướng.

3.1.3.5. Kết quả khởi tạo cạnh

Sau khi xây dựng đồ thị, nghiên cứu thu được:

- $N = 5,564$ nút (toàn bộ municipality trong lớp bản đồ hành chính),
- $|E| \approx 16,382$ cạnh (Queen + KNN bổ sung cho nút cô lập),
- Không có self-loop và không có cạnh trùng do chuẩn hóa (min, max),
- Các tập đầu ra gồm edge_list.csv, edge_index.pt, node2idx.json dùng xuyên suốt pipeline.

Việc kết hợp E_Q (tiếp giáp hành chính) và E_K (bổ sung liên thông) giúp đồ thị vừa bám sát cấu trúc địa lý thực, vừa đảm bảo điều kiện tối thiểu cho message passing trong GNN.

3.1.4. Định nghĩa Đặc trưng và Nhãn gốc – Original Features and Labels

Sau khi thiết lập cấu trúc đồ thị $G = (V, E)$ với mỗi nút v_i đại diện một địa phương (geocode 7 ký tự), nghiên cứu xây dựng ma trận đặc trưng đầu vào và nhãn mục tiêu cho từng lớp theo tuần (weekly snapshot). Mỗi bản ghi dữ liệu được chuẩn hóa theo khóa ghép thống nhất: $k = (\text{geocode}, \text{year}, \text{epiweek})$, nhằm đảm bảo đồng bộ giữa các nguồn dữ liệu dịch tễ–khí hậu–dân số–môi trường trong cùng một tuần dịch tễ tại cùng một địa phương. Tại mỗi tuần t (tương ứng một cặp year_epiweek), đồ thị được biểu diễn dưới dạng: $G_t = (V, E, X_t, y_t)$, trong đó V và E là cố định theo toàn bộ chuỗi thời gian (theo thiết kế hiện tại), còn:

- $X_t \in \mathbb{R}^{N \times F}$: ma trận đặc trưng của $N = 5564$ địa phương ở tuần t ;
- $y_t \in \mathbb{R}^N$: vector nhãn mục tiêu của N địa phương ở tuần t .

Để đảm bảo nhất quán chỉ số nút giữa đặc trưng–nhãn–cạnh, các hàng của X_t và y_t được sắp theo ánh xạ `node2idx` (`geocode` $\rightarrow$ `index`). Bộ đặc trưng gốc được chọn theo nguyên tắc: có cơ sở dịch tễ học và có sẵn theo bộ dữ liệu không gian–thời gian trong hệ sinh thái Mosqlimate/IBGE. Các đặc trưng gốc được gán cho mỗi nút v_i tại tuần t gồm các nhóm sau:

Nhóm khí hậu (Climate – theo tuần, theo địa phương):

- `temp_med`: nhiệt độ trung bình tuần ($^{\circ}\text{C}$),
- `precip_tot`: tổng lượng mưa tuần (mm),
- `rainy_days`: số ngày mưa trong tuần (ngày),
- `rel_humid_med`: độ ẩm tương đối trung bình tuần (%).

Nhóm dân số – xã hội (Population & Geography – theo địa phương, theo năm hoặc tỉnh):

- `populacao`: dân số địa phương theo năm (người),

- altitude: độ cao so với mực nước biển (m),
- area_km2: diện tích địa phương (km^2).

Với mỗi nút v_i tại tuần t , vector đặc trưng gốc có dạng:

$$x_{i,t} = [\text{temp_med}, \text{precip_tot}, \text{rainy_days}, \text{rel_humid_med}, \text{populacao}, \text{altitude}, \text{area_km2}]_{(i,t)}.$$

Mục tiêu của bài toán dự báo được định nghĩa là số ca mắc mới sốt xuất huyết theo tuần tại mỗi địa phương:

$$y_{i,t} = \text{casos}_{(i,t)},$$

Tất cả nguồn dữ liệu được ghép theo khóa $k = (\text{geocode}, \text{year}, \text{epiweek})$. Ở mức dữ liệu gốc, nghiên cứu áp dụng các quy tắc tối thiểu để đảm bảo dữ liệu nạp mô hình ổn định:

1. Casos thiếu được gán 0 (phản ánh không ghi nhận ca trong tuần hoặc thiếu báo cáo để tránh suy diễn trung bình làm sai logic dịch tễ).
2. Biến khí hậu thiếu được điền bằng giá trị trung bình phù hợp theo tập dữ liệu (đảm bảo liên tục chuỗi theo tuần).
3. Dân số theo năm nếu thiếu sẽ dùng năm gần nhất (nearest year) để giữ tính liên tục nhân khẩu học khi dữ liệu công bố không đều theo năm.
4. Diện tích nếu thiếu ưu tiên tính lại từ hình học bản đồ; nếu không khả dụng, dùng trung vị để giảm nhạy với ngoại lệ diện tích cực lớn.

Trong đó casos là số ca được ghi nhận chính thức (reported cases). Nhãn này là biến đếm không âm và có thể xuất hiện nhiều giá trị 0 ở các địa phương/tuần khác nhau (tính thừa theo không gian – thời gian).

3.1.5. Bổ sung Đặc trưng dẫn xuất – Engineered Features

Biến bổ sung từ kỹ thuật tạo đặc trưng (engineered features):

1. Incidence_per_1k: số ca mắc trên 1.000 dân theo PAHO [16].

$$\text{Incidence_per1k} = \frac{\text{Casos}}{\text{POPULACAO}} \times 1000$$

2. Humid_heat_index: chỉ số kết hợp nhiệt độ – độ ẩm [17].

$$Humid_heat_index = \frac{Temp_med \times RelHumid_med}{100}$$

3. Precip_std_roll3: độ lệch chuẩn của lượng mưa trong 3 tuần [18].

$$Precip_std_roll3 = Std(Precip_tot^{(t-2:t)})$$

4. Dry_spell_len: số ngày khô hạn trong tuần [19].

$$Dry_spell_len = 7 - Rainy_days$$

5. Incidence_lag1: độ trễ dịch tễ 1 tuần trước (Incidence lag-1) [20].

$$Incidence_lag1 = Incidence_per1k, prev$$

6. Neighbor_cases_prev1: số ca mắc ở các địa phương lân cận trong tuần trước [4].

$$Neighbor_cases_prev1(i, t) = \sum_{j \in Neighbors(i)} Casos(j, t - 1)$$

Trong đó i là khu vực đang xem xét (geocode), t là tuần dịch tễ hiện tại, $j \in Neighbors(i)$ là tập các khu vực lân cận trực tiếp với i và $Casos(j, t - 1)$ là số ca bệnh ở khu vực j trong tuần trước ($t - 1$).

3.1.6. Xây dựng snapshot theo tuần

Sau khi chuẩn hóa khóa ghép $k = (\text{geocode}, \text{year}, \text{epiweek})$ và hoàn tất tập đặc trưng gốc (Mục 3.1.4) cùng tập đặc trưng dẫn xuất, nghiên cứu chuyển đổi dữ liệu dạng bảng thành chuỗi đồ thị theo tuần để mô hình học đồng thời quan hệ không gian và phụ thuộc thời gian. Mỗi tuần dịch tễ t (được định danh bởi (y, w) tương ứng year và epiweek) được biểu diễn thành một đồ thị: $G_t = (V, E, X_t, y_t)$,

Trong đó, V là tập nút cố định gồm $N = 5564$ municipality (định nghĩa tại Mục 3.1.2), không thay đổi theo thời gian. E là tập cạnh cố định (Queen contiguity + KNN cho nút cô lập) (định nghĩa tại Mục 3.1.3), được lưu dưới dạng *edge_index*. $X_t \in \mathbb{R}^{N \times F}$ là ma trận đặc trưng tại tuần t , với F là số chiều đặc trưng sau khi chọn và mã hóa. $y_t \in \mathbb{R}^N$ là vector nhãn tại tuần t , tương ứng mục tiêu dự báo theo municipality. Để đảm bảo nhất quán chỉ số nút trong toàn bộ pipeline (xây dựng dữ liệu – huấn luyện – đánh giá – trực quan hóa), mỗi snapshot tuần được lập theo ánh xạ: $\phi: \text{geocode} \rightarrow \{0, 1, \dots, N - 1\}$.

Với mỗi node v_i (ứng với geocode g_i), hàng thứ i của X_t được gán bởi vector đặc trưng tại khóa (g_i, y, w) : $X_t[i, :] = x(g_i, y, w)$, $y_t[i] = y(g_i, y, w)$. Nếu một địa phương không có bản ghi tại tuần t , nghiên cứu áp dụng quy tắc điền thiếu đã mô tả ở Mục

3.1.4–3.1.5 (ví dụ $\text{casos}=0$; khí hậu mean; dân số nearest-year; ...) để đảm bảo X_t và y_t luôn có đủ N hàng. Các đặc trưng dẫn xuất được tính theo hai hướng:

Theo thời gian (temporal features)

Ví dụ: Incidence_lag1 , Precip_std_roll3 ,... được tính dựa trên chuỗi tuần của cùng geocode:

$$\begin{aligned}\text{Incidence_lag1}(g, t) &= \text{Incidence}(g, t - 1), \text{Precip_std_roll3}(g, t) \\ &= \text{Std}(\text{Precip}(g, t - 2:t)).\end{aligned}$$

Nguyên tắc bắt buộc: mọi đặc trưng tại tuần t chỉ được dùng thông tin $\leq t$ (không dùng tương lai) để tránh rò rỉ theo thời gian.

Theo không gian (spatial neighborhood features)

Ví dụ: $\text{Neighbor_cases_prev1}$ được tính dựa trên tập láng giềng $\mathcal{N}(i)$ suy ra từ đồ thị:

$$\text{Neighbor_cases_prev1}(i, t) = \sum_{j \in \mathcal{N}(i)} \text{Casos}(j, t - 1).$$

Đặc trưng này vừa mang tính không gian (tập láng giềng), vừa đảm bảo tính thời gian (chỉ dùng $t - 1$). Mỗi snapshot G_t được lưu thành một tệp (ví dụ year_epiweek.pt) bao gồm các thành phần tối thiểu:

1. x : X_t (tensor $[N, F]$)
2. y : y_t (tensor $[N]$ hoặc $[N, 1]$ tùy chuẩn)
3. year, epiweek
4. geocodes: danh sách geocode theo thứ tự index $0..N - 1$
5. feature_cols: danh sách tên đặc trưng theo đúng thứ tự cột của x
6. train_mask, val_mask, test_mask: mặt nạ theo trục thời gian
7. scaler / label_transform / meta: thông tin chuẩn hóa để tái lập và kiểm chứng

Ngoài ra, edge_index được lưu riêng (ví dụ edge_index.pt) và dùng chung cho mọi t , giúp giảm dung lượng và đảm bảo tính nhất quán cấu trúc đồ thị.

Kết quả của bước này là một tập hợp có thứ tự theo thời gian: $\mathcal{D} = \{G_t\}_{t=1}^T$,

Trong đó T là tổng số tuần có dữ liệu trong giai đoạn nghiên cứu (ví dụ 2010–2024). Tập $\mathcal{D}$ là đầu vào trực tiếp cho các mô hình GNN/GCN/ST-GAT/Sheaf/Sheaf-Connection trong chương Thực nghiệm, đồng thời bảo toàn cấu trúc quá khứ - hiện tại - tương lai để đánh giá khả năng tổng quát hóa theo thời gian.

3.1.7. Phân chia mặt nạ train/validation/test theo trục thời gian

Vì mục tiêu của nghiên cứu là dự báo diễn biến dịch theo tuần trong bối cảnh chuỗi thời gian, việc chia tập huấn luyện/kiểm định/kiểm tra phải tuân thủ nguyên tắc quá khứ $\rightarrow$ hiện tại $\rightarrow$ tương lai, tránh mọi dạng nhìn trước (look-ahead) gây rò rỉ theo thời gian. Do đó, nghiên cứu áp dụng giao thức phân chia theo năm (year-based temporal split), trong khi vẫn giữ dữ liệu ở dạng snapshot theo tuần như Mục 3.1.6.

Nguyên tắc tổng quát: Với chuỗi đồ thị theo tuần $\{G_t\}_{t=1}^T$ (mỗi t tương ứng một *(year, epiweek)*), ta định nghĩa ba tập thời gian rời nhau:

$$\mathcal{T}_{train} \cap \mathcal{T}_{val} = \emptyset, \mathcal{T}_{train} \cap \mathcal{T}_{test} = \emptyset, \mathcal{T}_{val} \cap \mathcal{T}_{test} = \emptyset.$$

Trong đó, mọi tuần thuộc $\mathcal{T}_{train}$ phải xảy ra trước mọi tuần thuộc $\mathcal{T}_{val}$, và $\mathcal{T}_{val}$ phải xảy ra trước $\mathcal{T}_{test}$. Điều này đảm bảo đánh giá đúng khả năng tổng quát hóa theo thời gian (temporal generalization). Nghiên cứu sử dụng quy tắc phân chia theo năm:

- **Train:** các tuần thuộc giai đoạn 2010 $\rightarrow$ 2020
- **Validation:** các tuần thuộc 2021 $\rightarrow$ 2022
- **Test:** các tuần thuộc 2023 $\rightarrow$ 2024

Gọi $year(t)$ là năm của snapshot tuần t . Khi đó:

$$\begin{aligned} t \in \mathcal{T}_{train} &\Leftrightarrow 2010 \leq year(t) \leq 2020, \\ t \in \mathcal{T}_{val} &\Leftrightarrow year(t) \in \{2021, 2022\}, \\ t \in \mathcal{T}_{test} &\Leftrightarrow year(t) \in \{2023, 2024\}. \end{aligned}$$

Mỗi snapshot G_t chứa N nút (municipality). Trong thực tế, không phải mọi nút đều có dữ liệu hợp lệ ở mọi tuần (thiếu báo cáo, thiếu khí hậu, hoặc bị lọc). Vì vậy, trong mỗi snapshot tuần, ta dùng mặt nạ nhị phân theo nút: $m_t \in \{0,1\}^N$, trong đó, $m_t[i] = 1$ là nút i tại tuần t được phép tham gia loss/metric (dữ liệu hợp lệ), $m_t[i] = 0$ là nút i bị loại khỏi loss/metric ở tuần t . Nghiên cứu lưu 3 mặt nạ theo pha:

1. `train_mask` dùng khi tối ưu loss

2. val_mask dùng khi chọn mô hình/early stopping
3. test_mask dùng khi báo cáo kết quả cuối

Với mỗi snapshot tuần t , chỉ một loại mask tương ứng split của dữ liệu (ngoài trường hợp node thiếu dữ liệu thì vẫn =0). Tức là về logic:

$$\begin{aligned} \text{train_mask}_t &= 1[t \in \mathcal{T}_{\text{train}}] \odot \text{valid_mask}_t, \\ \text{val_mask}_t &= 1[t \in \mathcal{T}_{\text{val}}] \odot \text{valid_mask}_t, \\ \text{test_mask}_t &= 1[t \in \mathcal{T}_{\text{test}}] \odot \text{valid_mask}_t, \end{aligned}$$

Trong đó $\odot$ là nhân theo phần tử và valid_mask_t là mặt nạ hợp lệ dữ liệu theo nút tại tuần t . Split theo năm quyết định tuần đó thuộc train/val/test, còn mask theo nút đảm bảo chỉ tính loss/metric trên các node có dữ liệu hợp lệ tại tuần đó. Với dự báo của mô hình $\hat{y}_t \in \mathbb{R}^N$ và nhãn thật y_t , loss ở train được tính:

$$\mathcal{L}_{\text{train}}(t) = \frac{1}{\sum_i \text{train_mask}_t[i]} \sum_{i=1}^N \text{train_mask}_t[i] \cdot \ell(\hat{y}_t[i], y_t[i]),$$

với $\ell(\cdot)$ là Huber loss và tương tự, validation/test chỉ thay train_mask bằng val_mask hoặc test_mask.

3.1.8. Chuẩn hóa và biến đổi log - scale & log-transform

Nghiên cứu sử dụng chuẩn hóa Z-score (Standard Scaling) cho từng đặc trưng:

$x' = \frac{x-\mu}{\sigma}$, trong đó μ và σ lần lượt là trung bình và độ lệch chuẩn của đặc trưng. Để đảm bảo tính hợp lệ theo giao thức phân chia theo thời gian và tránh rò rỉ thông tin (data leakage), các tham số (μ, σ) chỉ được ước lượng trên tập huấn luyện (giai đoạn 2010–2020). Sau đó, cùng bộ tham số này được áp dụng nhất quán cho validation (2021–2022) và test (2023–2024). Với nhãn y là số ca mắc theo tuần (không âm và có nhiều giá trị 0), nghiên cứu sử dụng phép biến đổi: $y' = \log(1 + y)$, Cách này có hai lợi điểm: một là bảo toàn $y = 0$ và hai là giảm độ lệch phải của phân phối, giúp mô hình học ổn định hơn ở miền log-space

3.2. Kiến trúc mô hình – Model Architectures

3.2.1. Graph Neural Networks Baseline

Mục tiêu của mô hình baseline là thiết lập một mốc so sánh tối giản cho bài toán dự báo dengue trên đồ thị theo tuần. Mô hình sử dụng cơ chế message passing chuẩn của GNN, trong đó mỗi nút cập nhật biểu diễn bằng cách tổng hợp trung bình (mean aggregation) đặc trưng từ các nút lân cận, sau đó qua các lớp tuyến tính và phi tuyến để học quan hệ không gian cơ bản trên đồ thị.

Biểu diễn đầu vào và ký hiệu:

Tại mỗi tuần t , ta có một đồ thị $G_t = (V, E)$ cố định theo không gian, với ma trận đặc trưng nút $\mathbf{X}_t \in \mathbb{R}^{N \times F}$ (ở đây $N = 5564$, $F = 14$) ma trận cạnh được biểu diễn bằng `edge_index` (dạng PyG, biểu diễn E), nhãn dự báo theo nút được biểu diễn theo $\mathbf{y}_t \in \mathbb{R}^N$ (miền log-space). Mục tiêu của baseline là học một hàm dự báo: $\hat{\mathbf{y}}_t = f_\theta(\mathbf{X}_t, E)$.

Lớp lan truyền thông tin SimpleConv:

Mỗi lớp SimpleConv là một lớp MessagePassing với phép tổng hợp **mean**:

Bước 1: Chiếu tuyến tính đặc trưng nút: $\mathbf{h}_i = \mathbf{W}\mathbf{x}_i + \mathbf{b}$.

Bước 2: Truyền thông tin qua cạnh và lấy trung bình từ lân cận:

$$\mathbf{m}_i = \frac{1}{|\mathcal{N}(i)|} \sum_{j \in \mathcal{N}(i)} \mathbf{h}_j.$$

Trong implementation, `message(x_j)` trả lại trực tiếp embedding của nút láng giềng j , còn `aggr='mean'` thực hiện phép trung bình. Điểm cần chú ý: lớp này không dùng attention, không dùng edge features, và không có cơ chế temporal bên trong (tham số `temporal_seq` được giữ để tương thích pipeline nhưng không sử dụng). Mạng baseline gồm 2 lớp SimpleConv để khai thác thông tin lân cận bậc 1 và bậc 2 (two-hop neighborhood), ReLU + Dropout sau mỗi lớp để tăng phi tuyến và giảm overfitting và 1 lớp Linear cuối để dự báo giá trị hồi quy theo nút

Cụ thể:

$$\mathbf{H}^{(1)} = \text{Dropout}(\text{ReLU}(\text{Conv}_1(\mathbf{X})))$$

$$\mathbf{H}^{(2)} = \text{Dropout}(\text{ReLU}(\text{Conv}_2(\mathbf{H}^{(1)})))$$

$$\hat{\mathbf{y}} = \text{Linear}(\mathbf{H}^{(2)}) \in \mathbb{R}^N.$$

Trong output được squeeze (-1) để đưa về vector $[N]$, phù hợp với nhãn y

3.2.2. Graph Convolutional Networks

Mô hình GCN được sử dụng như một baseline mạnh hơn so với GNN-mean thông thường, vì GCN chuẩn hoá lan truyền theo bậc nút (degree normalization). Nhờ đó, thông tin từ lân cận được tổng hợp có kiểm soát, giảm thiên lệch do các nút có bậc quá lớn và giúp tối ưu ổn định hơn trên đồ thị không gian.

Tại mỗi tuần t , ta có:

Đồ thị $G_t = (V, E)$ (tập nút cố định theo không gian)

Đặc trưng nút $\mathbf{X}_t \in \mathbb{R}^{N \times F}$

Nhãn $\mathbf{y}_t \in \mathbb{R}^N$

Mục tiêu: $\hat{\mathbf{y}}_t = f_\theta(\mathbf{X}_t, E)$.

Trong kiến trúc này, tham số `temporal_seq` được giữ để tương thích pipeline nhưng không sử dụng. Công thức lan truyền của GCNConv: GCNConv (Kipf & Welling) thực hiện phép lan truyền: $\mathbf{H}^{(l+1)} = \sigma(\tilde{\mathbf{D}}^{-\frac{1}{2}} \tilde{\mathbf{A}} \tilde{\mathbf{D}}^{-\frac{1}{2}} \mathbf{H}^{(l)} \mathbf{W}^{(l)})$ trong đó $\tilde{\mathbf{A}} = \mathbf{A} + \mathbf{I}$ là ma trận kề có self-loop, $\tilde{\mathbf{D}}$ biểu diễn cho ma trận bậc tương ứng của $\tilde{\mathbf{A}}$, $\mathbf{W}^{(l)}$ là tham số học của lớp và $\sigma(\cdot)$ là phi tuyến (ReLU trong triển khai) Ý nghĩa: mỗi nút nhận thông tin từ chính nó và lân cận, nhưng được chuẩn hoá đối xứng theo bậc, giúp giảm hiệu ứng nút hub chi phối. Kiến trúc GCNModel (2-layer GCN): Mô hình nghiên cứu đang dùng gồm 2 lớp GCNConv dùng để học thông tin lân cận 1-hop và 2-hop, ReLU + Dropout sau mỗi lớp và Linear head để dự báo hồi quy theo nút vào dạng toán học:

$$\mathbf{H}^{(1)} = \text{Dropout}(\text{ReLU}(\text{GCNConv}_1(\mathbf{X})))$$

$$\mathbf{H}^{(2)} = \text{Dropout}(\text{ReLU}(\text{GCNConv}_2(\mathbf{H}^{(1)})))$$

$$\hat{\mathbf{y}} = \text{Linear}(\mathbf{H}^{(2)}) \in \mathbb{R}^N$$

Trong code `self.lin(h).squeeze(-1)` đưa output về vector $[N]$, khớp nhãn.

3.2.3. Spatial-Temporal Graph Attention Networks

Mục tiêu của ST-GAT trong nghiên cứu này là kết hợp đồng thời phụ thuộc thời gian theo tuần của từng địa phương và lan truyền/ảnh hưởng không gian qua liên kết lân cận

trong đồ thị. Kiến trúc được thiết kế theo hướng gọn nhẹ nhưng đủ mạnh để chạy ổn định trên CPU: Temporal Encoder (GRU + Multi-Head Attention) truyền 2 tầng GATConv và Linear head. Tại mỗi tuần t , đồ thị snapshot:

$$G_t = (V, E), |V| = N, |E| = E$$

Với $\mathbf{X}_t \in \mathbb{R}^{N \times F}$ là đặc trưng nút tại tuần t , $\mathbf{y}_t \in \mathbb{R}^N$ là nhãn (log-space) tại tuần t và $edge_index \in \mathbb{N}^{2 \times E}$ là danh sách cạnh Để mô hình hoá thời gian, với mỗi nút i , xây dựng một chuỗi đặc trưng trễ: $\mathbf{S}_{i,t} \in \mathbb{R}^{T \times F_t}$.

Mục tiêu:

$$\hat{\mathbf{y}}_t = f_\theta(\mathbf{X}_t, E, \mathbf{S}_t)$$

Khối Temporal Encoder: GRU + Multi-Head Attention: Khối thời gian tạo embedding theo nút: $\mathbf{z}_{i,t} = \text{TempEnc}(\mathbf{S}_{i,t}) \in \mathbb{R}^{H_t}$ Trong code:

Bước 1 — GRU: $\mathbf{H}_i = \text{GRU}(\mathbf{S}_i) \in \mathbb{R}^{T \times H_t}$; **out = gru(seq) trả về [N,T,H]**.

Bước 2 — Multi-Head Self-Attention: $\mathbf{A}_i = \text{MHA}(\mathbf{H}_i, \mathbf{H}_i, \mathbf{H}_i) \in \mathbb{R}^{T \times H_t}$

Bước 3 — lấy trạng thái cuối + residual (GRU last + attn last): $\mathbf{z}_i = \mathbf{H}_i[T] + \mathbf{A}_i[T]$ rồi **qua dropout + linear projection: $\mathbf{z}_i = \mathbf{W}_p(\text{Dropout}(\mathbf{z}_i))$**

GRU học dạng động lực theo thời gian (trend/seasonality/lag effect). Multi-Head Self-Attention giúp mô hình tập trung vào các mốc trễ quan trọng thay vì coi mọi bước trễ như nhau. Residual ở timestep cuối giúp ổn định và giữ thông tin thô của GRU.

Ghép không gian–thời gian ở mức nút

Nếu có temporal_seq (self.has_temporal=True), embedding thời gian được nối vào đặc trưng nút: $\tilde{\mathbf{X}} = [\mathbf{X} \parallel \mathbf{Z}] \in \mathbb{R}^{N \times (F+H_t)}$ (trong code: torch.cat([x, t_emb], dim=1)).

Nếu không có temporal_seq thì:

$$\tilde{\mathbf{X}} = \mathbf{X}$$

Ghép không gian–thời gian ở mức nút:

GAT thực hiện attention theo cạnh (i, j) để tổng hợp lân cận có trọng số.

Tầng 1 (concat=True) $\mathbf{H}^{(1)} = \text{ELU}(\text{GATConv}_1(\tilde{\mathbf{X}}, E))$

Với số head = heads1 và output dimension = hidden * heads1 do concat.

Tầng 2 (concat=False) $\mathbf{H}^{(2)} = \text{ELU}(\text{GATConv}_2(\mathbf{H}^{(1)}, E))$

Có số head = heads2 và concat=False nên output dimension = hidden (đã “gom head”).

Sau mỗi tầng có dropout: $\mathbf{H}^{(l)} \leftarrow \text{Dropout}(\mathbf{H}^{(l)})$

Linear head dự báo $\hat{\mathbf{y}} = \mathbf{W}\mathbf{H}^{(2)} \in \mathbb{R}^{N \times 1} \Rightarrow \mathbb{R}^N$

Temporal: dengue có tính mùa vụ + độ trễ (muối, khí hậu, miễn dịch cộng đồng) vậy nên GRU + attention giúp nắm lag effect.

Spatial: dịch lan theo liên vùng (di chuyển dân cư, vùng giáp ranh, điều kiện tương đồng) ví thể GAT cho phép mô hình ưu tiên hàng xóm quan trọng hơn hàng xóm ít liên quan.

Fusion: ghép thời gian vào nút trước khi message passing giúp attention không gian thấy được bối cảnh thời gian của từng node.

Tóm tắt công thức:

$$\mathbf{Z} = \text{TempEnc}(\mathbf{S}), \tilde{\mathbf{X}} = [\mathbf{X} \parallel \mathbf{Z}], \mathbf{H} = \text{GAT}_2(\text{GAT}_1(\tilde{\mathbf{X}}, E), E), \hat{\mathbf{y}} = \text{Linear}(\mathbf{H})$$

3.2.4. Sheaf Neural Networks Baseline

Khác với GCN/GAT vốn tổng hợp thông tin lân cận bằng một trọng số chung (GCN) hoặc attention scalar theo cạnh (GAT), sheaf-oriented baseline trong nghiên cứu này hướng tới ý tưởng: mỗi cạnh (edge) có một “toán tử truyền tin” riêng phụ thuộc vào cặp nút, nhằm mô hình hóa sự khác biệt liên vùng và tính không đồng nhất của quan hệ giữa các địa phương. Trong dịch tễ theo không gian–thời gian, quan hệ giữa hai đô thị kề nhau có thể rất khác nhau (mật độ dân số, khí hậu, giao thông, đô thị hóa...). Vì vậy, baseline Sheaf được xây dựng theo hướng edge-conditioned message passing: thông điệp truyền qua cạnh được điều chỉnh bởi tham số sinh ra từ chính cặp nút (i, j) .

Định nghĩa lớp SheafLayer (edge-conditioned message passing):

Cho một đồ thị $G = (V, E)$, với đặc trưng nút $\mathbf{x}_i \in \mathbb{R}^F$. Với mỗi cạnh có hướng $(i \leftarrow j)$ (trong code: row=i, col=j), mô hình tạo một vector trọng số theo cạnh:

$$\mathbf{w}_{ij} = f_{\theta}([\mathbf{x}_i \parallel \mathbf{x}_j]) \in \mathbb{R}^r$$

Trong đó f_θ là một MLP (edge_mlp), và r là rank (mặc định 4). Tiếp theo, thông điệp từ nút j sang i được điều chỉnh theo cạnh bằng cách nhân $\mathbf{x}_j$ với $\mathbf{w}_{ij}$ theo kiểu broadcast, rồi lấy trung bình theo chiều rank: $\mathbf{m}_{ij} = \frac{1}{r} \sum_{k=1}^r w_{ij,k} \mathbf{x}_j \in \mathbb{R}^F$. Cuối cùng, các thông điệp được cộng dồn về nút đích i : $\mathbf{z}_i = \sum_{j \in \mathcal{N}(i)} \mathbf{m}_{ij}$ và qua một phép chiếu tuyến tính để đổi chiều đặc trưng:

$$\mathbf{h}_i = \mathbf{W}\mathbf{z}_i$$

Tuy chưa phải Sheaf Neural Network đầy đủ theo lý thuyết bó (chưa có stalks/sections & restriction maps dạng ma trận, chưa có consistency objective rõ ràng). Tuy nhiên, nó giữ tinh thần quan trọng: toán tử truyền tin phụ thuộc cạnh (edge-conditioned / connection-like). Mô hình baseline được xếp chồng hai SheafLayer để tăng tầm nhìn lan truyền: Layer 1: tổng hợp từ lân cận bậc 1, sinh biểu diễn $\mathbf{h}^{(1)}$ và Layer 2: tổng hợp tiếp trên $\mathbf{h}^{(1)}$ để nhận ảnh hưởng bậc 2, sinh $\mathbf{h}^{(2)}$. Sau mỗi tầng có lớp phi tuyến ReLU và dropout để giảm overfitting. Cuối cùng, một linear head đưa về dự đoán một giá trị cho mỗi nút: $\hat{y}_i = \mathbf{w}^\top \mathbf{h}_i^{(2)} + b$. Sheaf baseline được dùng để: Kiểm tra xem cơ chế edge-conditioned weights có giúp hơn so với GNN/GCN cơ bản hay không. Là mốc trước khi nâng lên Sheaf-Connection (sheaf_conn).

3.2.5. Sheaf-Connection Neural Networks

Sheaf-Connection (sheaf_conn) được thiết kế theo tinh thần connection-style sheaf: thay vì chỉ học trọng số theo cạnh (edge-conditioned weights) như baseline Sheaf (mục 3.2.4), mô hình này giả định rằng mỗi cạnh (i, j) định nghĩa một toán tử biến đổi (restriction/connection map) để ánh xạ biểu diễn của nút nguồn sang không gian của nút đích. Khi đó, mục tiêu truyền tin không chỉ là cộng dồn thông tin lân cận, mà là giảm bất nhất (disagreement) giữa biểu diễn đã biến đổi của nút nguồn và biểu diễn nút đích. Trong bài toán dịch tễ, cách nhìn này phù hợp với giả thuyết: các vùng lân cận có thể khác nhau về quy mô/điều kiện, nên muốn truyền tin hiệu lan truyền hợp lý, cần một phép biến đổi theo cạnh để đưa hai vùng về cùng hệ quy chiếu biểu diễn trước khi so sánh/đồng bộ. Biểu diễn stalk và phân rã ẩn (hidden $\rightarrow$ stalks) để mô hình chiếu đặc trưng đầu vào $\mathbf{x}_i \in \mathbb{R}^F$ sang không gian ẩn $\mathbf{h}_i \in \mathbb{R}^H$ bằng in_proj. Sau đó, $\mathbf{h}_i$ được chia thành $\mathbf{S}$ stalk nhỏ $2\mathbf{D}$: $H = 2S, \mathbf{h}_i = [\mathbf{h}_i^{(1)}, \dots, \mathbf{h}_i^{(S)}], \mathbf{h}_i^{(s)} \in \mathbb{R}^2$.

Trong code, stalk_dim=2, num_stalks = hidden / 2 và reshape: $[N, H] \rightarrow [N, S, 2]$

Bởi học một phép biến đổi lớn $H \times H$ theo cạnh (rất nặng), mô hình học nhiều phép biến đổi nhỏ 2×2 theo từng stalk, giúp ổn định và giảm độ phức tạp.

Temporal context (tích hợp thông tin thời gian): Nếu có temporal_seq dạng $[N, T, F_t]$, mô hình lấy trung bình theo thời gian rồi chiếu về $\mathbb{R}^H$:

$$\mathbf{t}_i = \text{mean}_{t=1..T}(\text{temporal_seq}_{i,t,:}) \in \mathbb{R}^{F_t}, \tilde{\mathbf{t}}_i = \mathbf{W}_t \mathbf{t}_i \in \mathbb{R}^H, \\ \mathbf{h}_i \leftarrow \mathbf{h}_i + \tilde{\mathbf{t}}_i.$$

Trong code, _build_temporal_context: t_ctx = temporal_seq.mean(dim=1), temporal_proj = LazyLinear(H) để tránh mismatch F_t (tự suy ra ở lần forward đầu tiên) và $\mathbf{h} = \mathbf{h} + \mathbf{t_ctx}$. Điểm quan trọng: sheaf_conn có dùng thời gian, nhưng theo cách gọn (mean pooling), khác ST-GAT (GRU + attention).

Restriction/connection map theo cạnh: rotation 2×2 theo stalk:

Với mỗi cạnh $(i \rightarrow j)$, mô hình tạo feature cạnh: $\mathbf{e}_{ij} = [\mathbf{h}_i \parallel \mathbf{h}_j \parallel \|\mathbf{h}_i - \mathbf{h}_j\|] \in \mathbb{R}^{3H}$.

Qua edge_mlp, mô hình sinh một góc quay cho mỗi stalk: $\theta_{ij}^{(s)} = \text{MLP}(\mathbf{e}_{ij})_s, s = 1..S$.

Từ đó tạo ma trận quay 2D cho từng stalk: $\mathbf{R}_{ij}^{(s)} = \begin{bmatrix} \cos \theta_{ij}^{(s)} & -\sin \theta_{ij}^{(s)} \\ \sin \theta_{ij}^{(s)} & \cos \theta_{ij}^{(s)} \end{bmatrix} \in \mathbb{R}^{2 \times 2}$.

Trong code: _edge_rotations() tạo tensor rot: $[E, S, 2, 2]$. Ý nghĩa khoa học: $\mathbf{R}_{ij}^{(s)}$ đóng vai trò như một restriction/connection map nhỏ theo cạnh, thực thi đưa biểu diễn nguồn sang hệ quy chiếu của đích (ở mức stalk).

Disagreement và cập nhật thông tin (consistency-style message passing): Với biểu diễn stalk của nút nguồn và đích trên cạnh $(i \rightarrow j)$: $\mathbf{h}_i^{(s)}, \mathbf{h}_j^{(s)} \in \mathbb{R}^2$, mô hình ánh xạ nguồn qua restriction map: $\hat{\mathbf{h}}_{i \rightarrow j}^{(s)} = \mathbf{R}_{ij}^{(s)} \mathbf{h}_i^{(s)}$. Độ bất nhất (disagreement): $\Delta_{ij}^{(s)} = \hat{\mathbf{h}}_{i \rightarrow j}^{(s)} - \mathbf{h}_j^{(s)}$. Mô hình tạo tín hiệu cập nhật bằng cách giảm disagreement: cộng $-\Delta$ về nút đích (đẩy $\mathbf{h}_j$ gần với $\hat{\mathbf{h}}_{i \rightarrow j}$) và cộng $+\Delta$ về nút nguồn (đối xứng mềm, giúp ổn định). Sau đó lấy trung bình hai hướng:

$$\text{agg}_j^{(s)} \leftarrow \sum_{i \in \mathcal{N}(j)} (-\Delta_{ij}^{(s)}), \text{agg}_i^{(s)} \leftarrow \sum_{j \in \mathcal{N}(i)} (\Delta_{ij}^{(s)}),$$

$$\text{agg} = \frac{1}{2} (\text{agg_dst} + \text{agg_src}).$$

Cuối cùng áp dụng: residual: $\mathbf{h} \leftarrow \mathbf{h} + \text{Dropout}(\text{agg})$ và LayerNorm + ReLU để ổn định tối ưu. Sau lớp cập nhật, mô hình dùng out_head (MLP) để dự báo hồi quy: $\hat{y}_i = g_\phi(\mathbf{h}_i)$ và đảm bảo output dạng $[N]$ khi out_dim=1 (squeeze).

3.2.6. Độ phức tạp và tính ổn định

Mô hình	Thành phần chính	Độ phức tạp snapshot (xấp xỉ)	Nhạy cảm/ổn định	Ghi chú thực nghiệm
GNN baseline	$2 \times \text{mean aggregation} + \text{Linear}$	$(O(EH)) / \text{layer}$	Ổn định, ít nhạy	Là mốc so sánh, dễ hội tụ nhưng giới hạn biểu diễn
GCN	$2 \times \text{GCNConv} + \text{Linear}$	$(O(EH)) / \text{layer}$	Ổn định, tốt hơn baseline	Thường cải thiện nhờ chuẩn hóa lân cận
ST-GAT	TemporalEncoder (GRU+MHA) + $2 \times \text{GATConv}$	$(O(NTH_t) + O(EhH))$	Nhạy hyperparam hơn, nhưng mạnh	Attention + temporal giúp bắt mùa vụ và lan truyền
Sheaf baseline	edge_MLP sinh weights + aggregate	$(O(EH)) + \text{MLP theo cạnh}$	Dễ dao động nếu tune kém	Có thể khó tối ưu, phụ thuộc cấu hình rank/hidden

Sheaf-Conn (sheaf_conn)	edge_MLP sinh θ + rotation stalk 2D + residual+norm	(O(EH)) + (O(ES))	Hội tụ nhanh, cần kiểm soát cấu hình	Nếu hidden nhỏ hơn mô hình khác phải nêu rõ để công bằng
----------------------------	--	----------------------	--	--

Bảng 3.6 Độ phức tạp và tính ổn định

3.3. Hàm mất mát & Thước đo - Loss & Metrics

3.3.1. Loss: Huber – Robust với outliers

Dữ liệu dịch tễ theo tuần thường có phân phối lệch phải và xuất hiện các đỉnh bùng phát cục bộ (outliers) do đặc tính mùa vụ, lây lan theo vùng, hoặc sai khác trong cơ chế ghi nhận ca bệnh. Trong bối cảnh đó, việc tối ưu bằng MSE (Mean Squared Error) có thể khiến mô hình bị chi phối mạnh bởi một số tuần có sai số rất lớn, dẫn đến quá trình học kém ổn định và dễ overfit vào các cực trị. Do đó, nghiên cứu lựa chọn Huber loss như một hàm mất mát lai giữa MSE và MAE nhằm giảm nhạy với outliers nhưng vẫn giữ độ nhạy tại vùng sai số nhỏ. Gọi y_i là nhãn (trong nghiên cứu là nhãn đã biến đổi log:

$y_i = \log(1 + \text{casos}_i)$) và $\hat{y}_i$ là dự báo của mô hình cho một quan sát (node-week) i . Sai số được ký hiệu $e_i = \hat{y}_i - y_i$. Huber loss với ngưỡng $\delta > 0$ được định nghĩa:

$$\mathcal{L}_\delta(e_i) = \begin{cases} \frac{1}{2} e_i^2, & \text{nếu } |e_i| \leq \delta, \\ \delta \left(|e_i| - \frac{1}{2} \delta \right), & \text{nếu } |e_i| > \delta. \end{cases}$$

Tổng loss trên tập huấn luyện được lấy trung bình theo các phần tử thuộc mặt nạ huấn luyện của từng snapshot: $\mathcal{L} = \frac{1}{M} \sum_{i=1}^M \mathcal{L}_\delta(\hat{y}_i - y_i)$, trong đó M là số lượng node-week hợp lệ (thuộc train mask) trong epoch hiện tại. Trong thực nghiệm, nghiên cứu sử dụng HuberLoss(delta = 1.2) để đạt cân bằng giữa: tối ưu tốt trong vùng sai số nhỏ (hành vi giống MSE), và hạn chế ảnh hưởng của các sai số cực lớn (hành vi gần MAE) – phù hợp với dữ liệu dịch tễ có nhiều đỉnh bùng phát. Huber loss được lựa chọn vì đặc tính chuyển tiếp từ bình phương sai số sang tuyến tính theo ngưỡng δ , qua đó giảm tác động của các tuần bùng phát bất thường trong quá trình lan truyền dịch, giúp quá trình tối ưu ổn định hơn khi huấn luyện theo chuỗi snapshot tuần.

3.3.2. Log-space metrics: MAE/RMSE/R²/trimmed-R²

Trong nghiên cứu này, mô hình được huấn luyện để dự báo nhãn đã biến đổi log theo $y' = \log(1 + y)$ nhằm giảm lệch phân phối và ổn định tối ưu. Vì vậy, trước tiên cần đánh giá hiệu năng trực tiếp trong miền log (log-space) để phản ánh khả năng mô hình học và khớp dữ liệu trên đúng miền tối ưu. Gọi $y_i^{\log}$ là giá trị thực và $\hat{y}_i^{\log}$ là dự báo của mô hình tại quan sát (node-week) i , n là tổng số phần tử được đánh giá trong một tập (val/test hoặc gộp micro).

MAE trong log-space: Mean Absolute Error đo sai số tuyệt đối trung bình trong miền

$$\text{log:MAE}_{\log} = \frac{1}{n} \sum_{i=1}^n |\hat{y}_i^{\log} - y_i^{\log}|.$$

RMSE trong log-space: $\text{MAE}_{\log}$ cho biết mức lệch trung bình giữa dự báo và thực tế trong không gian log, ít nhạy hơn RMSE với các sai số lớn.

Root Mean Squared Error: nhấn mạnh sai số lớn hơn do bình phương sai số:

$$\text{RMSE}_{\log} = \sqrt{\frac{1}{n} \sum_{i=1}^n (\hat{y}_i^{\log} - y_i^{\log})^2}.$$

$\text{RMSE}_{\log}$ hữu ích để kiểm tra việc mô hình có gặp đỉnh sai số ở một số node-week hay không.

Hệ số xác định R^2 bền vững (robust R^2) trong log-space: Với dữ liệu có thể xuất hiện tuần có phương sai rất nhỏ (ví dụ nhiều giá trị gần nhau), việc tính R^2 cần cơ chế bảo vệ để tránh chia cho gần 0. Nghiên cứu dùng phiên bản R^2 bền vững:

$$R_{\log} = 1 - \frac{\sum_{i=1}^n (y_i^{\log} - \hat{y}_i^{\log})^2}{\sum_{i=1}^n (y_i^{\log} - \bar{y}^{\log})^2 + \varepsilon}, \bar{y}^{\log} = \frac{1}{n} \sum_{i=1}^n y_i^{\log}.$$

Trong đó ε là hằng số rất nhỏ nhằm tránh chia cho 0. Trong triển khai (robust_r2), nếu $\sum (y_i - \bar{y})^2$ quá nhỏ, chỉ số được đưa về 0 để tránh kết luận sai do bất ổn số học.

Trimmed- R^2 trong log-space:

Dữ liệu dịch tễ theo tuần có thể chứa một số điểm cực trị (đỉnh dịch cực bộ hoặc bất thường báo cáo). Để đánh giá năng lực mô hình trên mặt bằng chung thay vì bị chi phối

bởi một số điểm lỗi rất lớn, nghiên cứu sử dụng trimmed- R^2 : loại bỏ phần đuôi sai số tuyệt đối lớn nhất theo tỷ lệ τ (mặc định $\tau = 0.01$, tức cắt 1%).

Gọi $e_i = |y_i^{\log} - \hat{y}_i^{\log}|$. Ngưỡng cắt được xác định theo phân vị:

$$\theta = \text{Quantile}_{1-\tau}(e), \mathcal{I} = \{i \mid e_i \leq \theta\}.$$

Sau đó tính R^2 trên tập chỉ số giữ lại $\mathcal{I}$:

$$R_{\log, \text{trim}}^2 = R^2(\{y_i^{\log}\}_{i \in \mathcal{I}}, \{\hat{y}_i^{\log}\}_{i \in \mathcal{I}}).$$

Trimmed- R^2 giúp phản ánh ổn định hơn hiệu năng dự báo trong điều kiện có outliers và phù hợp với mục tiêu dự báo nền dịch thay vì tối ưu hóa một vài đỉnh cực lớn.

3.3.3. Real-space metrics: MAE/RMSE/SMAPE/ R^2 /trimmed- R^2

Mặc dù mô hình được huấn luyện trên nhãn đã biến đổi $y^{\log} = \log(1 + y)$ để ổn định tối ưu, giá trị cần diễn giải theo y tế cộng đồng là số ca bệnh trong miền thực y (ca/tuần). Vì vậy, nghiên cứu báo cáo đầy đủ các thước đo trong real-space sau khi back-transform dự báo từ log-space về real-space. Back-transform từ log-space sang real-space: Gọi $\hat{y}^{\log}$ là dự báo của mô hình trong log-space. Giá trị dự báo real-space được khôi phục theo một trong hai cách:

a. Log1p inverse cơ bản (khi không hiệu chỉnh bias): $\hat{y} = \exp(\hat{y}^{\log}) - 1$.

b. Hiệu chỉnh sai lệch log-normal (bias correction):

Do $\mathbb{E}[\exp(\hat{y}^{\log})] \neq \exp(\mathbb{E}[\hat{y}^{\log}])$, dự báo sau log có thể bị lệch dùng 2 cơ chế:

- Duan's smearing estimator (ưu tiên): ước lượng hệ số smearing

$S = \mathbb{E}[\exp(\varepsilon)]$ từ residual trên tập train, với $\varepsilon = y^{\log} - \hat{y}^{\log}$.

$$\hat{y} = \exp(\hat{y}^{\log}) \cdot S - 1.$$

- Sigma² correction (dự phòng): giả định residual gần log-normal với phương sai σ^2 : $\hat{y} = \exp(\hat{y}^{\log} + 0.5\sigma^2) - 1$.

c. Hiệu chỉnh sai lệch log-normal (bias correction):

Để giảm tác động của outlier cực trị trong miền thực, dự báo được chặn bởi một ngưỡng học từ train (phân vị cao, ví dụ $q = 0.999$): $\hat{y} \leftarrow \min(\max(\hat{y}, 0), \text{cap}_{q=0.999})$.

MAE trong real-space: $MAE_{\text{real}} = \frac{1}{n} \sum_{i=1}^n |\hat{y}_i - y_i|$. MAE_{real} trực tiếp phản ánh sai số trung bình theo đơn vị ca bệnh/tuần, dễ diễn giải thực tế.

RMSE trong real-space: $RMSE_{\text{real}} = \sqrt{\frac{1}{n} \sum_{i=1}^n (\hat{y}_i - y_i)^2}$. $RMSE_{\text{real}}$ nhấn mạnh các tuần/địa phương dự báo sai lớn đỉnh dịch. Với dữ liệu dịch tễ theo tuần thường có nhiều giá trị nhỏ và cả 0, nghiên cứu dùng SMAPE (Symmetric MAPE) có ổn định mẫu số bằng ε và SMAPE được ổn định bằng epsilon để xử lý tuần có $y = 0$:

$$SMAPE_{\text{real}} = \frac{1}{n} \sum_{i=1}^n \frac{2 |\hat{y}_i - y_i|}{|\hat{y}_i| + |y_i| + \varepsilon}.$$

R^2 trong real-space (robust R^2): $R^2_{\text{real}} = 1 - \frac{\sum_{i=1}^n (y_i - \bar{y})^2}{\sum_{i=1}^n (y_i - \bar{y})^2 + \varepsilon}$. Trong đó $\bar{y}$ là trung bình của y trên tập đánh giá. Tương tự log-space, ε giúp tránh bất ổn khi phương sai rất nhỏ.

Trimmed- R^2 trong real-space: Để giảm ảnh hưởng một số tuần/địa phương có sai số cực lớn (outlier), ta cắt phần đuôi sai số tuyệt đối lớn nhất τ (mặc định 1%):

$$e_i = |y_i - \hat{y}_i|, \theta = \text{Quantile}_{1-\tau}(e), \mathcal{I} = \{i \mid e_i \leq \theta\},$$

$$R^2_{\text{real,trim}} = R^2(\{y_i\}_{i \in \mathcal{I}}, \{\hat{y}_i\}_{i \in \mathcal{I}}).$$

Macro theo tuần: tính MAE/RMSE/SMAPE/ R^2 /trimmed- R^2 cho từng tuần rồi lấy trung bình theo tuần phản ánh độ ổn định theo thời gian. Micro gộp: gộp tất cả node-week của val/test rồi tính một lần phản ánh hiệu năng tổng thể theo số lượng mẫu.

3.3.4. ROC-AUC/PR-AUC từ hồi quy ($q=0.9$)

Bên cạnh các thước đo hồi quy (MAE/RMSE/ R^2) nhằm đánh giá sai số dự báo số ca, nghiên cứu này bổ sung nhóm chỉ số phục vụ mục tiêu cảnh báo sớm—tức khả năng phát hiện các tuần/địa phương có nguy cơ bùng phát cao. Do bài toán gốc được huấn luyện dưới dạng hồi quy (dự báo số ca theo tuần), nghiên cứu quy đổi đầu ra hồi quy thành một bài toán phân loại nhị phân thông qua ngưỡng theo phân vị. Cụ thể, với mỗi tập đánh giá (validation hoặc test), đặt ngưỡng bùng phát τ bằng phân vị $q = 0.9$ của phân phối số ca thực (real-space), $\tau = Q_{0.9}(y)$. Khi đó, nhãn nhị phân được định nghĩa

$z_{i,t} = 1$ nếu $y_{i,t} \geq \tau$ và $z_{i,t} = 0$ nếu $y_{i,t} < \tau$, trong đó $y_{i,t}$ là số ca thực tại địa phương i ở tuần dịch tễ t . Điểm số dùng để xếp hạng cho bài toán phân loại được lấy trực tiếp từ dự báo hồi quy $\hat{y}_{i,t}$ (sau khi back-transform về real-space), với giả định rằng $\hat{y}_{i,t}$ càng lớn thì xác suất rơi vào nhóm tuần bùng phát càng cao. Trên cơ sở nhãn nhị phân $z_{i,t}$ và điểm số $\hat{y}_{i,t}$, nghiên cứu tính ROC-AUC nhằm đo năng lực phân biệt (discrimination) giữa các tuần bùng phát và tuần bình thường theo nhiều ngưỡng quyết định khác nhau, đồng thời tính PR-AUC để phản ánh chất lượng cảnh báo trong bối cảnh dữ liệu mất cân bằng, do lớp dương (bùng phát) theo định nghĩa phân vị thường chỉ chiếm xấp xỉ 10% quan sát. Trong bối cảnh dịch tễ, PR-AUC có ý nghĩa thực tiễn mạnh hơn khi đánh giá mức độ đáng tin của cảnh báo, vì nó liên quan trực tiếp đến tương quan giữa precision (tỉ lệ cảnh báo đúng) và recall (tỉ lệ phát hiện được bùng phát). Ngoài ra, nghiên cứu báo cáo tỉ lệ dương (pos_rate) tương ứng với tỷ lệ quan sát có $z_{i,t} = 1$ theo ngưỡng phân vị đã chọn, nhằm cung cấp bối cảnh mất cân bằng lớp và giúp diễn giải PR-AUC một cách nhất quán. Trong trường hợp dữ liệu của một tập đánh giá chỉ chứa một lớp (toàn 0 hoặc toàn 1) hoặc môi trường thiếu thư viện tính toán AUC, hệ thống đánh giá sẽ trả về giá trị trung tính để tránh làm gián đoạn pipeline thực nghiệm, bảo đảm tính ổn định và khả năng tái lập của toàn bộ quy trình đánh giá.

3.3.5. Kiểm tra warning SMAPE (khi $y_{\text{true}}=0$) và cách xử lý (Discussion)

Trong dữ liệu dịch tễ theo tuần, số ca mắc tại nhiều địa phương thường xuất hiện giá trị bằng 0 (không ghi nhận ca bệnh trong tuần). Khi sử dụng SMAPE (Symmetric Mean Absolute Percentage Error), mẫu số của từng hạng tử có dạng $|y_{\text{true}}| + |y_{\text{pred}}|$. Vì vậy, nếu đồng thời $y_{\text{true}} = 0$ và $y_{\text{pred}} \approx 0$, mẫu số tiến về 0 và có thể phát sinh cảnh báo dạng *invalid value encountered in divide* do phép chia không xác định hoặc nhiễu số học. Đây là hiện tượng kỳ vọng trong bối cảnh dịch tễ nhiều số 0 và không phản ánh lỗi mô hình, mà phản ánh hạn chế kỹ thuật của thước đo SMAPE khi gặp các cặp giá trị rất nhỏ. Để đảm bảo SMAPE vẫn sử dụng được như một chỉ báo hỗ trợ trong miền thực, nghiên cứu áp dụng cơ chế ổn định mẫu số bằng một hằng số rất nhỏ ϵ nhằm tránh chia cho 0:

$$\text{SMAPE}(y, \hat{y}) = \frac{1}{n} \sum_{k=1}^n \frac{2|\hat{y}_k - y_k|}{\max(|y_k| + |\hat{y}_k|, \epsilon)}$$

ổn định số học. Cách làm này giúp tránh lỗi chia 0 và làm cho SMAPE luôn hữu hạn,

đồng thời vẫn giữ được ý nghĩa tỷ lệ sai số tương đối trong trường hợp số ca không quá nhỏ.

Chương 4. Thực nghiệm

4.1. Dữ liệu thực nghiệm và thống kê tập dữ liệu

Bảng 4.1 Thống kê dữ liệu thô theo năm 2010 đến 2024

year	2010	2011	2012	2013	2014	2015	2016	2017	2018	2019	2020	2021	2022	2023	2024
rows	289640	289640	295210	295201	295201	289640	289640	295210	295201	295201	295201	289640	289640	295210	133671
unique_geocodes	5570	5570	5570	5570	5570	5570	5570	5570	5570	5570	5570	5570	5570	5570	5570
unique_epiweeks	52	52	53	53	53	52	52	53	53	53	53	52	52	53	24
resolution_expected_geo_x_week	289640	289640	295210	295210	295210	289640	289640	295210	295210	295210	295210	289640	289640	295210	133680
resolution_actual_pairs	289640	289640	295210	295201	295201	289640	289640	295210	295201	295201	295201	289640	289640	295210	133671
coverage_ratio	1	1	1	0.99997	0.99997	1	1	1	0.99997	0.99997	0.99997	1	1	1	0.999933
casos_mean	4.759412	3.96572	3.243447	6.868662	3.258458	8.299396	7.660789	1.7524	1.639192	7.661136	3.301418	1.826025	4.77711	5.831344	42.86528
casos_median	0	0	0	0	0	0	0	0	0	0	0	0	0	0	1
casos_std	55.09726	55.16916	82.35249	98.63619	46.51951	88.73168	107.6746	22.02907	16.88202	99.85097	37.23538	22.5191	48.56834	63.57823	503.2453
casos_max	5737	7389	14708	15887	7679	12367	16228	3685	1779	15886	4189	2873	4718	6145	48223
casos_zero_rate	0.740119	0.731895	0.771461	0.710055	0.765089	0.663247	0.698771	0.804475	0.815048	0.681028	0.781149	0.838745	0.73638	0.729288	0.44124
casos_q00	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0
casos_q25	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0
casos_q50	0	0	0	0	0	0	0	0	0	0	0	0	0	0	1
casos_q75	1	1	0	1	0	1	1	0	0	1	0	0	1	1	11
casos_q90	4	4	3	6	3	9	8	2	2	8	3	1	5	5	55
casos_q95	13	10	8	18	8	24	21	5	5	20	9	4	13	16	130
casos_q99	80	64.61	49	108	53	133	125	31	29	121	59	31	78	99	608
casos_q100	5737	7389	14708	15887	7679	12367	16228	3685	1779	15886	4189	2873	4718	6145	48223

Bảng 4.2 Thống kê dữ liệu thô từ năm 2010 đến 2024

years_covered	2010-2024
total_rows	4233146
unique_geocodes_total	5570
unique_epiweeks_total	754
unique_years_total	15

unique_geocode_year_week	4233146
casos_mean	5.834458
casos_median	0
casos_std	111.4473
casos_max	48223
casos_zero_rate	0.738051
casos_q00	0
casos_q25	0
casos_q50	0
casos_q75	1
casos_q90	5
casos_q95	14
casos_q99	92
casos_q100	48223

Bảng 4.3 Thống kê chia tập dữ liệu

split	train	val	test
n_weeks	579	104	77
n_nodes	5564	5564	5564
n_features	14	14	14
node_weeks_used	3221556	578656	428428
nan_x	0	0	0
inf_x	0	0	0
nan_y	0	0	0
inf_y	0	0	0
year_min	2010	2021	2023
year_max	2020	2022	2024
epiweek_min	201001	202101	202301
epiweek_max	202053	202252	202424
y_log_min	0	0	0

y_log_p50	0	0	0
y_log_p95	2.564949	2.302585	3.850147
y_log_p99	4.356709	4.007333	5.616771
y_log_max	9.694555	8.459352	10.78361
y_real_min	0	0	0
y_real_p50	0	0	0
y_real_p95	12	9	45.99999
y_real_p99	77.00001	54.00001	274
y_real_max	16228	4718.001	48223.01
y_real_zero_rate	0.742062	0.78749	0.639344

Bảng 4.4 Thống kê theo năm chia tập huấn luyện

year	2010	2011	2012	2013	2014	2015	2016	2017	2018	2019	2020	2021	2022	2023	2024
split	train	train	train	train	train	train	train	train	train	train	train	val	val	test	test
n_weeks	52	52	53	53	53	52	52	53	53	53	53	52	52	53	24
node_weeks_used	2893	2893	2948	2948	2948	2893	2893	2948	2948	2948	2948	2893	2893	2948	1335
y_log_min	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0
y_log_p50	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0.693147
y_log_p95	2.639057	2.397895	2.197225	2.944439	2.197225	3.218876	3.091043	1.791759	1.791759	3.044523	2.302585	1.609438	2.639057	2.833213	4.875197
y_log_p99	4.394449	4.189655	3.912023	4.691348	3.988984	4.89784	4.836282	3.465736	3.401197	4.804021	4.094345	3.465736	4.37863	4.61512	6.412885
y_log_max	8.654866	8.907883	9.596215	9.67332	8.946375	9.422868	9.694555	8.212297	7.484369	9.673257	8.340456	7.96346	8.459352	8.723557	10.78361
y_real_min	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0
y_real_p50	0	0	0	0	0	0	0	0	0	0	0	0	0	0	1
y_real_p95	13	10	8	18	8	24	21	5	5	20	9	4	13	16	130
y_real_p99	80.00001	65.00001	49	108	53	133	125	31	29	121	59	31	78.73	99.99	608.65
y_real_max	5737.001	7388.998	14708.01	15887.01	7679.001	12367	16228	3685.001	1779	15886.01	4189	2873	4718.001	6144.999	48223.01
y_real_zero_rate	0.739839	0.731619	0.771235	0.709772	0.764887	0.663123	0.698605	0.804318	0.814902	0.680798	0.781035	0.838674	0.736306	0.729108	0.441117

Thống kê theo từng năm mô tả sự thay đổi theo thời gian

Bảng 4.5 Thống kê về đồ thị

N_nodes	5564
E_edges	16382
F_features	14
years_start	2010
years_end	2024
snapshots_total	760
deg_mean	2.944284687
deg_p95	7
deg_max	16
isolated_nodes_deg0	854
label_transform	log1p

Bảng 4.6 Thống kê về đặc trưng

feature_index	feature_name
0	temp_med
1	precip_tot
2	rainy_days
3	rel_humid_med
4	POPULACAO
5	altitude
6	area_km2
7	population_density
8	incidence_per_1k
9	humid_heat_index
10	precip_std_roll3
11	dry_spell_len
12	neighbor_cases_prev1
13	incidence_lag1

Tập dữ liệu thực nghiệm được tổ chức theo độ phân giải municipality–tuần dịch tễ với khóa chuẩn hóa (geocode, year, epiweek), nhằm mô hình hóa đồng thời quan hệ không gian–thời gian trong dự báo số ca sốt xuất huyết. Dữ liệu thô bao phủ giai đoạn 2010–

2024 với tổng cộng 4,233,146 bản ghi và 15 năm quan sát (Bảng 4.2). Theo từng năm, dữ liệu có quy mô gần như ổn định ở mức 289,640–295,210 dòng/năm khi năm đó đủ 52–53 tuần, riêng 2024 hiện có 133,671 dòng tương ứng 24 epiweeks (Bảng 4.1). Về không gian, dữ liệu nguồn ghi nhận 5,570 geocodes xuyên suốt các năm (Bảng 4.1–4.2), trong khi tập nút cuối cùng dùng cho mô hình đồ thị được cố định ở 5,564 nodes sau bước đồng bộ với lớp ranh giới hành chính và ánh xạ node2idx để đảm bảo nhất quán chỉ số (Bảng 4.3, 4.5). Mức đầy đủ theo lưới geocode $\times$ epiweek được đánh giá thông qua coverage_ratio, cho thấy dữ liệu tuần gần như đầy đủ với coverage_ratio ≈ 1.0 ở hầu hết các năm (một số năm ~ 0.99997 , và năm 2024 ~ 0.999933), tức số cặp (geocode, epiweek) quan sát được gần bằng số cặp kỳ vọng (Bảng 4.1). Nhân mục tiêu casos thể hiện đặc trưng dịch tễ điển hình: tỷ lệ bằng 0 rất cao (casos_zero_rate toàn kỳ 0.738051; nhiều năm nằm khoảng 0.66–0.84) và phân phối lệch phải với đuôi dài (toàn kỳ q95=14, q99=92, max=48,223) (Bảng 4.2). Do đó, pipeline huấn luyện sử dụng biến đổi log1p (label_transform = log1p) để giảm ảnh hưởng outlier và tăng ổn định tối ưu (Bảng 4.5).

Sau khi chuyển đổi dữ liệu thô thành weekly graph snapshots, tập dữ liệu được chia theo trục thời gian để mô phỏng kịch bản dự báo quá khứ – hiện tại – tương lai train 2010–2020 (579 tuần), val 2021–2022 (104 tuần), và test 2023–2024 (77 tuần) ở (Bảng 4.3). Mỗi snapshot có N=5,564 nodes, F=14 đặc trưng, và dữ liệu sau tiền xử lý không phát hiện lỗi số học (NaN/Inf = 0 cho cả X và y ở mọi split) (Bảng 4.3). Đồ thị không gian dùng chung cho toàn bộ tuần có E=16,382 edges, bậc trung bình deg_mean ≈ 2.94 , bậc cực đại deg_max = 16, và còn 854 nút bậc 0 (isolated_nodes_deg0) cần được lưu ý khi thảo luận về message passing và khả năng lan truyền thông tin (Bảng 4.5). Danh sách đặc trưng đầu vào gồm 14 biến (khí hậu, dân số–địa lý và engineered features) như trong Bảng 4.6.

4.2. Thiết lập thực nghiệm

4.2.1. Môi trường thực nghiệm (Computing Environment)

Bảng 4.7 Môi trường thực nghiệm

Nhóm	Thành phần	Giá trị
Hệ điều hành	OS	Windows 10 (Windows-10-10.0.19045-SP0)
Ngôn ngữ	Python	3.10.11 (tags/v3.10.11:7d4cc5a, Apr 5 2023, MSC v.1929 64-bit)
Thực thi	Python executable	python.exe
Phần cứng	CPU	Intel64 Family 6 Model 94 Stepping 3, GenuineIntel
Phần cứng	Logical cores	8
Phần cứng	RAM	16 GB
Deep Learning	PyTorch	2.4.1 + cpu
Tăng tốc	CUDA	CUDA available = False
Tăng tốc	cuDNN	0
Thư viện	numpy	2.2.6
Thư viện	pandas	2.3.2
Thư viện	scikit-learn	1.7.1
Thư viện	torch	2.4.1 + cpu
Thư viện	torch_geometric	2.6.1
GIS	geopandas	1.1.1
GIS	shapely	2.1.1
GIS	pyproj	3.7.1
Trực quan	matplotlib	3.10.6

4.2.2. Chiến thuật thực nghiệm và cấu hình

Nghiên cứu sử dụng quy trình huấn luyện toàn cục theo tuần (global weekly training), trong đó mỗi tuần tương ứng một snapshot đồ thị $G_t = (V, E)$ với V cố định và E cố

định, còn đặc trưng/nhãn thay đổi theo thời gian. Dữ liệu được chia theo trục thời gian: train (2010–2020), validation (2021–2022), test (2023–2024) nhằm mô phỏng kịch bản dự báo thực tế quá khứ – hiện tại – tương lai và tránh rò rỉ thông tin (data leakage).

Việc tối ưu tham số được thực hiện theo epoch, với cơ chế dừng sớm và lưu checkpoint tốt nhất trên validation. Đầu vào đặc trưng nút: $F = 14$ đặc trưng/node (từ `weekly_pt_scaled`), đầu ra là dự báo $\hat{y}$ trên miền log.

Hàm mất mát: Huber Loss với $\delta = 1.2$, nhằm giảm ảnh hưởng outlier nhưng vẫn giữ độ nhạy với sai số nhỏ. Tối ưu bằng AdamW, có weight decay để giảm overfitting.

Gradient clipping thì ta cắt chuẩn $\|\nabla\|_2 \leq 1.0$ mỗi bước cập nhật để ổn định huấn luyện. Số epoch tối đa: mặc định 200 (trong benchmark).

Mini-batch / batch: không dùng mini-batch theo node; mỗi tuần là một bước huấn luyện (tức batch theo snapshot tuần).

Dừng sớm (Early stopping): patience = 30 epoch dựa trên validation loss; lưu checkpoint tốt nhất. Ghi log hội tụ: ở các mốc 1..10 và mỗi 10 epoch (10, 20, ..., 200).


Siêu tham số theo từng mô hình:

Bảng 4.8 Cấu hình theo từng mô hình

Mô hình	Hidden dim	Dropout	Learning rate	Weight decay
GNN baseline (gnn)	128	0.2	0.0003	0.0001
GCN (gcn)	128	0.2	0.0003	0.0001
ST-GAT (gat)	128	0.2	0.0003	0.0001
Sheaf baseline (sheaf)	128	0.2	0.0003	0.0001
Sheaf-Connection (sheaf_conn)	64	0.2	0.0001	0.0005

Chương 5. Kết quả phân tích và thảo luận

5.1. Tổng quan so sánh các mô hình



Hình 5.1: Tổng quan các mô hình

Mục tiêu của thí nghiệm là đánh giá năng lực dự báo số ca sốt xuất huyết theo tuần trên đồ thị municipalities (chuỗi snapshot theo tuần) bằng cách so sánh năm họ mô hình gồm GNN baseline, GCN, ST-GAT, Sheaf baseline và Sheaf-Connection (sheaf_conn). Kết quả tổng hợp trong Bảng 5.1 cho thấy sheaf_conn đạt hiệu năng tốt nhất một cách nhất quán trên cả tập kiểm định và kiểm thử, đặc biệt trong không gian log (nhãn huấn luyện theo log1p). Cụ thể, best_val_loss của sheaf_conn đạt 0.001606, thấp hơn đáng kể so với ST-GAT (0.0605) và các baseline còn lại (Sheaf: 0.0932, GCN: 0.1321, GNN: 0.2083). Xu hướng này lặp lại ở test_loss_final khi sheaf_conn chỉ 0.007109, trong khi ST-GAT là 0.1486, Sheaf baseline 0.2205, GCN 0.2569 và GNN 0.4414. Các kết quả trên cho thấy sheaf_conn không chỉ fit tốt trên validation mà còn duy trì được chất lượng khi đánh giá trên giai đoạn tương lai (2023–2024), phản ánh khả năng tổng quát hóa

theo thời gian tốt hơn. Ở mức đánh giá theo tuần (macro) trong log-space, sheaf_conn tiếp tục thể hiện ưu thế rõ rệt. Trên validation, sheaf_conn đạt $MAE_{log} = 0.0179$, $RMSE_{log} = 0.0533$, $R^2_{log} = 0.9949$ và $R^2_{trim_{log}} = 0.9981$, trong khi ST-GAT lần lượt đạt $MAE_{log} = 0.1852$, $RMSE_{log} = 0.3419$, $R^2_{log} = 0.7935$, $R^2_{trim_{log}} = 0.8311$. Trên test, khoảng cách vẫn duy trì: sheaf_conn có $MAE_{log} = 0.0422$, $RMSE_{log} = 0.1067$, $R^2_{log} = 0.9662$, $R^2_{trim_{log}} = 0.9704$, vượt đáng kể ST-GAT ($MAE_{log} = 0.318$, $RMSE_{log} = 0.5438$, $R^2_{log} = 0.7584$, $R^2_{trim_{log}} = 0.7921$). Việc trimmed- R^2 của sheaf_conn vẫn cao gần 1.0 cho thấy mô hình không chỉ đúng ở các tuần bình thường, mà còn ổn định hơn trước các tuần có sai số lớn thường gắn với đỉnh dịch hoặc biến động báo cáo, trong khi các baseline suy giảm rõ rệt khi xét tiêu chí bền vững với ngoại lệ.

Trong không gian thực (real-space), các sai số tuyệt đối tăng mạnh ở mọi mô hình do phân phối nhãn có tính lệch phải và đỉnh bùng phát rất lớn ví dụ năm 2024 có max lên tới 48,223 ca/tuần), khiến RMSE chịu tác động mạnh của các tuần cực trị. Dù vậy, sheaf_conn vẫn cho kết quả tốt nhất theo tiêu chí hồi quy thực tế: trên test macro, $MAE_{real} = 8.169$ là thấp hơn rõ rệt so với ST-GAT (14.695) và các baseline khác (Sheaf 15.478, GCN 15.004, GNN 21.956). Về mức giải thích phương sai trong real-space, sheaf_conn đạt $R^2_{real} = 0.5542$, cao hơn ST-GAT (0.2603) và các baseline (Sheaf 0.1496, GCN 0.3147, GNN 0.0860). Đồng thời, $R^2_{trim_{real}} = 0.9420$ của sheaf_conn vượt trội so với ST-GAT (0.4766), Sheaf (0.4437), GCN (0.5206), và đặc biệt GNN cho giá trị âm (-0.292), cho thấy sheaf_conn duy trì chất lượng ngay cả khi giảm ảnh hưởng của các điểm ngoại lệ lớn. Ở đây cần nhấn mạnh rằng real-space metrics mang ý nghĩa diễn giải y tế cộng đồng trực tiếp (sai số số ca), còn log-space metrics phản ánh hiệu quả học trong miền tối ưu hóa và tính ổn định trước phân phối lệch do đó, việc báo cáo song song hai miền là cần thiết để tránh kết luận sai lệch.

Kết quả micro gộp toàn bộ node-week củng cố nhận định trên: sheaf_conn đạt $micro_R^2_{log} = 0.9914$ và $micro_R^2_{trim_{log}} = 0.9963$, cao hơn đáng kể ST-GAT (0.8044 và 0.8413). Trong real-space micro, R^2 tuyệt đối thấp ở tất cả mô hình (sheaf_conn 0.1066, ST-GAT 0.0567, ...) do đây là tiêu chí rất nhạy khi gộp toàn bộ không gian-thời gian và bị chi phối mạnh bởi các đỉnh hiếm vì rằng micro real-space

phản ánh độ khó cực đại của bài toán trên toàn bộ node-week, còn macro theo tuần giúp đánh giá tính ổn định theo thời gian rõ ràng hơn.

Ngoài hồi quy, nghiên cứu còn quy đổi dự báo sang bài toán cảnh báo tuần bùng phát thông qua ngưỡng phân vị $q = 0.9$ trên số ca thực để tính ROC-AUC/PR-AUC. Kết quả cho thấy sheaf_conn gần như đạt mức tối ưu: val_ROC_AUC = 0.9998, val_PR_AUC = 0.9986, và trên test vẫn rất cao (ROC-AUC = 0.9992, PR-AUC = 0.9933), vượt trội so với ST-GAT (test ROC-AUC = 0.9752, PR-AUC = 0.7839) và các baseline. Điều này đặc biệt quan trọng trong bối cảnh dịch tễ vì PR-AUC nhạy với mất cân bằng lớp tuần bùng phát hiếm, do đó kết quả trên hàm ý sheaf_conn có tiềm năng tốt cho mục tiêu cảnh báo sớm chứ không chỉ giảm sai số trung bình.


Tổng hợp lại, Bảng 5.1 và các biểu đồ so sánh macro (log/real) cho thấy: sheaf_conn đạt hiệu năng dẫn đầu ổn định trên val và test ở cả hồi quy và cảnh báo bùng phát, ST-GAT là mô hình mạnh thứ hai, đặc biệt thể hiện tốt hơn các baseline truyền thống (GCN/GNN) và Sheaf baseline, Sheaf baseline cho thấy ý tưởng sheaf có ích nhưng chưa tối ưu bằng biến thể connection trong cấu hình hiện tại. Các quan sát này là cơ sở để phần tiếp theo phân tích sâu về hội tụ (Mục 5.2), biến động theo tuần (Mục 5.3) và so sánh cơ chế giữa ba mô hình chính (Mục 5.4).

Bảng 5.1 So sánh tổng quan các mô hình

model	sheaf_conn	gat	sheaf	gcn	gnn
best_val_loss	0.001606112	0.0605	0.0932	0.1321	0.2083
val_loss_final	0.001606112	0.0605	0.0932	0.1321	0.2083
test_loss_final	0.007109037	0.1486	0.2205	0.2569	0.4414
val_macro_MAE_log	0.017887593	0.1852	0.2162	0.2851	0.4085
val_macro_RMSE_log	0.053332003	0.3419	0.4538	0.5231	0.6963
val_macro_R2_log	0.994932601	0.7935	0.6369	0.5199	0.1632
val_macro_R2trim_log	0.998118409	0.8311	0.7231	0.5712	0.1502
test_macro_MAE_log	0.042211189	0.318	0.3766	0.4632	0.678
test_macro_RMSE_log	0.106674925	0.5438	0.7344	0.7463	1.0524
test_macro_R2_log	0.966165037	0.7584	0.5901	0.5364	0.1448
test_macro_R2trim_log	0.970420136	0.7921	0.687	0.5828	0.176

val_macro_MAE_real	0.770325359	2.5947	3.2245	2.9477	5.0234
val_macro_RMSE_real	14.05476314	23.018	25.272	22.149	26.723
val_macro_SMAPE_real	1.494097692	1.7047	1.724	1.7264	1.7464
val_macro_R2_real	0.835018175	0.3857	0.2249	0.4377	0.0961
val_macro_R2trim_real	0.993542193	0.6572	0.5344	0.6225	-0.96
test_macro_MAE_real	8.168897798	14.695	15.478	15.004	21.956
test_macro_RMSE_real	152.4353034	163.42	167.16	161.22	168.73
test_macro_SMAPE_real	1.217561698	1.5208	1.5545	1.5512	1.6215
test_macro_R2_real	0.554186254	0.2603	0.1496	0.3147	0.086
test_macro_R2trim_real	0.941967778	0.4766	0.4437	0.5206	-0.292
micro_MAE_log	0.042211189	0.318	0.3766	0.4632	0.678
micro_RMSE_log	0.125038222	0.5972	0.8253	0.7918	1.1384
micro_R2_log	0.991426244	0.8044	0.6265	0.6562	0.2894
micro_R2trim_log	0.996283537	0.8413	0.7422	0.7039	0.3646
micro_MAE_real	8.168897798	14.695	15.478	15.004	21.956
micro_RMSE_real	270.815567	278.29	281.42	275.92	282.76
micro_SMAPE_real	1.217561698	1.5208	1.5545	1.5512	1.6215
micro_R2_real	0.10663851	0.0567	0.0353	0.0727	0.0261
micro_R2trim_real	0.97250266	0.4326	0.4418	0.5679	-0.107
val_ROC_AUC	0.99979628	0.9822	0.9594	0.9362	0.8103
val_PR_AUC	0.998554288	0.8909	0.7897	0.6904	0.4161
val_pos_rate	0.108072845	0.1081	0.1081	0.1081	0.1081
test_ROC_AUC	0.999203995	0.9752	0.9349	0.9572	0.8268
test_PR_AUC	0.99328837	0.7839	0.7191	0.73	0.4563
test_pos_rate	0.100980795	0.101	0.101	0.101	0.101
smear_train	1.004166842	1.128	1.6279	1.4137	2.5667
sigma2_train_log	0.003814783	0.1575	0.2738	0.3568	0.6621
cap_train_q999	528	528	528	528	528


5.2. Phân tích hội tụ



Hình 5.2 Biểu đồ tổng hợp sự hội tụ


Hình 5.2 trình bày đường cong mất mát huấn luyện (train loss) và mất mát kiểm định (validation loss) theo số epoch cho toàn bộ các mô hình. Nhìn chung, cả 5 mô hình đều thể hiện xu hướng giảm loss mạnh trong giai đoạn đầu và tiệm cận khi số epoch tăng, cho thấy quá trình tối ưu bằng AdamW với Huber loss có thể hội tụ ổn định trên bộ dữ liệu theo tuần.

Điểm nổi bật nhất là Sheaf-Connection (sheaf_conn) hội tụ nhanh và đạt mức loss rất thấp, với val_loss giảm từ khoảng 0.1291 (epoch 1) xuống khoảng 0.00168 (gần epoch 190–200). Trong khi đó, các mô hình còn lại (GAT/GCN/GNN/Sheaf baseline) hội tụ chậm hơn và dừng ở mức loss cao hơn đáng kể. Xu hướng này phù hợp với quan sát ở phần so sánh hiệu năng (mục 5.1), khi sheaf_conn vượt trội trên cả log-space lẫn real-space. Ngoài ra, GAT cho thấy đường cong val_loss có dao động cục bộ đặc biệt vùng khoảng >100 epoch, phản ánh đặc trưng tối ưu của kiến trúc attention + temporal encoder có thể nhạy hơn với cấu hình học (learning rate/regularization) so với các mô hình tuyến tính hóa hơn như GCN.



Hình 5.3 Hội tụ của từng mô hình

Hình 5.3 thể hiện hội tụ riêng của các mô hình nền (GNN baseline, GCN, GAT, Sheaf baseline), còn Hình 5.4 tập trung vào biến thể Sheaf-Connection. Để mô tả có căn cứ định lượng, Bảng 5.2–5.6 tóm tắt các mốc chính: epoch đầu, epoch đạt val loss tốt nhất, và val loss cuối. Huber loss trên miền log huấn luyện trên $y_{\log} = \log_{1p}(y)$, nên loss nhỏ phản ánh dự báo tốt hơn trong không gian log.



Hình 5.4 Hội tụ của biến thể Sheaf

Bảng 5.2 Sự hội tụ của GNN

model	epoch	train_loss	val_loss	best_val_so_far	elapsed_min
gnn	1	0.302463	0.235016	0.235016	1.836778
gnn	2	0.283117	0.230067	0.230067	3.333039
gnn	3	0.278382	0.227093	0.227093	4.705012
gnn	4	0.275513	0.224873	0.224873	6.08384
gnn	5	0.273619	0.222856	0.222856	7.478933
gnn	6	0.272164	0.221203	0.221203	8.84916
gnn	7	0.271155	0.220346	0.220346	10.25951
gnn	8	0.270311	0.21975	0.21975	11.64856
gnn	9	0.269606	0.219591	0.219591	13.02054
gnn	10	0.269113	0.218937	0.218937	14.39776
gnn	20	0.265211	0.216107	0.216107	28.22033
gnn	30	0.263249	0.214527	0.214527	42.00222
gnn	40	0.261849	0.213961	0.213961	55.81984
gnn	50	0.260754	0.213208	0.213208	69.66461
gnn	60	0.259772	0.213027	0.212581	83.46643
gnn	70	0.259156	0.212478	0.212085	97.19127
gnn	80	0.258476	0.212084	0.211408	111.044
gnn	90	0.257901	0.211424	0.211223	124.8031
gnn	100	0.257425	0.211005	0.211005	138.5665

gnn	110	0.256987	0.21069	0.210549	152.3697
gnn	120	0.256542	0.210053	0.210053	166.2112
gnn	130	0.256202	0.209991	0.209823	179.9773
gnn	140	0.255866	0.209735	0.209735	193.6615
gnn	150	0.255357	0.20943	0.209423	207.4097
gnn	160	0.255102	0.209173	0.209173	221.2618
gnn	170	0.254734	0.209021	0.208913	235.0358
gnn	180	0.25458	0.208358	0.208358	248.7587
gnn	190	0.254208	0.20897	0.208358	262.5111
gnn	200	0.253808	0.208695	0.208342	276.1788

GNN baseline giảm loss nhanh giai đoạn đầu nhưng sớm tiệm cận ở mức tương đối cao, phù hợp vai trò mốc so sánh (baseline) khi không có cơ chế attention hay cấu trúc sheaf/connection để tăng năng lực biểu diễn phụ thuộc không gian–thời gian.

Bảng 5.3 Sự hội tụ của GCN

model	epoch	train_loss	val_loss	best_val_so_far	elapsed_min
gcn	1	0.264509	0.196249	0.196249	1.575952
gcn	2	0.237213	0.18799	0.18799	3.122756
gcn	3	0.229212	0.183751	0.183751	4.63093
gcn	4	0.225103	0.180034	0.180034	6.129085
gcn	5	0.221848	0.177337	0.177337	7.615954
gcn	6	0.218872	0.175089	0.175089	9.113852
gcn	7	0.216099	0.17291	0.17291	10.58893
gcn	8	0.213308	0.171295	0.171295	12.0909
gcn	9	0.210609	0.169252	0.169252	13.58942
gcn	10	0.208189	0.167601	0.167601	15.0774
gcn	20	0.193808	0.156898	0.156898	30.13189
gcn	30	0.186169	0.150362	0.150362	45.12966
gcn	40	0.18179	0.146273	0.146273	60.17472
gcn	50	0.178741	0.143579	0.143579	75.21772
gcn	60	0.176591	0.142197	0.142197	90.24945

gcn	70	0.174906	0.140462	0.140462	105.2586
gcn	80	0.173556	0.139037	0.139037	120.3001
gcn	90	0.172279	0.138144	0.138144	135.3523
gcn	100	0.171137	0.137496	0.137199	150.3625
gcn	110	0.170189	0.136504	0.136347	165.4456
gcn	120	0.16931	0.135747	0.135365	180.4867
gcn	130	0.168605	0.135013	0.134954	195.5047
gcn	140	0.167993	0.134394	0.1343	210.6021
gcn	150	0.167243	0.133799	0.133799	225.6639
gcn	160	0.166576	0.13397	0.133442	240.7074
gcn	170	0.166004	0.133164	0.132899	255.7605
gcn	180	0.165652	0.133269	0.132897	270.8789
gcn	190	0.165077	0.132692	0.132643	285.9465
gcn	200	0.164546	0.132461	0.132148	301.0358

GCN cho đường cong giảm đều và ổn định, ít dao động. Tuy nhiên mức val loss cuối vẫn cao hơn đáng kể so với GAT và đặc biệt là sheaf_conn, cho thấy tổng hợp lân cận kiểu convolution (trung bình/chuẩn hóa) chưa đủ để mô hình hóa các tương tác phức tạp theo thời gian.

Bảng 5.4 Sự hội tụ của GAT

model	epoch	train_loss	val_loss	best_val_so_far	elapsed_min
gat	1	0.227158	0.166496	0.166496	3.184369
gat	2	0.201822	0.156507	0.156507	6.332986
gat	3	0.187652	0.14863	0.14863	9.406157
gat	4	0.180249	0.142405	0.142405	12.49187
gat	5	0.174853	0.13647	0.13647	15.58078
gat	6	0.168901	0.133299	0.133299	18.68976
gat	7	0.164142	0.127949	0.127949	21.80007
gat	8	0.160563	0.120905	0.120905	24.91452
gat	9	0.156682	0.121925	0.120905	27.98358
gat	10	0.154609	0.117846	0.117846	31.06284

gat	20	0.138308	0.107794	0.102441	62.0029
gat	30	0.129713	0.09315	0.092866	92.96374
gat	40	0.125067	0.090851	0.089667	123.9966
gat	50	0.123866	0.084248	0.084248	154.9864
gat	60	0.120263	0.085448	0.084239	186.1919
gat	70	0.117894	0.082714	0.081994	217.2281
gat	80	0.116508	0.08024	0.080044	248.2556
gat	90	0.115614	0.076914	0.076878	279.1078
gat	100	0.111444	0.081762	0.076878	309.9641
gat	110	0.112704	0.080771	0.076431	340.8112
gat	120	0.109326	0.098277	0.073811	371.6764
gat	130	0.107321	0.077326	0.072768	402.5755
gat	140	0.099761	0.072942	0.066331	433.4393
gat	150	0.100128	0.068446	0.065661	464.263
gat	160	0.097512	0.064245	0.063416	495.2086
gat	170	0.09823	0.06651	0.06322	526.1733
gat	180	0.09733	0.07011	0.061285	557.0789
gat	190	0.094928	0.070138	0.061285	587.9652
gat	200	0.095376	0.079051	0.060466	618.8384

GAT đạt val loss tốt nhất ở khoảng epoch 160, sau đó val_loss tăng nhẹ về cuối (≈ 0.079), gợi ý dấu hiệu quá khớp nhẹ hoặc dao động tối ưu. Điều này phù hợp với bản chất mô hình có nhiều bậc tự do (temporal encoder + multi-head attention + 2 tầng GATConv). Trong thực nghiệm kết quả này củng cố vai trò của early stopping (lưu checkpoint tốt nhất theo validation) để chọn mô hình tổng quát hóa tốt.

Bảng 5.5 Sự hội tụ của Sheaf Baseline

Model	epoch	train_loss	val_loss	best_val_so_far	elapsed_min
sheaf	1	0.300833	0.225958	0.225958	2.684146
sheaf	2	0.259467	0.208534	0.208534	5.300134
sheaf	3	0.211305	0.178156	0.178156	7.921365
sheaf	4	0.181146	0.15261	0.15261	10.52434

sheaf	5	0.16542	0.138513	0.138513	13.1356
sheaf	6	0.157773	0.130532	0.130532	15.70681
sheaf	7	0.152906	0.130503	0.130503	18.29969
sheaf	8	0.149087	0.125725	0.125725	20.88575
sheaf	9	0.145387	0.123965	0.123965	23.48274
sheaf	10	0.141705	0.120425	0.120425	26.06786
sheaf	20	0.128949	0.108349	0.108349	52.00194
sheaf	30	0.1254	0.106637	0.106382	77.86606
sheaf	40	0.123721	0.107022	0.105764	103.6496
sheaf	50	0.123113	0.102962	0.102962	129.5158
sheaf	60	0.122176	0.101613	0.100923	155.573
sheaf	70	0.120358	0.101672	0.099674	183.0317
sheaf	80	0.119488	0.099479	0.097621	209.9517
sheaf	90	0.118261	0.100645	0.097621	235.7347
sheaf	100	0.117603	0.099183	0.09681	261.3087
sheaf	110	0.117138	0.095549	0.095549	288.0396
sheaf	120	0.116732	0.096792	0.095549	314.3799
sheaf	130	0.116546	0.094946	0.094946	344.027
sheaf	140	0.115626	0.095864	0.094699	370.8896
sheaf	150	0.11559	0.097479	0.094699	397.1462
sheaf	160	0.116209	0.098174	0.094699	423.4282
sheaf	170	0.115259	0.095074	0.093505	452.3932
sheaf	180	0.115038	0.096403	0.093505	481.783
sheaf	190	0.114922	0.09626	0.093212	511.5831
sheaf	200	0.114566	0.096476	0.093212	542.2535

Sheaf baseline giảm nhanh ở giai đoạn đầu và ổn định quanh mức ~ 0.095 – 0.10 . So với GAT, sheaf baseline hội tụ êm hơn nhưng mức loss tốt nhất kém hơn, cho thấy phiên bản sheaf baseline hiện tại có thể bị hạn chế về biểu diễn hoặc tối ưu, đặc biệt khi không khai thác temporal context một cách mạnh như ST-GAT.

Bảng 5.6 Sự hội tụ biến thể Sheaf Connection Neural Network

model	epoch	train_loss	val_loss	best_val_so_far	elapsed_min
sheaf_conn	1	0.248489	0.129054	0.129054	1.937625
sheaf_conn	2	0.130956	0.099358	0.099358	3.828801
sheaf_conn	3	0.102334	0.081727	0.081727	5.651708
sheaf_conn	4	0.087406	0.069246	0.069246	7.454691
sheaf_conn	5	0.07719	0.060642	0.060642	9.252074
sheaf_conn	6	0.069426	0.054002	0.054002	11.04398
sheaf_conn	7	0.063171	0.048805	0.048805	12.86027
sheaf_conn	8	0.057881	0.044398	0.044398	14.66923
sheaf_conn	9	0.053183	0.040766	0.040766	16.46627
sheaf_conn	10	0.049229	0.037616	0.037616	18.25024
sheaf_conn	20	0.027825	0.020014	0.020014	36.11143
sheaf_conn	30	0.019585	0.012609	0.012609	54.05463
sheaf_conn	40	0.015492	0.009104	0.009104	71.90053
sheaf_conn	50	0.013141	0.006943	0.006943	89.74445
sheaf_conn	60	0.011718	0.005578	0.005578	107.5588
sheaf_conn	70	0.010611	0.004638	0.004638	125.415
sheaf_conn	80	0.009886	0.004365	0.00415	143.2945
sheaf_conn	90	0.00934	0.003797	0.003753	161.1586
sheaf_conn	100	0.008884	0.003163	0.003163	179.0224
sheaf_conn	110	0.00858	0.003164	0.003047	196.8508
sheaf_conn	120	0.008284	0.002879	0.002699	214.747
sheaf_conn	130	0.008036	0.002484	0.002484	232.5425
sheaf_conn	140	0.007872	0.002386	0.002276	250.3331
sheaf_conn	150	0.007648	0.002207	0.002207	268.2689
sheaf_conn	160	0.007482	0.002075	0.001972	286.1408
sheaf_conn	170	0.007324	0.001989	0.001782	304.0783
sheaf_conn	180	0.007189	0.001694	0.001694	321.9295
sheaf_conn	190	0.007067	0.001681	0.001649	339.8028
sheaf_conn	200	0.006983	0.001683	0.001606	357.6777

Sheaf-Connection thể hiện hội tụ vượt trội: loss giảm rất mạnh trong $\sim 20-50$ epoch đầu, sau đó tiếp tục giảm chậm và ổn định đến cuối. Mức $\text{val_loss} \approx 0.00168$ là rất thấp so với các mô hình còn lại, cho thấy biến thể connection-style (restriction/rotation theo cạnh + residual + layer norm + temporal context) đã tạo ra cơ chế lan truyền thông tin và ép nhất quán (consistency) hiệu quả hơn trên đồ thị municipalities theo tuần.

5.3. Phân tích theo tuần

Bảng 5.7 Bảng thông số theo tuần

model	sheaf_conn	gat	sheaf	gcn	gnn
best_val_loss	0.001606112	0.060466	0.093212	0.132148	0.208342
val_loss_final	0.001606112	0.060466	0.093212	0.132148	0.208342
test_loss_final	0.007109037	0.14856	0.220472	0.256897	0.441381
val_macro_MAE_log	0.017887593	0.185173	0.216193	0.285112	0.408511
val_macro_RMSE_log	0.053332003	0.34193	0.45383	0.523065	0.696294
val_macro_R2_log	0.994932601	0.793515	0.636915	0.519896	0.163205
test_macro_MAE_log	0.042211189	0.318019	0.376576	0.463215	0.678
test_macro_RMSE_log	0.106674925	0.543808	0.734361	0.746311	1.052414
test_macro_R2_log	0.966165037	0.758433	0.590098	0.536383	0.144799
val_macro_MAE_real	0.770325359	2.594694	3.224523	2.947746	5.023411
val_macro_RMSE_real	14.05476314	23.0178	25.27151	22.14891	26.72315
val_macro_R2_real	0.835018175	0.385727	0.22494	0.437718	0.096086
test_macro_MAE_real	8.168897798	14.69452	15.47771	15.00417	21.95629
test_macro_RMSE_real	152.4353034	163.4183	167.1559	161.2176	168.7292
test_macro_R2_real	0.554186254	0.260275	0.14955	0.314692	0.086017
val_PR_AUC	0.998554288	0.890878	0.78969	0.690448	0.416132
test_PR_AUC	0.99328837	0.783863	0.719055	0.730001	0.456318
val_ROC_AUC	0.99979628	0.98217	0.959393	0.936192	0.81031
test_ROC_AUC	0.999203995	0.975248	0.934931	0.957186	0.826782
weekly_test_MAE_log_mean	0.042211189	0.318019	0.376576	0.463215	0.678
weekly_test_MAE_log_std	0.03421664	0.172226	0.22748	0.218506	0.341342
weekly_test_MAE_log_median	0.027023497	0.261101	0.288789	0.41621	0.595668
weekly_test_RMSE_log_mean	0.106674925	0.543808	0.734361	0.746311	1.052414
weekly_test_RMSE_log_std	0.065658239	0.248553	0.378987	0.266208	0.436778
weekly_test_RMSE_log_median	0.076775918	0.474697	0.608142	0.719047	0.996895
weekly_test_R2_log_mean	0.966165037	0.758433	0.590098	0.536383	0.144799

weekly_test_R2_log_std	0.158898478	0.137274	0.164102	0.111824	0.07167
weekly_test_R2_log_median	0.994320163	0.801348	0.666611	0.552622	0.163404
weekly_test_R2trim_log_mean	0.970420136	0.792094	0.686963	0.582791	0.176037
weekly_test_R2trim_log_std	0.159532248	0.139365	0.136685	0.112815	0.070254
weekly_test_R2trim_log_median	0.997383036	0.830753	0.734324	0.595446	0.176552
weekly_test_MAE_real_mean	8.168897798	14.69452	15.47771	15.00417	21.95629
weekly_test_MAE_real_std	12.51952409	19.62124	19.88995	19.55818	27.81272
weekly_test_MAE_real_median	1.49054809	4.990216	5.490885	5.232227	8.334494
weekly_test_RMSE_real_mean	152.4353034	163.4183	167.1559	161.2176	168.7292
weekly_test_RMSE_real_std	225.3082777	226.7277	227.8843	225.3879	228.3823
weekly_test_RMSE_real_median	27.19079566	39.83243	45.35178	37.07409	46.19882
weekly_test_SMAPE_real_mean	1.217561698	1.520807	1.554549	1.551207	1.621468
weekly_test_SMAPE_real_std	0.359366091	0.238717	0.215582	0.229372	0.162309
weekly_test_SMAPE_real_median	1.306390624	1.577222	1.602605	1.612551	1.652628
weekly_test_R2_real_mean	0.554186254	0.260275	0.14955	0.314692	0.086017
weekly_test_R2_real_std	0.352951892	0.184145	0.124467	0.215566	0.069557
weekly_test_R2_real_median	0.614904796	0.24215	0.109135	0.30914	0.077814
weekly_test_R2trim_real_mean	0.941967778	0.476592	0.443701	0.520568	-0.29154
weekly_test_R2trim_real_std	0.161010186	0.231736	0.194366	0.183973	0.369866
weekly_test_R2trim_real_median	0.98825055	0.489956	0.467026	0.544931	-0.19164
weekly_val_MAE_log_mean	0.017887593	0.185173	0.216193	0.285112	0.408511
weekly_val_MAE_log_std	0.011600321	0.079636	0.093194	0.137587	0.18526
weekly_val_MAE_log_median	0.013490459	0.152984	0.181949	0.242844	0.34348
weekly_val_RMSE_log_mean	0.053332003	0.34193	0.45383	0.523065	0.696294
weekly_val_RMSE_log_std	0.01939135	0.120832	0.156318	0.172954	0.249874
weekly_val_RMSE_log_median	0.046810504	0.30651	0.414145	0.486049	0.637045
weekly_val_R2_log_mean	0.994932601	0.793515	0.636915	0.519896	0.163205
weekly_val_R2_log_std	0.001633481	0.042782	0.055323	0.051126	0.04529
weekly_val_R2_log_median	0.995078516	0.800817	0.650448	0.528279	0.160205
weekly_val_R2trim_log_mean	0.998118409	0.831106	0.723105	0.571179	0.150215
weekly_val_R2trim_log_std	0.000689821	0.034192	0.041258	0.045138	0.09268
weekly_val_R2trim_log_median	0.998326155	0.836722	0.73331	0.576318	0.165305
weekly_val_MAE_real_mean	0.770325359	2.594694	3.224523	2.947746	5.023411
weekly_val_MAE_real_std	1.220258481	3.305421	3.281552	3.346146	4.691194
weekly_val_MAE_real_median	0.222445695	1.300787	1.967317	1.623018	3.154419
weekly_val_RMSE_real_mean	14.05476314	23.0178	25.27151	22.14891	26.72315

weekly_val_RMSE_real_std	18.86258226	23.50593	24.50279	22.83072	25.85346
weekly_val_RMSE_real_median	3.185953363	11.81664	13.96494	11.3485	15.16425
weekly_val_SMAPE_real_mean	1.494097692	1.704741	1.723966	1.726355	1.74641
weekly_val_SMAPE_real_std	0.225145954	0.152548	0.138999	0.137093	0.112489
weekly_val_SMAPE_real_median	1.570292159	1.753584	1.769099	1.771994	1.778607
weekly_val_R2_real_mean	0.835018175	0.385727	0.22494	0.437718	0.096086
weekly_val_R2_real_std	0.170626894	0.139413	0.10893	0.145946	0.08428
weekly_val_R2_real_median	0.926416219	0.397775	0.220086	0.465438	0.079538
weekly_val_R2trim_real_mean	0.993542193	0.657218	0.53437	0.622495	-0.96048
weekly_val_R2trim_real_std	0.005568665	0.131261	0.143908	0.127474	1.372722
weekly_val_R2trim_real_median	0.995267383	0.69199	0.54354	0.635991	-0.29331
epoch_log_last_epoch	200	200	200	200	200
epoch_log_last_train_loss	0.006983251	0.095376	0.114566	0.164546	0.253808
epoch_log_last_val_loss	0.00168346	0.079051	0.096476	0.132461	0.208695
epoch_log_best_val_loss	0.001681394	0.064245	0.094946	0.132461	0.208358
epoch_log_last_elapsed_min	357.677744	618.8384	542.2535	301.0358	276.1788

Khác với các chỉ số micro gộp tất cả node-week và macro trung bình theo tuần, phân tích theo tuần nhằm đánh giá độ ổn định theo thời gian của mô hình, đặc biệt trong bối cảnh dengue có tính mùa vụ, bùng phát theo đợt và phân phối nhãn lệch phải. Do đó, ngoài giá trị trung bình theo tuần, nghiên cứu báo cáo thêm độ lệch chuẩn (std) và trung vị (median) của các metric theo tuần trên hai tập validation và test. Ngược lại, các mô hình còn lại có sai số theo tuần lớn hơn đáng kể: GAT (MAE_log_mean $\approx$ 0.318, R2_log_mean $\approx$ 0.758), Sheaf baseline (MAE_log_mean $\approx$ 0.377, R2_log_mean $\approx$ 0.590), GCN (MAE_log_mean $\approx$ 0.463, R2_log_mean $\approx$ 0.536) và GNN baseline kém nhất (MAE_log_mean $\approx$ 0.678, R2_log_mean $\approx$ 0.145). Xu hướng tương tự lặp lại trên tập validation, trong đó sheaf_conn vẫn duy trì weekly_val_R2_log_mean $\approx$ 0.995 với std rất nhỏ ($\approx$ 0.00163), phản ánh tính ổn định cao theo thời gian ngay trên giai đoạn kiểm định. Ngoài R² chuẩn, chỉ số trimmed-R² theo tuần cũng được dùng để giảm ảnh hưởng các outlier tuần bùng phát cực đoan. Trên test, sheaf_conn đạt weekly_test_R2trim_log_mean $\approx$ 0.9704 và median $\approx$ 0.9974, củng cố nhận định rằng hiệu năng cao không chỉ đến từ vài tuần dễ, mà mang tính nhất quán trên phần lớn các tuần. Khi chuyển về miền số ca thực (real-space), sai số tuyệt đối chịu tác động mạnh của các tuần bùng phát đặc trưng đỉnh nhọn của dengue. Điều này thể hiện rõ qua việc RMSE_real theo tuần có độ lệch chuẩn rất lớn ở tất cả mô hình trên test, ví dụ

$\text{weekly_test_RMSE_real_std} \approx 225\text{--}228$, cho thấy có những tuần mà sai số bình phương tăng mạnh do vài đô thị có ca bệnh cực cao. Dù vậy, `sheaf_conn` vẫn giữ lợi thế rõ rệt về MAE_real theo tuần trên test: $\text{weekly_test_MAE_real_mean} = 8.17$, $\text{median} = 1.49$, thấp hơn đáng kể so với GAT ($\text{mean} = 14.69$, $\text{median} = 4.99$) và các mô hình còn lại. Khoảng cách giữa mean và median (đặc biệt ở test) phản ánh đúng bản chất: phần lớn tuần có sai số nhỏ, nhưng một số tuần bùng phát gây đuôi dài làm tăng trung bình. Về SMAPE theo tuần (thước đo phù hợp khi dữ liệu có nhiều giá trị nhỏ/0), `sheaf_conn` đạt $\text{weekly_test_SMAPE_real_mean} = 1.218$ thấp hơn GAT (1.521) và các mô hình còn lại, cho thấy mô hình không chỉ giảm sai số tuyệt đối mà còn cải thiện tương đối theo quy mô ca bệnh. Ở góc nhìn R^2_real theo tuần, mức trung bình thường thấp hơn log-space do real-space phóng đại sai số tại các đỉnh. Tuy nhiên, `sheaf_conn` vẫn đạt $\text{weekly_test_R2_real_mean} \approx 0.554$ ($\text{median} \approx 0.615$), cao nhất trong nhóm. Trong khi GAT (≈ 0.260), GCN (≈ 0.315), Sheaf baseline (≈ 0.150) và GNN (≈ 0.086) thấp hơn đáng kể. Đặc biệt, trimmed-R^2_real theo tuần giúp bảo vệ khỏi outlier: `sheaf_conn` vẫn giữ $\text{weekly_test_R2trim_real_mean} \approx 0.942$, thể hiện khả năng khớp tốt trên phần lõi của phân phối. Trong vận hành y tế cộng đồng, nhu cầu quan trọng là phát hiện sớm tuần bất thường (hot weeks) hơn là chỉ giảm sai số trung bình. Do đó nghiên cứu chuyển bài toán hồi quy thành tín hiệu nhị phân dựa trên ngưỡng phân vị ($q = 0.90$) và báo cáo ROC-AUC, PR-AUC. Kết quả cho thấy `sheaf_conn` đạt hiệu năng cảnh báo vượt trội:

- Validation: ROC-AUC = 0.9998, PR-AUC = 0.9986
- Test: ROC-AUC = 0.9992, PR-AUC = 0.9933

Trong khi đó, GAT vẫn khá mạnh nhưng thấp hơn rõ rệt trên test ($\text{PR-AUC} \approx 0.784$), còn GNN baseline kém nhất ($\text{PR-AUC} \approx 0.456$). Vì PR-AUC nhạy với mất cân bằng lớp (tỷ lệ tuần “hot” thấp), kết quả này gợi ý `sheaf_conn` không chỉ khớp tốt trung bình, mà còn giữ được chất lượng cảnh báo trong các tuần hiếm gặp nhưng quan trọng về dịch tễ.

5.4. Kiểm chứng độ hợp lệ của thực nghiệm


5.4.1. Kiểm định hoán vị nhãn - Permutation Test

model	sheaf_conn	sheaf_conn	sheaf_conn	sheaf_conn	sheaf_conn
perm_run	1	2	3	4	5
perm_seed	1123	1124	1125	1126	1127
perm_epochs	10	10	10	10	10
base_val_R2_log	0.995578	0.995578	0.995578	0.995578	0.995578
base_test_R2_log	0.991426	0.991426	0.991426	0.991426	0.991426
perm_val_R2_log	0.10109	0.100785	0.099227	0.099279	0.099557
perm_test_R2_log	0.02799	0.028276	0.025359	0.024577	0.028279
perm_val_MAE_log	0.475972	0.474809	0.476374	0.477076	0.476444
perm_test_MAE_log	0.786007	0.785175	0.787133	0.788857	0.786886

Bảng 5.8 Kiểm định hoán vị nhãn

Bảng 5.8 trình bày kết quả kiểm định hoán vị nhãn (Permutation Test) nhằm đánh giá nguy cơ mô hình đạt hiệu năng cao do shortcut/leakage thay vì học quan hệ thực giữa đặc trưng và nhãn. Trên mô hình Sheaf-Connection (sheaf_conn), hiệu năng baseline trên tập kiểm định/kiểm thử đạt mức rất cao (ví dụ $R_{\log}^2$ xấp xỉ 0.99). Tuy nhiên, khi hoán vị ngẫu nhiên nhãn trong tập train và huấn luyện nhanh trong 10 epoch thực hiện 5 lần với các seed khác nhau, các chỉ số trên val/test suy giảm mạnh và ổn định qua các lần chạy: $R_{\log}^2$ giảm về mức gần 0 (khoảng 0.10 trên validation và khoảng 0.02–0.03 trên test), trong khi $MAE_{\log}$ và $RMSE_{\log}$ tăng lên đáng kể so với baseline. Kết quả này cho thấy mô hình không thể duy trì hiệu năng khi mối liên hệ $X \rightarrow y$ bị phá vỡ, từ đó củng cố rằng pipeline huấn luyện–đánh giá không có dấu hiệu rò rỉ thông tin nhãn rõ rệt và hiệu năng quan sát được chủ yếu đến từ tín hiệu dự báo thực trong dữ liệu.

5.5. Ý nghĩa diễn giải dịch tễ



Hình 5.5 Công cụ trực quan hóa

Thông qua đó nghiên cứu có thể trực quan hóa Biome và các thông số mạng lưới Brazil, dự đoán và khoan vùng dịch bệnh, thiết lập dự đoán sai số và khoan vùng dịch bệnh, thiết lập từng lớp cài đặt, thể hiện rõ sự trực quan hóa và cảm quan hóa dành cho cán bộ nhân viên y tế đưa ra quyết định kịp thời. Bảng điều khiển (dashboard) được thiết kế như một công cụ trực quan hóa đa lớp để hỗ trợ cả cán bộ y tế và người dùng chuyên môn phân tích dữ liệu theo dõi, so sánh và diễn giải diễn biến sốt xuất huyết theo không gian–thời gian. Giao diện cung cấp hệ tham số điều khiển ở panel bên trái cho phép lựa chọn năm/tuần dịch tễ, lọc và hiển thị Top-5 địa phương bùng phát, đồng thời tùy biến chế độ hiển thị bằng nhiều bảng màu (nhấn điểm nóng, đơn sắc đỏ/xanh tăng dần, và chế độ thân thiện với người mù màu). Trên bản đồ, người dùng có thể bật/tắt các lớp như số ca thực tế (Truth), dự báo (Prediction), sai số (Error), cùng các lớp hỗ trợ (mật độ dân số, điểm/nút, cạnh liên kết, sinh cảnh/biome) để quan sát đồng thời tín hiệu dịch tễ và bối cảnh nền. Trục thời gian một chiều giúp đọc mạch diễn tiến theo tuần, trong khi thang màu và thanh chú giải cho phép định lượng nhanh cường độ. Nhờ cơ chế hiển thị theo lớp và theo thời điểm, dashboard hỗ trợ phát hiện điểm nóng, quan sát cụm lan truyền theo vùng lân cận, và kiểm tra mức nhất quán giữa dự báo – thực tế nhằm phục vụ cảnh báo sớm và ra quyết định can thiệp.

Chương 6. Kết luận

6.1. Kết luận chính từ kết quả thực nghiệm

6.1.1. Kết luận theo log-space (MAE/RMSE/R²/trimmed-R²)

Trong miền log-space, là miền huấn luyện chính của mô hình, kết quả cho thấy sheaf_conn vượt trội nhất quán và rất rõ ràng. Trên validation, mô hình này đạt:

$\text{val_macro_MAE_log} = 0.0179$, $\text{val_macro_RMSE_log} = 0.0533$;

$\text{val_macro_R2_log} = 0.9949$, $\text{val_macro_R2trim_log} = 0.9981$;

Trên test, tiếp tục đạt $\text{test_macro_MAE_log} = 0.0422$, $\text{test_macro_RMSE_log} = 0.1067$, $\text{test_macro_R2_log} = 0.9662$, $\text{test_macro_R2trim_log} = 0.9704$. Đây là khoảng cách hiệu năng rất lớn so với mô hình đứng thứ hai là ST-GAT ($\text{test_macro_R2_log} = 0.7584$) và càng lớn hơn so với Sheaf baseline, GCN và GNN. Vì log-space là miền tối ưu hóa trực tiếp, kết quả này cho phép kết luận rằng sheaf_conn là mô hình học được cấu trúc quy luật tốt nhất trên dữ liệu dengue theo tuần. Đặc biệt, trimmed-R² luôn cao hơn R² thông thường nhưng vẫn giữ khoảng cách ưu thế cho sheaf_conn, cho thấy mô hình không chỉ hoạt động tốt ở phần của phân phối chuẩn, mà còn giữ được chất lượng khi giảm ảnh hưởng của các ngoại lệ. Kết quả micro cũng củng cố điều đó, với $\text{micro_R2_log} = 0.9914$ và $\text{micro_R2trim_log} = 0.9963$, chứng tỏ năng lực khớp rất mạnh trên toàn bộ node-week. Từ đó, có thể kết luận ở cấp độ phương pháp rằng: cấu trúc connection-style dựa trên restriction map theo cạnh và giảm disagreement có khả năng mô hình hóa quan hệ không gian–thời gian trong log-space tốt hơn attention graph thông thường và tốt hơn các baseline convolution/message passing cổ điển.

6.1.2. Kết luận theo real-space (MAE/RMSE/SMAPE/R²/trimmed-R²)

Trong miền số ca thực tế (real-space), các mô hình đều chịu tác động mạnh bởi phân phối nhân có đuôi dài và các tuần bùng phát cực trị. Vì vậy, sai số tuyệt đối và RMSE cao hơn đáng kể là hiện tượng phù hợp với bản chất dữ liệu, không phải mâu thuẫn với kết quả tốt ở log-space. Tuy vậy, sheaf_conn vẫn là mô hình mạnh nhất trong real-space. Cụ thể, trên test macro, sheaf_conn đạt $\text{MAE_real} = 8.17$, $\text{RMSE_real} = 152.44$,

$\text{SMAPE_real} = 1.218$, $\text{R2_real} = 0.5542$, $\text{R2trim_real} = 0.9420$, tốt hơn rõ rệt so với ST-GAT ($\text{R2_real} = 0.2603$, $\text{R2trim_real} = 0.4766$) và các baseline còn lại. Điều này cho thấy khi quy đổi về số ca thực, sheaf_conn không chỉ dự báo tốt theo nghĩa thống kê, mà còn giữ được ý nghĩa thực tiễn hơn đối với giám sát dịch tễ. Dù RMSE vẫn lớn, median của các chỉ số weekly real-space lại thấp hơn nhiều so với mean, chứng tỏ phần lớn các tuần được dự báo khá tốt, và chỉ một số tuần cực trị làm tăng trung bình sai số. Một kết luận quan trọng ở đây là: đối với dữ liệu dengue, real-space không nên được diễn giải riêng lẻ bằng RMSE, mà cần đặt cùng MAE, SMAPE và đặc biệt là trimmed- R^2 . Khi làm như vậy, sheaf_conn tiếp tục chứng minh tính vượt trội. Như vậy, kết quả real-space xác nhận rằng mô hình tốt trong log-space không chỉ hiệu quả về mặt tối ưu hóa, mà còn mang lại giá trị thực tiễn khi quy đổi ngược sang số ca bệnh.

6.1.3. Kết luận về hội tụ và độ ổn định (epoch log & convergence plots)

Các đường hội tụ cho thấy tất cả mô hình đều có thể giảm loss theo epoch, nghĩa là pipeline dữ liệu, tối ưu hóa và huấn luyện là hợp lệ. Tuy nhiên, mức độ hội tụ khác nhau rất rõ giữa các họ mô hình: GNN baseline hội tụ nhanh nhưng dừng sớm ở mức loss cao, phản ánh giới hạn biểu diễn. GCN hội tụ đều, ổn định hơn GNN nhưng không đạt mức loss thấp. ST-GAT đạt mức loss tốt hơn GCN/GNN, song validation loss dao động hơn về cuối, cho thấy mô hình mạnh nhưng nhạy hyperparameter. Sheaf baseline hội tụ tương đối ổn định nhưng vẫn dừng ở vùng loss cao hơn GAT. Sheaf-Connection hội tụ tốt nhất, với $\text{epoch_log_best_val_loss} \approx 0.00168$, thấp hơn rất lớn so với GAT (0.0642), Sheaf (0.0949), GCN (0.1325) và GNN (0.2084). Từ đó có thể kết luận rằng sheaf_conn không chỉ mạnh về kết quả cuối, mà còn mạnh về tính ổn định của quá trình học. Cơ chế residual, LayerNorm, temporal context và connection-style update đã giúp mô hình hội tụ sâu hơn mà không tạo ra dao động lớn như attention-heavy model. Đây là một điểm rất quan trọng ở cấp độ nghiên cứu: mô hình tốt không chỉ là mô hình có metric cao, mà còn là mô hình có quá trình học đáng tin cậy và tái lập được.

6.1.4. Kết luận về khả năng tổng quát hóa theo thời gian

Vì dữ liệu được chia theo thời gian chặt chẽ (train 2010–2020, val 2021–2022, test 2023–2024), hiệu năng trên test phản ánh trực tiếp năng lực tổng quát hóa sang tương

lai. Trong bối cảnh đó, sheaf_conn vẫn duy trì $\text{test_macro_R2_log} = 0.9662$ và $\text{test_macro_R2_real} = 0.5542$, tức mức suy giảm từ validation sang test là có nhưng vẫn nhỏ hơn rõ rệt so với các mô hình khác. Đặc biệt, phân tích theo tuần cho thấy sheaf_conn giữ được $\text{weekly_test_R2_log_mean} = 0.9662$ với $\text{median} = 0.9943$, cùng $\text{PR-AUC} = 0.9933$ trên test cho nhiệm vụ tuần bùng phát. Điều này chứng minh mô hình không chỉ khớp tốt các xu hướng đã thấy trong train, mà còn chuyển tải được quy luật sang giai đoạn dịch tễ tương lai có mức độ khó cao hơn, nhất là năm 2024 với đỉnh dịch lớn. Do đó, có thể kết luận rằng sheaf_conn có khả năng tổng quát hóa theo thời gian tốt nhất trong benchmark, và kết quả này đặc biệt có ý nghĩa đối với bài toán ứng dụng thực tế, nơi mô hình luôn phải dự báo cho các tuần chưa từng quan sát.

6.2. Kết luận theo từng họ mô hình

6.2.1. GNN baseline: vai trò mốc so sánh và giới hạn

GNN baseline hoàn thành tốt vai trò của một mô hình đối chứng cơ sở. Mô hình này chứng minh rằng chỉ với message passing đơn giản, dữ liệu đồ thị đã cung cấp tín hiệu tốt hơn nhiều so với cách tiếp cận phi đồ thị. Tuy nhiên, các kết quả cho thấy GNN baseline có hiệu năng thấp nhất hoặc gần thấp nhất trên hầu hết các metric, đặc biệt ở test macro/log-space ($\text{R2_log} = 0.1448$) và real-space ($\text{R2_real} = 0.0860$). Điều đó phản ánh giới hạn: tổng hợp lân cận kiểu trung bình không đủ để biểu diễn các phụ thuộc không gian–thời gian phức tạp của dengue. Vì vậy, GNN baseline phù hợp như một mốc tối thiểu, nhưng không đủ mạnh cho mục tiêu dự báo dịch có độ biến động cao.

6.2.2. GCN: cải thiện nhờ tổng hợp lân cận, khi nào hiệu quả

GCN cho thấy bước cải thiện rõ so với GNN baseline nhờ sử dụng graph convolution có chuẩn hóa theo bậc. Kết quả test macro/log-space ($\text{R2_log} = 0.5364$) và real-space ($\text{R2_real} = 0.3147$) cho thấy mô hình đã tận dụng được cấu trúc lân cận tốt hơn. Tuy vậy, GCN vẫn bị giới hạn bởi cơ chế tổng hợp tương đối đồng đều giữa các láng giềng, nên khó nắm bắt các quan hệ dị thể mạnh giữa các vùng. Mô hình này phù hợp khi cần một baseline đồ thị ổn định, dễ huấn luyện, và có chất lượng trung bình khá; nhưng chưa phải lựa chọn tối ưu cho bài toán dengue liên vùng có mùa vụ và cực trị rõ rệt.

6.2.3. ST-GAT: lý do mạnh trong bối cảnh không gian–thời gian

ST-GAT là mô hình mạnh thứ hai trong toàn bộ benchmark. Sức mạnh của nó đến từ việc kết hợp hai thành phần: temporal encoder (GRU + attention theo chuỗi) và GATConv để học attention không gian. Điều này giúp mô hình thích ứng linh hoạt với ảnh hưởng không đồng đều giữa các địa phương và nắm bắt trễ thời gian trong lan truyền bệnh. Kết quả của ST-GAT trên test macro/log-space ($R2_{log} = 0.7584$) và PR-AUC (0.7839) cho thấy đây là một lựa chọn rất mạnh nếu xét trong nhóm các mô hình attention phổ biến. Tuy nhiên, so với sheaf_conn, ST-GAT vẫn kém hơn đáng kể cả về metric lẫn độ ổn định hội tụ, cho thấy attention truyền thống dù mạnh nhưng chưa khai thác tối đa được cấu trúc liên vùng có phép biến đổi theo cạnh.

6.2.4. Sheaf baseline: nhận định về hiệu năng và độ khó tối ưu

Sheaf baseline mang giá trị nghiên cứu rõ rệt vì nó đưa ý tưởng edge-dependent transformation vào bài toán dịch tễ đồ thị. Kết quả của mô hình này tốt hơn GNN baseline, cạnh tranh với GCN ở một số tiêu chí, nhưng vẫn thấp hơn ST-GAT và thấp hơn đáng kể so với sheaf_conn. Điều này cho thấy hướng sheaf là hợp lý, nhưng phiên bản baseline hiện tại chưa đủ mạnh hoặc chưa đủ ổn định để khai thác hết lợi ích của biểu diễn theo cạnh. Nói cách khác, ý tưởng sheaf là đúng hướng, nhưng implementation baseline vẫn khó tối ưu và chưa tạo được lợi thế quyết định.

6.2.5. Sheaf-Connection (sheaf_conn): mức độ phù hợp với cấu trúc liên vùng

Sheaf-Connection là mô hình đạt kết quả tốt nhất ở mọi nhóm chỉ số quan trọng: loss, log-space, real-space, PR-AUC/ROC-AUC, hội tụ và ổn định theo tuần. Điều đó cho thấy kiến trúc connection-style với restriction map nhỏ theo cạnh, residual, normalization và temporal context là rất phù hợp với bài toán lan truyền dịch liên vùng. Về mặt thực nghiệm, sheaf_conn không chỉ giảm sai số mà còn giữ được khả năng cảnh báo tuần bùng phát ở mức gần tối ưu. Về mặt phương pháp, mô hình này cho thấy một hướng mở rộng đáng giá của học đồ thị trong dịch tễ: thay vì chỉ cộng thông tin hàng xóm, có thể học cách biến đổi và đồng bộ hóa thông tin giữa các vùng lân cận trước khi lan truyền.

6.3. Đóng góp

6.3.1. Dữ liệu và mô hình hóa

Nghiên cứu đã chuẩn hóa được một bộ dữ liệu dengue theo độ phân giải municipality–tuần, tích hợp đa nguồn (dịch tễ, khí hậu, dân số, môi trường) và đưa về dạng snapshot đồ thị nhất quán cho toàn bộ giai đoạn 2010–2024. Đây là đóng góp nền tảng giúp chuyển dữ liệu thô thành cấu trúc phù hợp cho học đồ thị không gian–thời gian.

6.3.2. Thiết kế Pipeline trong bài toán dịch tễ sốt xuất huyết

Một pipeline hoàn chỉnh đã được xây dựng, bao gồm: tạo node/edge, khởi tạo xây dựng feature& label, tạo snapshot tuần, feature engineering, chuẩn hóa, log-transform, huấn luyện–đánh giá, back-transform, benchmark đa mô hình, kiểm soát leakage, randomness control và permutation test. Đóng góp này có giá trị không chỉ cho kết quả hiện tại mà còn cho khả năng tái lập và mở rộng nghiên cứu.

6.3.3. Khả năng ứng dụng thực tế giám sát dịch tễ

Kết quả PR-AUC/ROC-AUC rất cao của sheaf_conn cho thấy nghiên cứu không dừng ở mức fit tốt số ca, mà còn có tiềm năng hỗ trợ cảnh báo sớm tuần bùng phát. Khi kết hợp với dashboard trực quan hóa đa lớp, pipeline có thể trở thành công cụ hỗ trợ ra quyết định cho giám sát và can thiệp y tế công cộng.

6.3.4. Khả năng mang thực nghiệm về Việt Nam

Mặc dù nghiên cứu sử dụng dữ liệu Brazil, cấu trúc bài toán và pipeline hoàn toàn có thể chuyển dịch sang bối cảnh Việt Nam nếu có dữ liệu tuần theo địa phương, khí hậu và liên kết hành chính tương ứng. Điều này mở ra khả năng xây dựng hệ dự báo sốt xuất huyết cấp Phường Thành Phố Quốc Gia, hoặc các bệnh truyền nhiễm khác có cơ chế lan truyền liên vùng và bản đồ trực quan hóa toàn bộ Việt Nam.

6.3.5. Hướng phát triển và kiến nghị nghiên cứu tiếp theo

Từ kết quả hiện tại, có thể đề xuất một số hướng phát triển tiếp theo. Thứ nhất, bổ sung edge features giàu ngữ nghĩa hơn như khoảng cách địa lý, luồng di chuyển, hay quan hệ giao thông. kiểm chứng mô hình trên vùng dữ liệu khác hoặc quốc gia khác, từ đó đánh giá sâu hơn về tính chuyển giao và tổng quát hóa liên miền bằng Sheaf connection.

TÀI LIỆU THAM KHẢO

- [1] Pan American Health Organization, "Epidemiological Update: Dengue in the Region of the Americas - Week 12, 2024," PAHO/WHO Institutional Repository, 2024.
- [2] M. N. S. de Oliveira, "The unprecedented surge of dengue in Brazil: A 2024 clinical and epidemiological overview," *Journal of Infection in Developing Countries*, 2024.
- [3] Agência Brasil, "Brazil hits record 1,094 dengue deaths in 2024," Agência Brasil, 2024.
- [4] S. T. Stoddard, A. C. Morrison, G. M. Vazquez-Prokopec and e. al., "House-to-house human movement drives dengue virus transmission," *Proc. Natl. Acad. Sci. USA*, vol. 110, no. 3, p. 994–999, 2013.
- [5] B. Khemani et al., "A review of graph neural networks: concepts, architectures, techniques, challenges, datasets, applications, and future directions," B. Khemani et al. , 2024.
- [6] B. Sanchez-Lengeling et al., "A Gentle Introduction to Graph Neural Networks," *Distill*, 2021.
- [7] F. Scarselli, M. Gori, A. C. Tsoi, M. Hagenbuchner, and G. Monfardini, "The graph neural network model," *IEEE Transactions on Neural Networks*, 2008.
- [8] T. N. Kipf and M. Welling, "Semi-supervised classification with graph convolutional networks," in *Proc. Int. Conf. Learn. Represent*, 2017.
- [9] P. Veličković, G. Cucurull, A. Casanova, A. Romero, P. Liò, and Y. Bengio, "Graph attention networks," in *Proc. Int. Conf. Learn. Represent*, 2018.
- [10] Ashish Vaswani, Noam Shazeer, Niki Parmar, Jakob Uszkoreit, Llion Jones, Aidan N. Gomez, Łukasz Kaiser, Illia Polosukhin, "Attention Is All You Need," *31st Conference on Neural Information Processing Systems (NIPS 2017)*, 2017.

- [11] K. Bodnar, F. Di Giovanni, B. P. Chamberlain, P. Liò, and M. M. Bronstein, "Neural sheaf diffusion," in Proc. 36th Int. Conf. Mach. Learn. (ICML), 2022.
- [12] Chen Cai, Yusu Wang, "A Note on Over-Smoothing for Graph Neural Networks," Proceedings of the 37th International Conference on Machine Learning (ICML), PMLR 108 , 2020.
- [13] Yu He, Cristian Bodnar, Pietro Liò, "Sheaf-based Positional Encodings for Graph Neural Networks," Proceedings of Machine Learning Research 228, Symmetry and Geometry in Neural Representations, 2023.
- [14] F. Ganem, L. B. Vacaro, E. C. Araujo, L. D. Alves, L. Bastos, L. M. Carvalho, I. Almeida, A. M. de Sá, and F. C. Coelho, "Mosqlimate: a platform to providing automatable access to data and forecasting models for arbovirus disease," arXiv preprint arXiv:24, 2024.
- [15] F. C. Coelho et al., "Full dataset for dengue forecasting in Brazil for Infodengue-Mosqlimate sprint 2024," Zenodo, 2024.
- [16] Pan American Health Organization (PAHO, "Dengue: Guidelines for diagnosis, treatment, prevention and control," Washington DC: Pan American Health Organization, 2019.
- [17] F. J. Colon-Gonzalez, I. R. Lake and G. Bentham, "Climate variability and the epidemiology of dengue," Int. J. Environ. Res. Public Health, 2011.
- [18] T. Dostal, J. Meisner, C. Munayco, P. J. García, C. Cárcamo and L. E. P. Lu, "The effect of weather and climate on dengue outbreak risk in Peru, 2000–2018: a time-series analysis," PLoS Negl Trop Dis, 2022.
- [19] G. Kuno, "Review of the factors modulating dengue transmission," Epidemiol. Rev., vol. 17, no. 2, p. 321–335, 1995.
- [20] Y. L. Hii, N. Rocklöv, M. Ng and A. Ebi, "Forecast of dengue incidence using temperature and rainfall," PLoS Negl Trop Dis, vol. 6, no. 11, p. e1908, 2012.

PHỤ LỤC